Université d'ORLÉANS

MASTER 1 MATHÉMATIQUES APPLIQUÉES, STATISTIQUE

2024 – 2025

Projet en Mathématiques appliquées

Analyse multidimensionnelle des données de tourbières.

Encadrante : Sophie Jacquot

Étudiants : Kokou TETE et Eunice SITTI-MAWUBEJRO

Université d'Orléans
Année universitaire 2024–2025

Remerciements

Nous tenons à exprimer notre profonde gratitude à Madame Sophie JACQUOT, notre encadrante, pour son soutient constant, la justesse de ses conseils, sa disponibilité sans faille et le temps précieux qu'elle nous a consacré tout au long de ce projet. Son accompagnement a été déterminant à chaque étape de notre travail.
Nous adressons également nos sincères remerciements à Monsieur Thomas HABERKORN, directeur de notre master ainsi que tous nos profs. Leur engagement et la qualité de leurs enseignements ont grandement contribué à notre formation et à la réalisation de ce projet.

Table des matières

Introduction **5**

I Contexte 6

0.1 Qu'est-ce qu'une tourbière ? 7
0.2 Programme junon 7

II Analyse des données 9

1 Chargement et Exploration des données **10**
1.1 Chargement des bibliothèques 10
1.2 Chargement des données et petits réglages 10
1.3 Visualisation des variables d'intérêt 11
1.3.1 $FC0_2$ 11
1.3.2 FCH_4 12
1.4 Traitement des manquants 13
1.4.1 Imputation des manquants 15
1.5 Les variables d'intérêt après imputation 15
1.5.1 FCO_2 15
1.5.2 FCH4 17

2 Analyse en Composantes Principales(ACP) **19**
2.1 En quoi cela consiste-t-il ? 19
2.2 ACP sur les données 19
2.2.1 Ecarts-types 19
2.2.2 L'ACP 20
2.2.3 Corrélations entre les variables 21
2.2.4 Les cercles de corrélation 22
2.2.5 Les cercles de corrélation avec les variables supplémentaires 25
2.2.6 Quelques remarques et commentaires 28
2.2.7 Représentation du plan factoriel 30
2.2.8 Regard sous un autre angle 34

III Modélisation des séries temporelles et prévisions 43

1 **44**
1.1 Introduction 44

1.2 Les différentes étapes de la modélisation de série temporelles 44
1.2.1 Méthodologie ARIMA 44
1.2.2 Quelques détails sur les différentes parties théoriques 45
1.3 Application sur nos données 46
1.3.1 Les composantes principales 46
1.3.2 Les gaz à effets de serre 50
1.3.3 Comparaison des modèles 72
1.4 Impact des phénomènes observés sur les flux de CO_2 et CH_4 80
1.5 Modélisation des flux de CO_2 et CH_4 sur les données mensuelles 81

Conclusion générale **88**
Annexe 1 89
Annexe 2 92
Bibliographie 96

Introduction

Les tourbières sont des lieux continuellement saturés en eau, où se développe une faune et une flore spécifiques à elles. La conséquence de la saturation en eau du sol est son appauvrissement en oxygène, une situation dite anoxique. Avec le travail du temps, au fil des années et des décennies cette situation est ainsi favorable à l'accumulation d'une matière organique appelée la tourbe. Grâce à la tourbe, les tourbières ont la capacité de stocker du carbone. Ce sont des zones humides particulières, des écosystèmes ayant un rôle essentiel dans la régulation du climat. Cependant, leur fonctionnement reste mal compris et elles subissent des dégradations causées par l'Homme et l'activité humaine. En fonction des régions, on peut trouver des comportements qui pourraient déstabiliser ces écosystèmes assez particuliers. Au XXe siècle en Norvège par exemple, elles étaient asséchées pour en faire des surfaces cultivables. En Ecosse par contre, la tourbe est parfois prélevée et utilisée comme combustible dans des cheminées pour se réchauffer ; et d'autres encore la prélèvent pour en faire du terreau. On comprend ainsi que l'utilisation de la tourbe par l'homme ne date pas d'hier. Elle a été un matériau utilisé pour diverses activités ou pour résoudre différentes problématiques. Autant d'actions qui avec le temps pourraient considérablement nuire au fonctionnement des tourbières.

Dans le cadre de notre projet, nous travaillons sur la tourbière de La Guette. La tourbière de la Guette est une étendue de 1300 m autour de la rivière la Guette. Sa superficie est de 23 ha et présente une profondeur de tourbe allant de 80 cm à 1,80 m par endroit. Il contient une grande variété de faune et de flore. Sa taille et sa biodiversité en font donc un bon sujet d'analyse. Nous allons étudier cette tourbière à l'aide du programme Junon ; programme qui vise à développer un jumeau numérique de cet écosystème. Ce jumeau numérique permet de simuler le fonctionnement écologique de la tourbière à partir d'un ensemble de données environnementales variées, incluant entre autres les flux de CO2, de CH4, l'évapotranspiration, la température du sol ou encore l'humidité. Notre objectif est de mener une analyse multidimensionnelle et temporelle de ces données afin de mieux comprendre le fonctionnement de la tourbière.

Notre démarche se résume en ces points :

- Nettoyer les données, en identifiant les valeurs manquantes et les valeurs aberrantes, puis en les imputant à l'aide de méthoses appropriées.

- Réaliser une Analyse en Composantes Principales (ACP) en mettant en supplémentaires les variables CO2, de CH4, afin d'interpréter les grandes structures de variation et de repérer les variables les plus influentes dans le système étudié.

- Analyser les composantes principales comme des séries temporelles, en étudiant leurs tendances, saisonnalités et anomalies à l'aide des vus en cours.

Enfin, nous chercherons à modéliser les séries chronologiques de CO2 et CH4, en particulier à travers des régressions sur les composantes principales, pour mieux comprendre leur dynamique et leur sensibilité aux autres variables environnementales.

Première partie

Contexte

0.1 Qu'est-ce qu'une tourbière ?

Les tourbières qui font l'objet de notre document ont longtemps été perçues comme des lieux insalubres. Parfois confondus aux marais et aux marécages, elles ont fait l'objet de plusieurs dégradations par l'homme. La question que l'on se pose est de savoir si ces lieux sont réellement insalubres. En réalité, cette perception est erronée et vient principalement de l'ignorance qu'on peut avoir de ces écosystèmes, de leur rôle et de leurs utilités écologiques. Pour mieux comprendre les données sur lesquelles nous travaillons, il a été nécessaire d'améliorer notre compréhension des tourbières, de leur fonctionnement et de leur importance. Qu'est ce donc une tourbière ?

Une tourbière est une zone humide continuellement saturée en eau au contraire des marais qui peuvent s'assécher à des moments de l'année. Il s'y développe une végétation speécifique. Ce milieu constamment saturé d'eau entraîne la pauvreté du sol en oxygène. Cet élément cause une décomposition incomplète des végétaux et des animaux morts qui se retrouvent sur ce sol. Cette accumulation de végétaux et de faune morte au fil des décennies donne naissance à une matière organique appelée la tourbe. Et c'est grâce à cette matière organique particulière que les tourbières jouent un rôle important dans les enjeux climatiques.

Les tourbières peuvent agir ou être utiles de différentes façons et on va le découvrir dans les prochaines lignes. En effet, elles peuvent agir comme puits de carbone (en absorbant du carbone et le stockant) ou au contraire comme source de carbone (en participant à l'émission de carbone). Même si elles ne couvrent que 3% des terres émergées, elles peuvent stocker entre 30 et 33% du carbone mondial. En plus de cela, elles ont un impact important sur le cycle de l'eau, en prévenant par exemple des inondations. On peut aussi évoquer le rôle qu'elles peuvent avoir dans la documentation des espèces végétales comme animales. En effet la biomasse végétale ou animale ne s'étant pas entièrement décomposée, on y retrouve de l'ADN de différentes espèces qui s'y est accumulé avec le temps. Malgré leur importance, ces écosystèmes restent mal compris et continuent d'être menacés par le drainage,l'exploitation agricole et le changement climatique. Il est donc essentiel de mieux les connaître pour les préserver efficacement.

0.2 Programme junon

Selon le site internet de l'institut d'études avancées du Val de Loire, le Studium, Junon est "un ambitieux programme de développement" d'un pôle de recherche numérique sur l'environnement continental en région Centre Val de Loire. Il est piloté par le Bureau de Recherche Géologiques et Minières, en association avec différents organismes dont des organismes de recherche, des laboratoires, l'université d'Orléans entre autres. Il s'inscrit

dans un ensemble d'actions plus large visant à concevoir des services numériques visant à améliorer le suivi et la compréhension de l'environnement dans le but de permettre une meilleure gestion des ressources naturelles. Dans cette optique, les chercheurs développent ainsi des jumeaux numériques sur l'eau, le sol, et l'air. Le programme Junon vise ainsi à créer un jumeau numérique (qui est une réplique virtuelle) d'un objet, d'un projet, d'un processus ou d'un système tout au long de son cycle de vie. Il permet de mieux comprendre l'évolution de son double réel et de prévoir son développement. Il a pour objectif d'aider à la gestion des ressources naturelles comme énoncé plus haut et à la prévision des catastrophes climatiques grâce à des outils numérique. L'ambition de ce programme est de mieux suivre et gérer les ressources naturelles régionales et de former un outil de prédiction servant au développement harmonieux et durable du territoire. Avec l'aide des données présentées par le programme, nous allons essayer de mieux comprendre le fonctionnement de la tourbière de la Guette et comment les différentes variables peuvent avoir un impact sur son écosystème.

Deuxième partie

Analyse des données

Chapitre 1

Chargement et Exploration des données

Nous disposons d'un jeu de données qui répertorie différentes mesures bio-météorologiques qui ont été effectuées sur le site de la tourbière de la guette (située dans la région centre val de Loire). Ce jeu de données est composé de 1807 lignes et 60 colonnes. Il répertorie 59 variables sur une période de Janvier 2017 à Décembre 2021 . Il provient du programme junon. Nous allons dans un premier temps explorer ces données avec RStudio.

1.1 Chargement des bibliothèques

Puisque nous utilisons RStudio, il faut que nous chargons quelques charger bibliothèques importantes à la réalisation de notre travail. En voici la liste et leur utilité.

```
library(tseries)
library(dygraphs)
library(VIM)
library(corrplot)
library(missMDA)
library(xts)
library(ggplot2)
library(ade4) \#pour l'acp
library(forecast)
```

1.2 Chargement des données et petits réglages

```
data1 = read.table("dataprojet1.txt",header = TRUE)
summary(data1)
dim(data1)
date=as.Date(data1[,1])
donnees = data.frame(date,data1[,-1])
summary(donnees)
dim(donnees)
```

Nous chargeons d'abord les données à partir du fichier `dataprojet1`. Une rapide exploration avec summary nous permet de constater que nous avons 1807 lignes et 60 colonnes

de mesures prises entre janvier 2017 et décembre 2021.
Ensuite, la colonne `"date"` est convertie au bon format. L'objet `"donnees"` contient l'ensemble des données nécessaires à notre analyse.
A présent, examinons certaines variables notamment FCO_2 et FCH_4

1.3 Visualisation des variables d'intérêt

Tous les graphiques interactifs ci-dessous sont présentés sous forme statique mais disponible dans notre fichier .RMD. L'exploration interactive est donc disponible dans le fichier .RMD.

1.3.1 $FC0_2$

Le $FC0_2$ est une variable qui représente le flux de dioxyde de carbone (CO_2) mesuré dans notre tourbière. D'après la documentation du programme Junon, un flux négatif signifie qu'il y a production de plus de matière organique et donc plus de carbone stocké. Tandis qu'un flux positif signifie qu' il y a plus de gaz à effet de serre relâché dans l'atmosphère donc des températures plus hautes que la normale.
Interessons-nous à la courbe de son évolution dans le temps. Ci-après, le code utilisé ; la fonction dygraph vient de la bibliothèque Dygraphs que nous avons chargée plus haut.

```
attach(donnees)
dataFCO2 = data.frame(date,FCO2)
dygraph(dataFCO2,main="Flux␣de␣␣␣CO2␣dans␣la␣tourbiere") %>%
  dySeries("FCO2", label = "FCO2", color = "blue") %>%
  dyAxis("y", label = "Valeurs") %>%
  dyOptions(strokeWidth = 1.5) %>%
  dyLegend(show = "always")%>%
  dyRangeSelector()
```

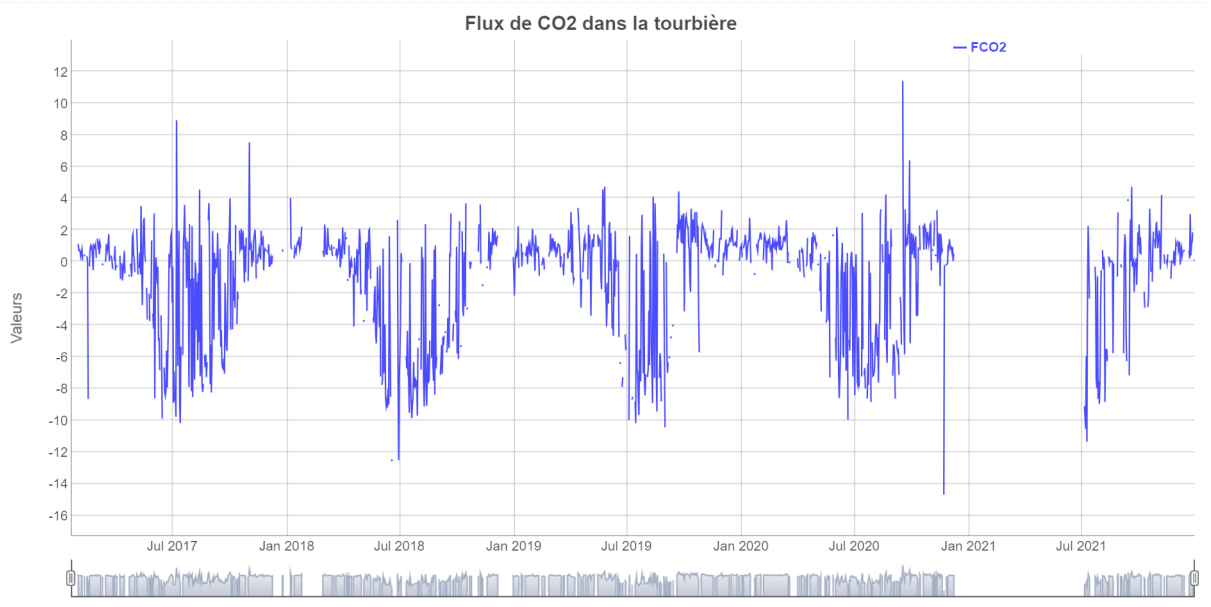


FIGURE 1.1 – flux de $C0_2$ dans la tourbière

Le graphique 1.1 montre l'évolution du flux de CO_2 de janvier 2017 à décembre 2021. Nous constatons que le CO_2 varie fortement au cours de cette période. Cependant, ce graphique ne nous aide pas à faire une lecture claire de cette évolution. En effet, on constate la présence d'interruptions nettes, un vide à plusieurs endroits, notamment entre Décembre 2020 à Juillet 2021. Ces zones vides correspondent à des valeurs manquantes (NA) dans les données.

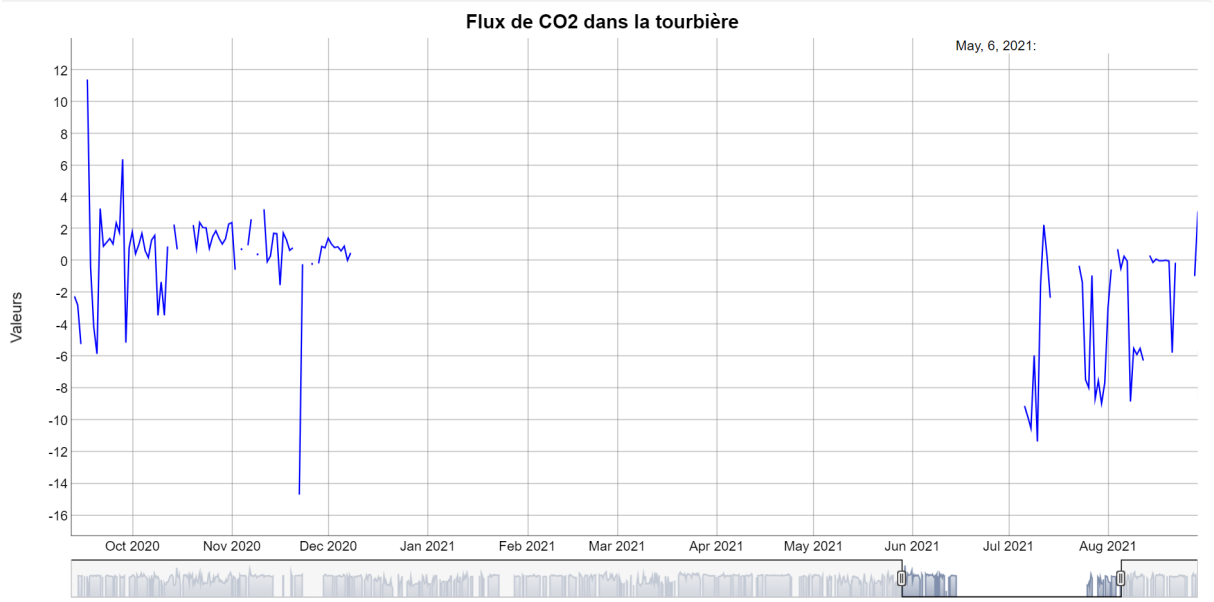


FIGURE 1.2 – les manquants sur une période

Ces valeurs manquantes compliquent nos analyses. Vérifions si nous rencontrons le même problème avec la variable FCH_4.

1.3.2 FCH_4

Le flux de méthane (CH_4) est une autre variable clé à analyser. De même, intéressons-nous à la courbe de son évolution dans le temps. Le code utilisé est similaire à celui de la partie précédente.

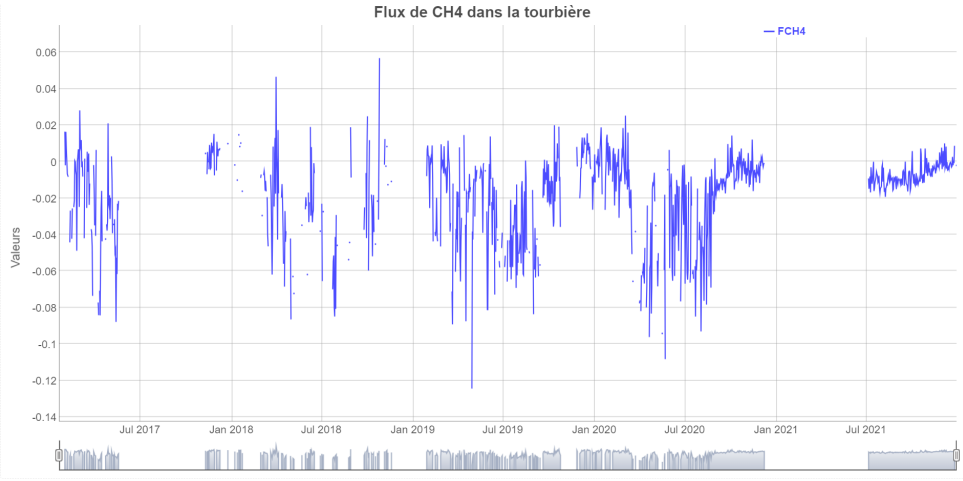


FIGURE 1.3 – Flux de CH_4 dans la tourbière

Comme pour le CO_2, le graphique 1.3 présente des discontinuités. Pour l'illustrer, nous avons fait un zoom sur la période de Juin 2017 à Avril 2018 ; nous constatons une longue période avec très peu de mesures.



FIGURE 1.4 – Manquants sur une période

Avec cette variable aussi, il y a des valeurs manquantes. Ces valeurs manquantes constituent un frein considérable à l'avancement de nos analyses notamment l'ACP. Nous devons donc utiliser une méthode pour remplacer les NA car nous ne pouvons pas juste les enlever.Pour ce faire, nous allons utiliser une méthode d'imputation des manquants.

1.4 Traitement des manquants

Nous avons constaté que dans notre jeu de données, il y a plusieurs valeurs manquantes(NA). En effet, sur les dygraphs précédents, il y a plusieurs espaces vides ainsi que des ruptures dans les courbes d'évolution de nos variables.
Pour avoir une idée précise de l'ampleur de ces NA, comptons d'abord le nombre total de NA. Pour ce faire, regardons de plus près avec le code suivant :

```
natot = sum(is.na(donnees))
cat("le nombre de valeurs manquantes au total est  :",natot, "\n"
   )
```

Le nombre de valeurs manquantes au total est : 14885. Chacune de nos 59 variables comportent des NA. Ces NA sont répartis en différentes proportions pour chaque variable.

```
na_prop <- sort(colMeans(is.na(donnees[,-1])))
na_prop
barplot(na_prop, las = 2, col = c(1:60), main = "Proportion de
   valeurs manquantes par variable",
        ylab = "Proportion")
```

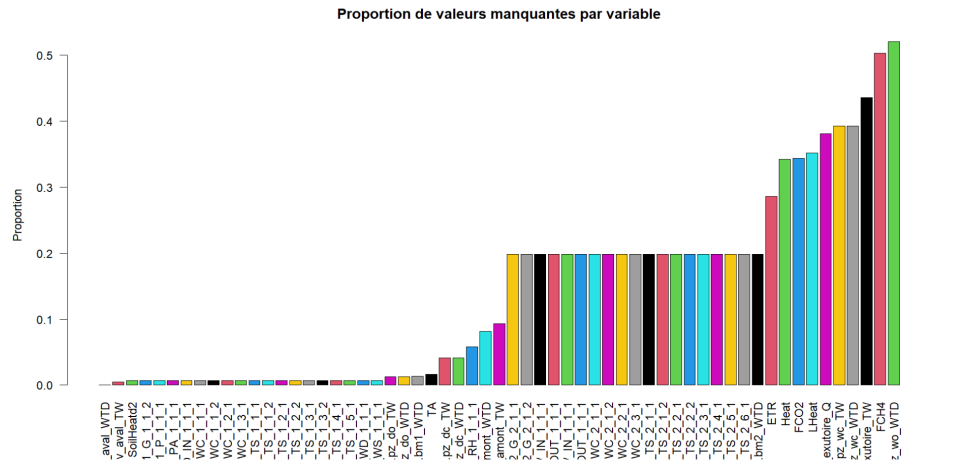


FIGURE 1.5 – Repartition des NA par variable

D'après ce graphique, certaines variables présentent plus de 50% de manquants (notamment FCH_4 et `lgt.pz_wo_WTD`). La variable qui a le moins de NA est lgt.pz_cbdv_aval_WTD et celle qui en a le plus est lgt.pz_wo_WTD avec 52,08% de manquants.

Nos variables principales, FCO_2 et FCH_4, présentent elles aussi un taux élévé de données manquantes.

```
naFCH4<- round((sum(is.na(FCH4)) / nrow(donnees))*100,2)
naFCO2<- round((sum(is.na(FCO2)) / nrow(donnees))*100,2)
```

— FCO_2 : 34,37% de valeurs manquantes

— FCH_4 : 50,3% de valeurs manquantes

La quantité non négligeable des valeurs manquantes constitue une limitation majeure pour la suite.
Examinons de plus près la répartition des NA entre nos variables d'intérêt :

```
aggr(donnees[, c("FCO2", "FCH4")],numbers=TRUE )
```

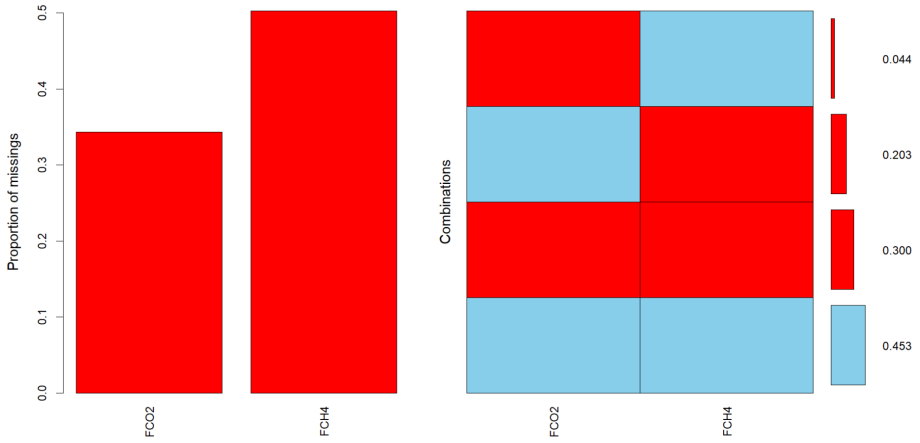


FIGURE 1.6 – Distribution des NA de FCO_2 et FCH_4

Sur ce graphique, chaque barre indique une configuration de présence ou d'absence des deux variables. Voici ce que l'on observe :

— 45,3% des observations ont à la fois FCO_2 et FCH_4 présents.

— 30% des observations présentent l'absence simultanée des deux.

— 20,3% des cas ont FCH_4 manquant alors que FCO_2 est présent

— 4,4% des cas ont FCO_2 manquants et FCH_4 présent

Ceci renforce la nécessité de choisir une méthode d'imputation adaptée, capable de prendre en compte la structure des données.

1.4.1 Imputation des manquants

Nous allons utiliser les outils du package missMDA pour gérer les manquants. Ces outils permettent de remplacer les NA par des valeurs plausibles. L'idée ici, est de prédire ces valeurs à partir d'une analyse en composantes principales (ACP) qui prend en compte les similarités entre individus et entre variables.
Avant l'imputation proprement dite, nous devons choisir un nombre optimal de composantes à conserver pour l'ACP. Pour cela, nous utilisons la fonction `estim_ncpPCA()`, qui évalue ce nombre en minimisant le critère d'erreur de prédiction des valeurs manquantes (SMEP).

```
nb1 <- estim_ncpPCA(donnees[,-1], method = "Regularized")$ncp

dataimp <- imputePCA(donnees[,-1], ncp = nb1, method = "
   Regularized")$completeObs
dataimp = data.frame(date,dataimp)
summary(dataimp)
```

Nous avons utilisé la méthode dite "Regularized", qui introduit une pénalisation afin d'éviter le sur-ajustement, en particulier dans les jeux de données avec beaucoup de bruit ou de manquants, comme c'est le cas ici.

1.5 Les variables d'intérêt après imputation

Nous voulons maintenant vérifier visuellement si l'imputation semble cohérente. Autrement dit, les courbes des variables clés (FCO_2 et FCH_4) montrent-elles une continuité crédible, sans ruptures ou comportements bizarres liés à l'imputation ?

1.5.1 FCO_2

```
s_FCO2 <- xts(dataimp[, "FCO2"],order.by = date)
s_FCH4 <- xts(dataimp[, "FCH4"],order.by = date)
dygraph(s_FCO2, main = "Imputation␣PCA␣-␣FCO2")
```

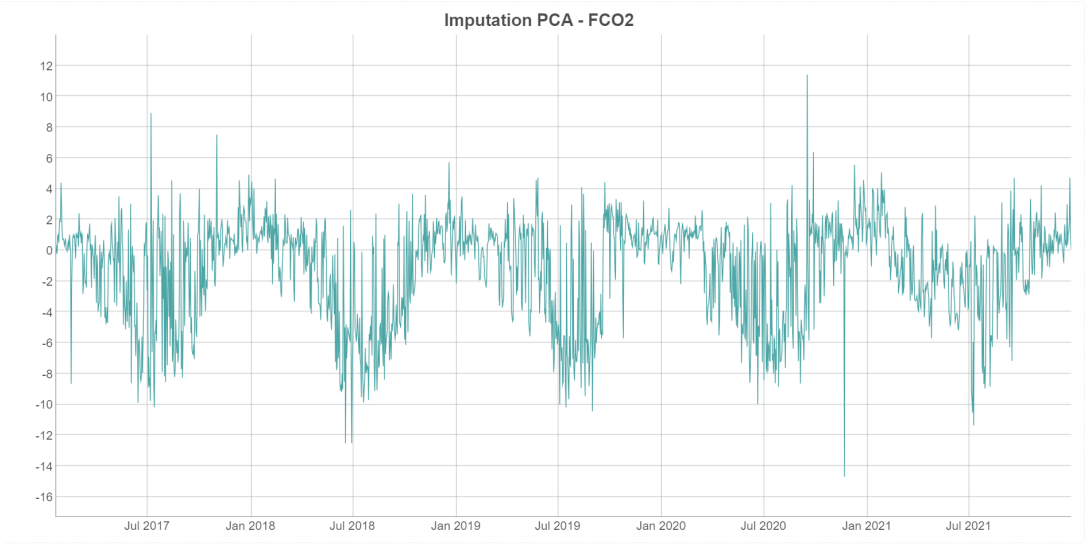


FIGURE 1.7 – Évolution du flux de CO_2 après imputation

Le graphique 1.7 montre une évolution harmonieuse, sans comportement bizarre à première vue. Les périodes où il y avait initialement des manquants semble être comblés et s'intègrent assez bien au reste de la courbe.

Pour mieux vérifier, nous avons utilisé la fonction `ggplot_na_imputations`, qui montre les valeurs initiales (en bleu) et les valeurs imputées (en rouge) :

```
ggplot_na_imputations(donnees[,-1]$FCO2, s_FCO2)
```

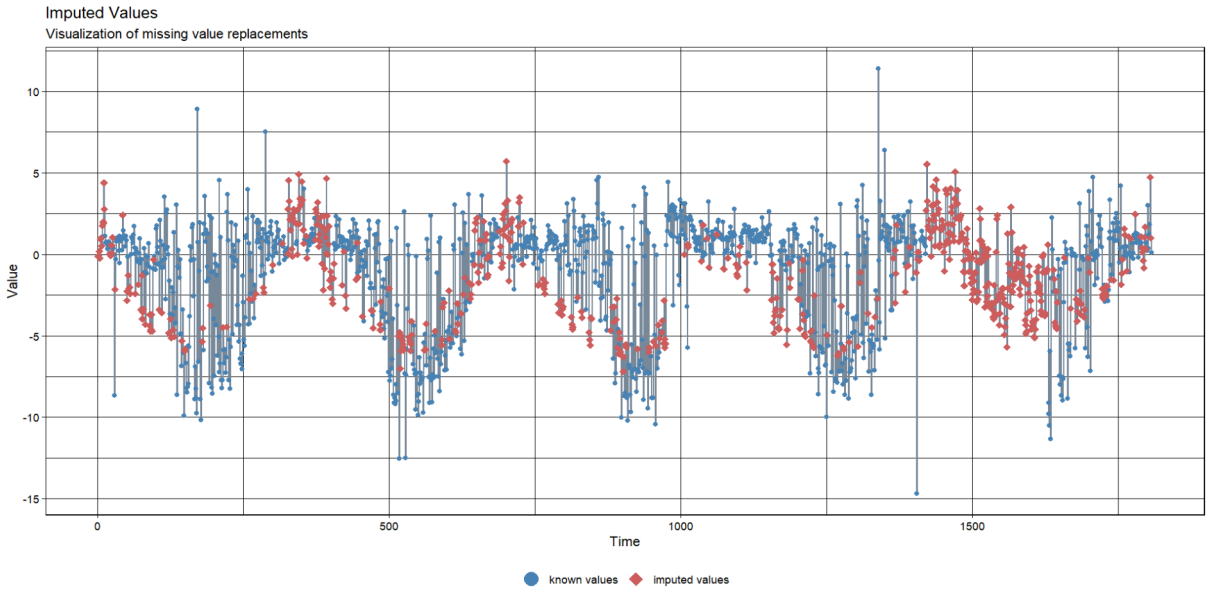


FIGURE 1.8 – Comparatif

Les points rouges restent cohérents avec l'allure de la courbe. Visuellement, nous ne remarquons aucun comportement bizarre. Cela suggère que l'imputation a été bien faite pour cette variable. De plus nous avons comparé les statistiques (Min,Max, moyenne et ecart type) de cette variable avant et après imputation.

```r
summary(dataimp$FCO2)
summary(donnees$FCO2)

sd(dataimp$FCO2, na.rm = TRUE)
sd(donnees$FCO2, na.rm = TRUE)
```

Et nous avons obtenu des résultats plutot encourageant. En efffet :

- le Min avant est pareil que celui après imputation , qui est de -14.695.
- également le Max reste inchangé avant et imputation. il est de 11,3887.
- il y a une "légère" différence entre la moyenne avant imputation (-1,1414) et celle d'après qui est de -1,2126
- les écart-types diffère aussi. Avant imputation, il était de 3,4831 alors qu'après , il est 3,2398

Globalement, les valeurs extrêmes (Min,Max) restent inchangées est encourangeant. Et même s'il y a une différence entre la moyenne avant après et l'écart-type avant après, cette différence reste "légère". Ce qui suggère que l'imputation sur cette variable est acceptable.

1.5.2 FCH4

```r

dygraph(s_FCH4, main = "Imputation PCA - FCH4")
```

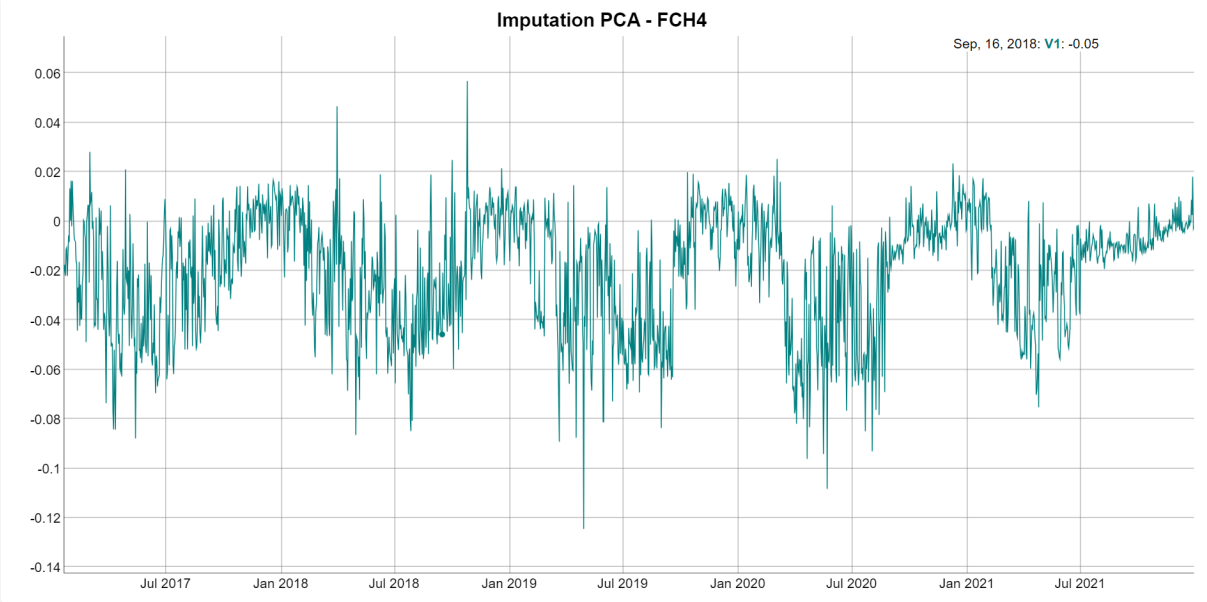


FIGURE 1.9 – Évolution du flux de CH_4 après imputation

Nous constatons la même chose pour cette variable, le flux de CH_4. Le graphe montre une évolution continue sans comportement inattendu visuellement.

```r
ggplot_na_imputations(donnees[,-1]$FCH4, s_FCH4)
```

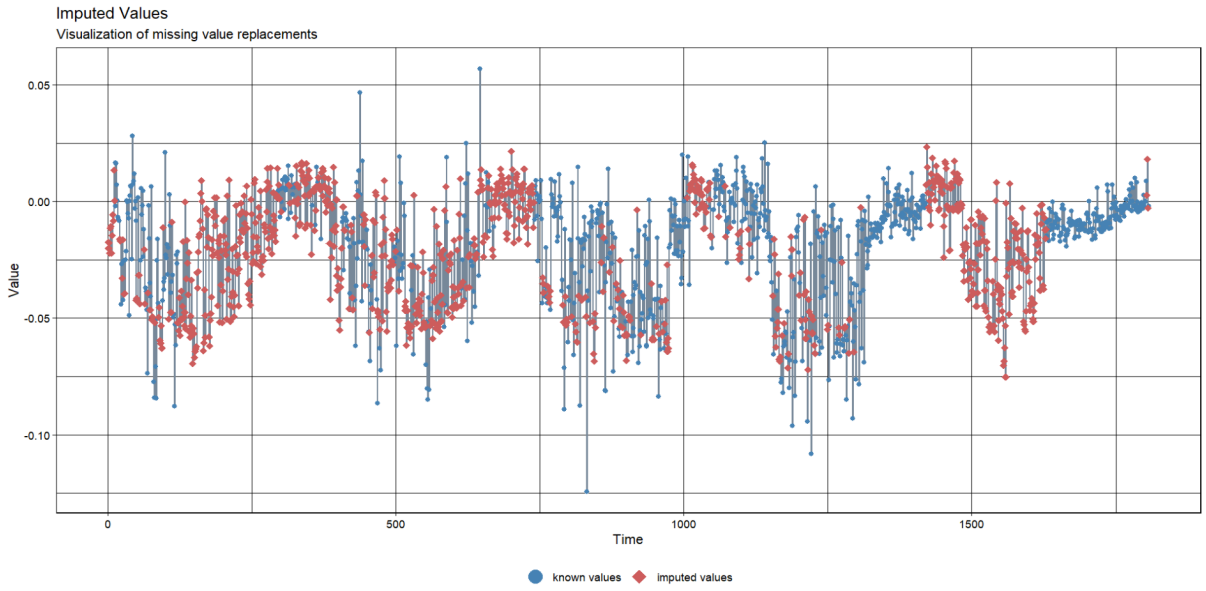


FIGURE 1.10 – Comparatif CH4

Avec la fonction `ggplot_na_imputations` , les points rouges qui représentent les valeurs imputées semblent bien s'intégrées au graphe. De plus nous avons comparé les statistiques (Min,Max, moyenne et ecart type) de cette variable avant et après imputation. Et nous avons pu remarqué que :

- le Min (-0,1244) reste inchangé.
- le max (0,0568) reste aussi le même .
- la moyenne avant imputation est -0,018. elle est assez différente de celle d'après qui est -0,0201
- l'écartt type d'après a légèrement diminue passant de 0,0238 (avant imputation) à 0,0235 après

Les valeurs extrêmes, min et max n'ayant pas changé et comme les écarts-types sont du même ordre, ça semble etre bon signe pour notre imputation. Cependant, étant donné que la variable FCH_4 présentait plus de 50% de NA, il est important de faire attention à nos interprétations en ce qui la concerne.

Chapitre 2

Analyse en Composantes Principales(ACP)

2.1 En quoi cela consiste-t-il ?

L'analyse en composantes principales (ACP) consiste à résumer un tableau de données quantitatives de n lignes (aussi appelés individus) et p colonnes (aussi appelés caractères ou variables), avec $p > 2$.
L'objectif ici est de réaliser une synthèse et une simplification de l'information disponible, et en "perdant" le moins possible de l'information présente dans les données de départ. Pour cela, on va réduire la dimension du jeu de données tout en concervant le plus possible l'information de départ. L'ACP recherche de nouvelles variables, appelées composantes principales, qui sont des combinaisons linéaires des variables d'origine et qui capte la plus grande part possible de la variabilité totale. Cette technique permet notamment :

— de visualiser les données dans un espace de faible dimension (souvent 2 ou 3 axes) ;

— de repérer des structures dans les données : regroupements, oppositions et corrélations ;

— de simplifier le jeu de données pour une interprétation plus efficace.

2.2 ACP sur les données

Notre jeu de données contient un ensemble de mesures réalisées sur la tourbière. Ces mesures sont exprimées dans diverses unités de mesure. L'évapotranspiration (ETR) par exemple est exprimée en mm/h, le flux de CO_2 (FCO_2) quant à lui est mesuré en mumolCO$_2$/m^2/s, la vitesse du vent en m/s etc. Vu qu'il y a plusieurs unités de mesure, nous avons pensé à faire une ACP normée. Mais, pour en avoir le cœur net, nous avons vérifié les écarts-types des variables dans le but de voir s'ils ont le même ordre de grandeur.

2.2.1 Ecarts-types

```
print(apply(dataimp[,-1],2,sd),3)
sdmen <- apply(dataimp[,-1],2,sd)
max(sdmen)/min(sdmen) )
```

Le rapport entre l'écart-type maximum et l'écart-type minimum est de l'ordre de 6935. Ce chiffre montre un déséquilibre fort entre les variables : certaines varient énormément , d'autres très peu. Si nous les utilisions telles quelles, les variables qui ont un petit écart-type seraient négligées dans la construction des composantes principales. Il est donc nécessaire de réaliser une ACP normée. Cela permettra de donner le même poids à chaque variable, indépendamment de son échelle.

2.2.2 L'ACP

Nous utilisons les outils du package ADE4 dans cette partie. Comme nous voulons comprendre comment les gaz à effet de serre se comportent dans notre tourbière, nous allons les mettre en variables supplémentaires. Cela nous permettra dabord de voir comment les autres variables se comportent : est-ce-qu'il y a des regroupements ? des oppositions ? ou est-ce-que certaines sont liées ?
Ensuite, nous pourrons voir comment les GES se projettent dans l'ensemble.

```
acpj <- dudi.pca(dataimp[,-c(1,3,4)], scale = TRUE, scannf = F,
   nf =7)
class(acpj)
names(acpj)
head(acpj$li)
```

Inertie

L'inertie permet de mesurer la proportion d'information expliquée par chaque axe principal. Nous voulons gardé les axes qui résument au mieux les données (généralement ce sont les premières).

```
inertie <- inertia.dudi(acpj, col.inertia = F, row.inertia = T)
names (inertie)
inertie$tot.inertia
```

	inertia <dbl>	cum <dbl>	cum(%) <dbl>
Ax1	2.946403e+01	29.46403	51.69128
Ax2	9.278844e+00	38.74287	67.96996
Ax3	5.877332e+00	44.62021	78.28106
Ax4	3.773572e+00	48.39378	84.90137
Ax5	1.574224e+00	49.96800	87.66316
Ax6	8.908973e-01	50.85890	89.22614
Ax7	8.721185e-01	51.73102	90.75617
Ax8	7.732400e-01	52.50426	92.11273
Ax9	6.851419e-01	53.18940	93.31474
Ax10	5.624855e-01	53.75189	94.30155
Ax11	4.452057e-01	54.19709	95.08262
Ax12	3.733960e-01	54.57049	95.73770
Ax13	3.181890e-01	54.88868	96.29592
Ax14	2.413269e-01	55.13000	96.71930
Ax15	2.393172e-01	55.36932	97.13916
Ax16	1.932826e-01	55.56260	97.47825
Ax17	1.852712e-01	55.74787	97.80329
Ax18	1.549263e-01	55.90280	98.07509
Ax19	1.257045e-01	56.02850	98.29562
Ax20	1.093928e-01	56.13790	98.48754
Ax21	9.766335e-02	56.23556	98.65888
Ax22	8.506627e-02	56.32063	98.80812
Ax23	7.731220e-02	56.39794	98.94375
Ax24	7.372785e-02	56.47167	99.07310
Ax25	6.642920e-02	56.53810	99.18964

1-25 of 57 rows Previous 1 2 3 Next

FIGURE 2.1 – Pourcentage d'inertie expliqué par chaque axe

Le document 2.1 montre le pourcentage d'inertie expliquée par chaque axe et les inerties cumulées correspondantes. En nous arrêtant aux 3 premiers axes, nous avons déjà plus de 70% (78,28% plus précisément) de l'inertie totale. Cela signifie qu'une grande partie de l'information du jeu de données est concentrée dans ces 3 axes là. Nous pourrons donc nous concentrer principalement sur eux pour la suite de notre analyse.

Eboulis des valeurs propres

Pour conforter notre choix, nous utilisons la règle du coude sur l'éboulis des valeurs propres.

```
barplot(acpj$eig,names.arg=1:length(dataimp[,-c(1,3,4)]))
```

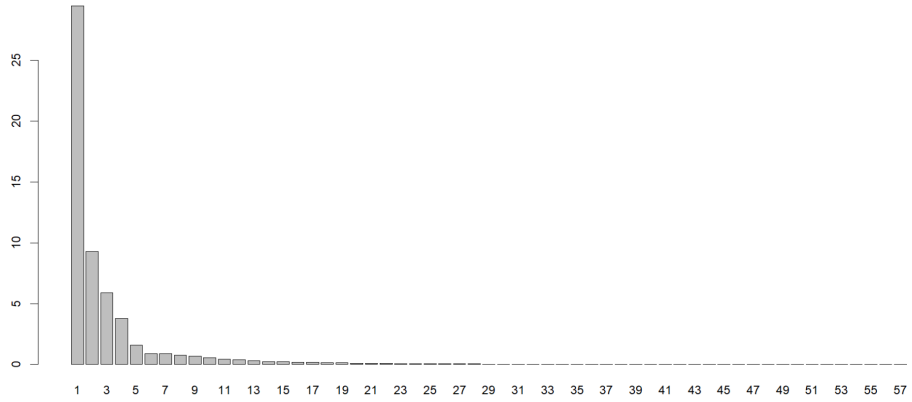


FIGURE 2.2 – Eboulis des valeurs propres

En utilisant la règle du coude, nous sommes tentés de garder 3 à 4 axes principaux. On voit que avec les 3 premier axes, on capte plus de 78% d'inertie et avec 4 axes, nous arrivons à expliquer 84,90%. Pour la suite, commençons d'abord avec 3 axes.

2.2.3 Corrélations entre les variables

Avant de continuer avec l'ACP, nous avons visualisé la matrice de corrélation des variables. Notre objectif est de voir si certaines variables sont fortement liées ou si au contraire elles sont peu corrélées.

```
mcorr<-as.matrix(cor(dataimp[,-1], use = "complete.obs"))
corrplot(mcorr,type="upper",tl.cex=0.6, order="hclust",tl.col="
   black",tl.srt=100 )
```

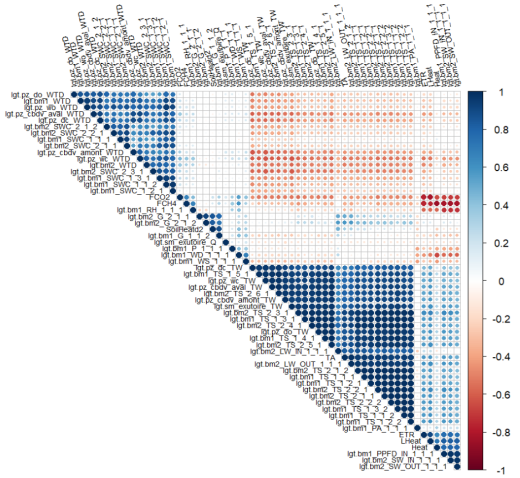


FIGURE 2.3 – Matrice de corrélation des variables

Sur cette figure, on distingue quelques informations :

— Les variables FCO_2 et FCH_4 présentent une corrélation négative avec certaines variables énergétiques comme l' ETR(l'évapotranspiration), LHEAT(chaleur latente), HEAT(la chaleur sensible). Cela pourrait signifier que le flux de GES est influencés par la chaleur sur le site. Sur la figure, elles sont représentées par la couleur rouge

— Les variables mesurant la température du sol à différents endroits et à différentes profondeurs sur le site forment un bloc homogène et semblent fortement corrélées entre elles (notamment lgt.bm2_TS_2_1_1, lgt.bm2_TS_2_1_2 , lgt.bm2_TS_2_2_1 , lgt.bm2_TS_2_2_2 , lgt.bm1_TS_1_1_1, lgt.bm1_TS_1_1_2 ? lgt.bm1_TS_1_2_2 ...). Elles sont représentées en bleu foncé.

— Le bloc bleu assez clair regroupe les variables qui mesurent le Water Table Depth(WTD), l'eau du sol (SWC)

2.2.4 Les cercles de corrélation

Nous représentons les cercles de corrélation des variables obtenus à partir de l'ACP. Ces cercles permettent de voir la représentation des variables par les composantes principales. Elles aident surtout à comprendre comment les variables se regroupent ou s'opposent.

Axes 1 et 2

```
s.corcircle(acpj$co,xax=1,yax=2,clabel=0.5, sub ="cercle de
   correlation")
title ( "ACP normee: 1-2")
```

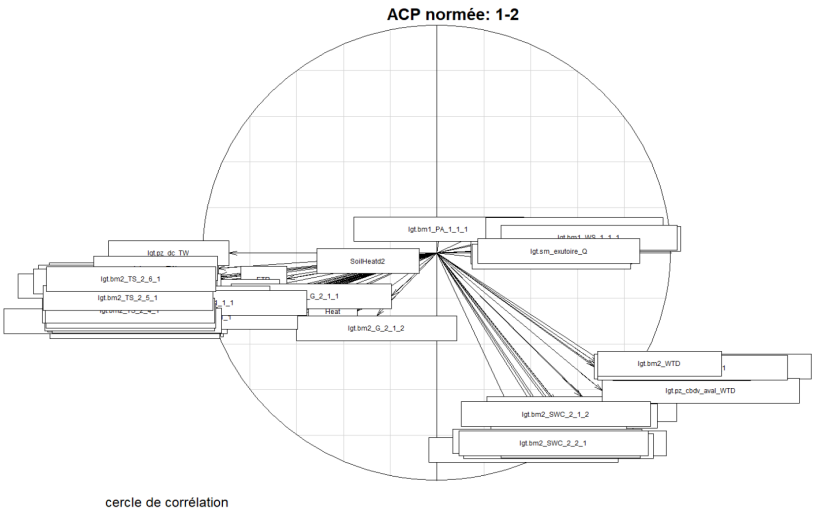


FIGURE 2.4 – Cercle de corrélation avec les axes 1 et 2

Sur la figure 2.4 , nous distinguons 2 grands groupes de variables bien représentées et un ensemble d'autres mal représentées (proches du centre du cercle donc peu corrélées avec les axes 1 et 2). Parmi les variables bien représentées, nous remarquons que :

Le long de l'axe 1 (l'axe horizontal) : on retrouve les variables liées à la chaleur comme :

— le rayonnement (SW)

— la température du sol (TS)

— tla empérature de l'eau (TW)

— l'évapotranspiration (ETR).

Cela suggère que **l'axe 1** capte assez **les phénomènes thermiques** dans la tourbière.

Le long de l'axe 2 (axe vertical) : on retrouve les variables comme :

— la profondeur de la nappe phréatique (WTD)

— la teneur en eau du sol (SWC)

Dans ce plan, les variables proche du centre ne sont pas bien décrites. Elles sont peut être mieux représentées dans d'autres plans. Regardons le cercle suivant.

Axes 1 et 3

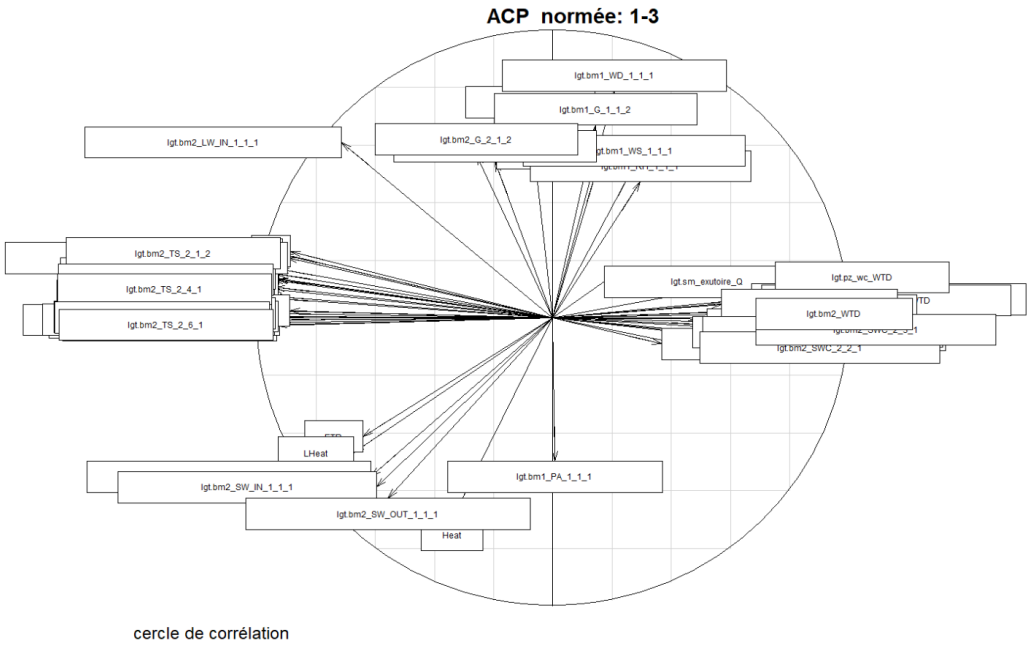


FIGURE 2.5 – Cercle de corrélation avec les axes 1 et 3

Sur la figure 2.5, nous observons 4 grands groupes bien représentés et bien séparés. Deux groupes sur l'axe 1 et deux sur l'axe 3.

Le long de l'axe 1 :

— A droite, on retrouve des variables liées à **la teneur du sol en eau** (SWC) et à **la profondeur de la nappe phréatique** (WTD) ;

— A gauche, on trouve des variables qui sont liées à la **température du sol** (TS).

Avec ça, nous pouvons dire que d'un coté l'axe 1 capte les phénomènes liés à la dynamique de l'eau (hydrologique) et de l'autre, il capte les phénomènes thermiques.
Comme les deux cotés sont opposés, cela suggère que les phénomènes thermiques et hydriques sont **antagonistes** : quand l'un augmente, l'autre diminue. Quand le sol se réchauffe, il perd de l'humidité.

Le long de l'axe 3 : Nous distinguons :

- En bas, on trouve : **la teneur en eau du sol** (SWC), **l'évapotranspiration** (ETR.), le **Rayonnement Photosynthéthique** (PPFD) , **la chaleur latente**(Lheat) et la **chaleur sensible**(Heat). Ce sont des variables associées à l'activité biologique ou thermique.
- En haut, il y a les variables atmosphériques : **Wind speed** (WS), **Relative humidity** (RH) et **Wind direction** (WD) . Ces variables sont liées au **vent et à l'humidité de l'air**

L'axe 3 oppose les phénomènes atmosphériques (vent et humidité) aux phénomènes thermo-biologiques(activité des plantes, evapotranspiration).

Axes 2 et 3

```
s.corcircle(acpj$co,xax=2,yax=3,clabel = 0.5, sub ="cercle de
    correlation")
title ( "ACP normee: 2-3")
```

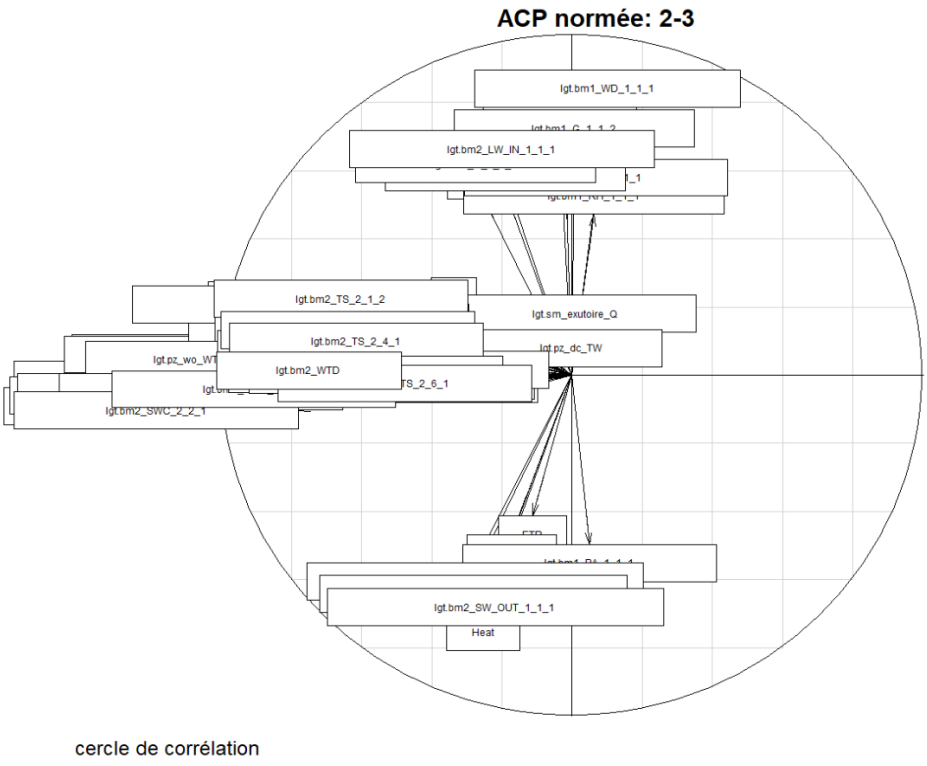


FIGURE 2.6 – Cercle de corrélation avec les axes 2 et 3

Sur ce dernier cercle, on retrouve 3 groupes de variables.

Sur l'axe 2, on observe un groupe de variables dont la majorité n'est pas proche du cercle. Cependant, celles proche du cercle sont liées à la **teneur en eau du sol** (SWC) et à la **profondeur de la nappe phréatique** (WTD).

En ce qui concerne l'axe 3, on peut observer 2 groupes qui s'opposent. En effet, il y a :

— En bas, un premier groupe de variable qui sont : la **teneur en eau du sol** (SWC), **l'évapotranspiration** (ETR.), la **Rayonnement Photosynthéthique** (PPFD) , **la chaleur latente**(Lheat), la **pression de l'air** (PA) et la **chaleur sensible**(Heat). Il s'agit de variables liées à l'énergie solaire et la transpiration des plantes ;

— En haut, il y a le second groupe de variables. Il contient le **flux thermique du sol** (G), le **Rayonnement** (LW_IN) et la **direction du vent** (WD) . Ces variables sont liées au **vent**, à l'atmosphère et au **radiation** et au sol.

Ce plan confirme encore l'opposition entre l'**activité thermique-biologique** et la **dynamique atmosphérique**.

En somme, cette analyse montre que les trois premiers axes résument bien l'essentiel des dynamiques observées dans la tourbière : opposition entre chaleur et humidité, entre activité biologique et conditions atmosphériques. Ces oppositions nous aideront à mieux comprendre l'évolution des gaz à effet de serre, que nous allons maintenant projeter dans ces plans.

2.2.5 Les cercles de corrélation avec les variables supplémentaires

Nous avons dans un premier temps fait une ACP sans inclure les variables que nous cherchons à comprendre : FCO_2 et FCH_4. En effet, nous voulions comprendre la structure du jeu de donnée sans influencer l'analyse avec nos 2 variables principales. Ensuite, nous projetons FCO_2 et FCH_4 en tant que **variables supplémentaires** dans les différents cercles de corrélations. Cela permet d'identifier à quelles variables elles sont liées ou opposées. Dans un premier temps, nous avons centré et réduit FCO_2 et FCH_4. Puis, nous avons calculé leur corrélation avec les différents axes. A partir de là, nous les avons représentés dans les cercles.

```
var_sup <- scale(dataimp[,c(3,4)])
cor_sup <- cor(var_sup,acpj$li )
head(cor_sup)
```

Axes 1 et 2

```
s.corcircle(acpj$co,xax=1,yax=2,clabel=0.6 , sub ="Cercle␣1" )

arrows(0, 0, cor_sup[1,1], cor_sup[1,2], col = "red", length =
   0.1)
text(cor_sup[1,1], cor_sup[1,2], labels = "FCO2", pos = 3, col =
   "red")

```

```
arrows(0, 0, cor_sup[2,1], cor_sup[2,2], col = "blue", length =
    0.1)
text(cor_sup[2,1], cor_sup[2,2], labels = "FCH4", pos = 3, col =
    "blue")
title("␣FCO2␣et␣FCH4␣suivant␣l'axe␣1␣et␣2")
```

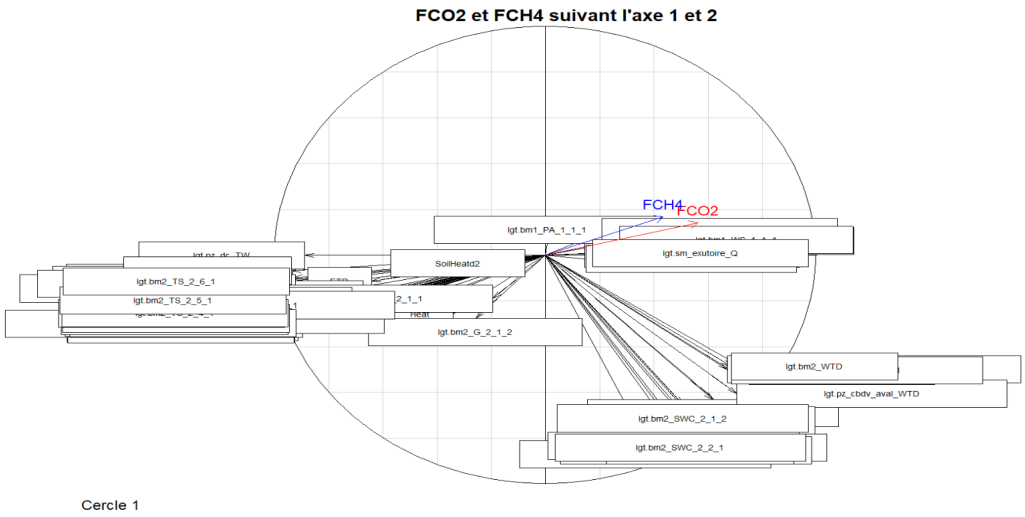


FIGURE 2.7 – Projection de FCO_2 et FCH_4 sur les axes 1 et 2

Sur la figure 2.7, on peut voir que FCO_2 et FCH_4 suivent l'axe 1 vers la droite mais, comme leurs flèches n'est pas proche du cercle, tout interprétation est à prendre avec prudence. En regardant les corrélations, on voit que FCO_2 est mieux représenté. La flèche de FCO_2 à droite fait opposition aux variables thermiques situées à gauche de l'axe 1. Nous pouvons donc dire que FCO_2 est en opposition avec les phénomènes thermiques notamment la **température de l'eau** (TW) et **la température du sol** (TS). Cela suggère que plus les températures sont élevées, plus le flux de CO_2 diminue.

Axes 1 et 3

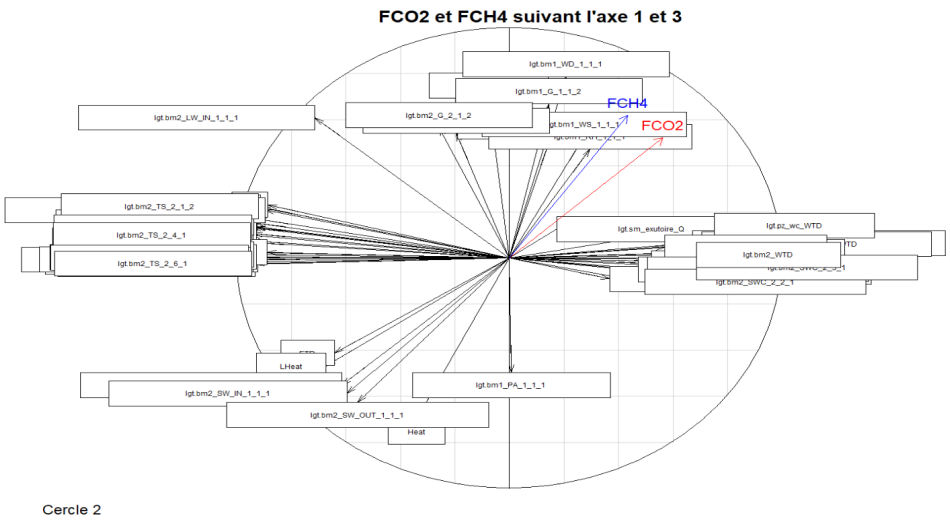


FIGURE 2.8 – Projection de FCO_2 et FCH_4 sur les axes 1 et 3

Dans ce plan, FCO_2 et FCH_4 sont mieux représentés. Ces variables semblent être captées par l'axe 3. Cela suggère que les phénomènes atmosphériques (humidité, vent) sont fortement liées à FCO_2 et FCH_4. Les deux gaz semblent opposés à des variables comme **ETR**, **PPFD**, **Heat** et **Lheat**, c'est-à-dire des indicateurs d'activité thermique et biologique. Mais, ils sont orientés dans la même direction que le **vent** (WS, WD) ou **l'humidité** (RH), ce qui suggère que les conditions atmosphériques (vent et humidité) influencent davantage ces flux que les variables de type chaleur ou rayonnement.

Axes 2 et 3

```
s.corcircle(acpj$co,xax=2,yax=3,clabel=0.6, sub ="Cercle 3")

arrows(0, 0, cor_sup[1,2], cor_sup[1,3], col = "red", length =
   0.1)
text(cor_sup[1,1], cor_sup[1,2], labels = "FCO2", pos = 3, col =
   "red")

arrows(0, 0, cor_sup[2,2], cor_sup[2,3], col = "blue", length =
   0.1)
text(cor_sup[2,2], cor_sup[2,3], labels = "FCH4", pos = 3, col =
   "blue")
title("FCO2 et FCH4 suivant l'axe 2 et 3")
```

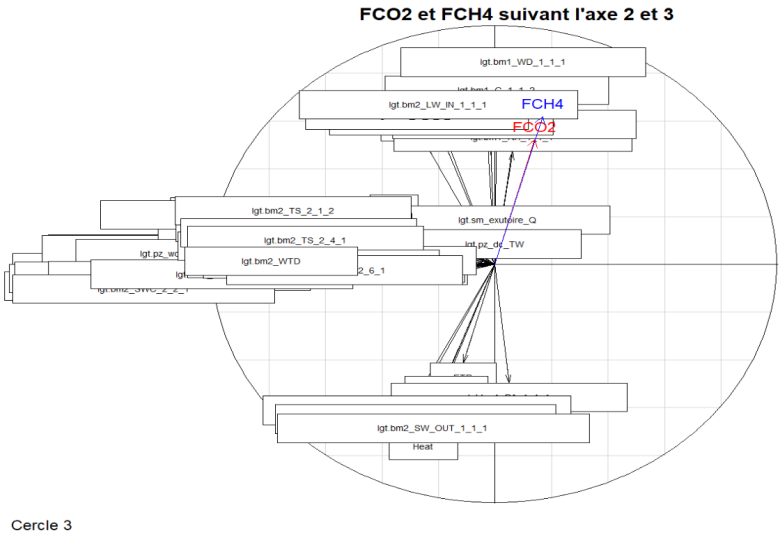


FIGURE 2.9 – Projection de FCO_2 et FCH_4 sur les axes 2 et 3

Dans ce dernier plan, les deux flèches confirment leur bonne représentation sur l'axe 3. FCH_4 y est même mieux aligné que FCO_2. Elles pointent dans une direction opposée à celle des variables énergétiques (PPFD, ETR, Lheat, Heat). Cela renforce l'idée d'une **relation négative entre les flux de GES et les variables thermiques**.

En revanche, elles sont orientées du même côté que les variables liées au vent et à l'humidité, ce qui suggère que les conditions atmosphériques pourraient favoriser l'émission de GES dans la tourbière.

2.2.6 Quelques remarques et commentaires

Le grand nombre de variables rend les cercles de corrélation difficilement lisibles même avec une taille de police réduite. Pour faciliter l'interprétation, nous avons donc étudié les corrélations entre les axes principaux et chaque variable.
Dans un premier temps, nous avons calculé la corrélation entre les axes factorielles et les variables :

```
cc<-cor(dataimp[,-c(1,3,4)],acpj$li)
head(cc)
```

Ensuite, nous avons identifié les variables corrélées (positivement/ négativement) aux différents axes. Enfin, nous avons emis nos hypothèses et nos interprétations en nous basant sur les résultats obtenus. Nous considérons qu'une variable est significativement corrélée à un axe si le coefficient de corrélation est supérieur ou égal à 0.5 en valeur absolue. Pour chaque axe, nous distinguons les corrélations positives et négatives afin d'interpréter le sens des composantes.

Axe 1

Voici la suite de la démarche pour l'axe 1. Il s'agit de la même méthode pour les deux autres.
- D'abord on a regardé les variables dont la valeur absolue de la corréllation avec l'axe 1 est supérieur à une certaine valeur seuil. Nous l'avions d'abord prise assez proche de 1 mais, nous n'avons pas obtenu assez de variables.

```
seuil=0.5
cor1<-cc[abs(cc[,1])>=seuil,,drop=F]
nrow(cor1)
rownames(cor1)
```

Avec cela, on voit qu'il y a 43 variables qui sont corrélées à l'axe 1. Pour la plupart, il s'agit des variables de la température du sol (TS), celles de la température de l'eau (TW), celles de la profondeur de la nappe fréatique (WTD), celle de la teneur du sol en eau (SWC) et l'evapotranspiration (ETR). La liste complète se trouve dans l'Annexe 2.
Ensuite, nous avons regardés quelles variables étaient négativement corrélées.

```
cor1N<-cc[cc[,1]<=(-seuil),,drop=F]
nrow(cor1N)
rownames(cor1N)
```

Elles sont au nombre de 30. Essentiellement, nous avons les variables de la température du sol (TS), celle de la chaleur latente (LHEAT) et celle de l'evapotranspiration (ETR). La liste complète se trouve également dans l'annexe 2.

Enfin, nous avons regardés les variables qui sont positivement corrélées à notre axe.

```
cor1p<-cc[cc[,1]>=(seuil),,drop=F]
nrow(cor1p)
rownames(cor1p)
```

Elles sont au nombre de 13. Il s'agit essentiellement des variables de la teneur du sol en eau (SWC) et des variables liées à la nappe phréatique (WTD).

En somme, l'axe 1 oppose clairement les variables liées à la température/énergie (corrélation négative) aux variables liées à l'humidité/nappe phréatique (corrélation positive).

Axe 2

Les variables ayant une corrélation négative sont au nombre de 14. Ce sont les variables qui mesurent la teneur en eau (SWC) et celles liées à la nappe phréatique (WTD).
Il n' y a aucune variable corrélées positivement à l'axe 2.
En somme, l'axe 2 apparait comme celle qui capte le mieux et uniquement les phénomènes liés à l'hydrologie.

Axe 3

Les variables qui ont une corrélation négative avec cet axe sont au nombre de 4. Elles sont liées à la chaleur (HEAT) et aux rayonnements à ondes courtes (SW). Ces variables captent l'énergie solaire et la chaleur sensible.

```
[1] "Heat"
[2] "lgt.bm1_PPFD_IN_1_1_1"
[3] "lgt.bm2_SW_IN_1_1_1"
[4] "lgt.bm2_SW_OUT_1_1_1"
```

Les variables qui ont une corrélation positive avec cet axe sont au nombre de 8. Il s'agit du rayonnement à ondes longues (LW), de la direction et la vitesse du vent (WD, WS) et du flux de chaleur au sol (G).

```
[1] "SoilHeatd2"
[2] "lgt.bm1_G_1_1_2"
[3] "lgt.bm1_P_1_1_1"
[4] "lgt.bm1_WD_1_1_1"
[5] "lgt.bm1_WS_1_1_1"
[6] "lgt.bm2_G_2_1_1"
[7] "lgt.bm2_G_2_1_2"
[8] "lgt.bm2_LW_IN_1_1_1"
```

Les variables négativement corrélées à l'axe 3 (HEAT, SW) décrivent l'énergie solaire et la chaleur sensible. Les positives (LW, WD, WS, G) décrivent le vent, la direction, le rayonnement à ondes longues et le flux au sol. L'axe 3 oppose donc les phénomènes atmosphériques (vent, radiation longue ondes) aux phénomènes thermiques (chaleur sensible, rayonnement court).

Corrélation de nos variables d'intérêt avec les axes

Pour être plus précis, nous avons regardé la corrélation entre nos GES et les composantes principales.

```
var_sup <- scale(dataimp[,c(3,4)])
cor_sup <- cor(var_sup,acpj$li )
cor_sup[,1:3]
```

```
          Axis1      Axis2     Axis3
FCO2  0.5620687  0.1400541 0.5213142
FCH4  0.4325035  0.1676419 0.6179814
```

Commentaires

En résumé, nous observons que FCO_2 présente une corrélation de 0.56 avec l'axe 1 et de 0.52 avec l'axe 3. Pour FCH_4, la corrélation est plus marquée avec l'axe 3 (0.62) qu'avec l'axe 1 (0.43). Les deux variables sont très peu présent en ce qui concerne l'axe 2. L'axe 1, que nous avons interprété comme opposant les variables thermiques (température du sol, évapotranspiration) aux variables hydriques (teneur en eau du sol, profondeur de la nappe), semble fortement associé au flux de CO_2. Cette corrélation positive suggère que les variations thermiques de la tourbière ont un impact sur le flux de CO_2. Le flux est surement réduit lorsque la température augmente.
L'axe 3, représentant l'opposition entre phénomènes atmosphériques (vent, rayonnement à ondes longues) et chaleur sensible ou rayonnement solaire, est corrélé à la fois à FCO_2 et FCH_4. Cette association, plus marquée pour FCH_4, indique que les conditions atmosphériques, telles que la circulation du vent et l'humidité de l'air, pourraient influencer la dynamique d'émission de ces gaz à effet de serre.
Ces résultats confirment l'importance de considérer à la fois les phénomènes thermiques et les conditions atmosphériques pour expliquer les variations des flux de CO_2 et CH_4 dans la tourbière.

2.2.7 Représentation du plan factoriel

Analysons à présent la répartition des mois sur les plans factoriels :

Représentation du plan factoriel barycentré sur les mois Axe 1-3

```
mois <-format(date, format = "%m")
mois1 <- factor(mois,
                levels = sprintf("%02d", 1:12),
                labels = c("Janvier", "Fevrier", "Mars", "Avril",
                   "Mai", "Juin",
                           "Juillet", "Aout", "Septembre", "
                              Octobre", "Novembre", "Decembre"),
                ordered = TRUE)

s.class(acpj$li[,c(1,3)], fac = mois1, col = rainbow(length(
   unique(mois))),
        sub = "Plan factoriel - Barycentres mensuels",
        csub = 0.3)
```

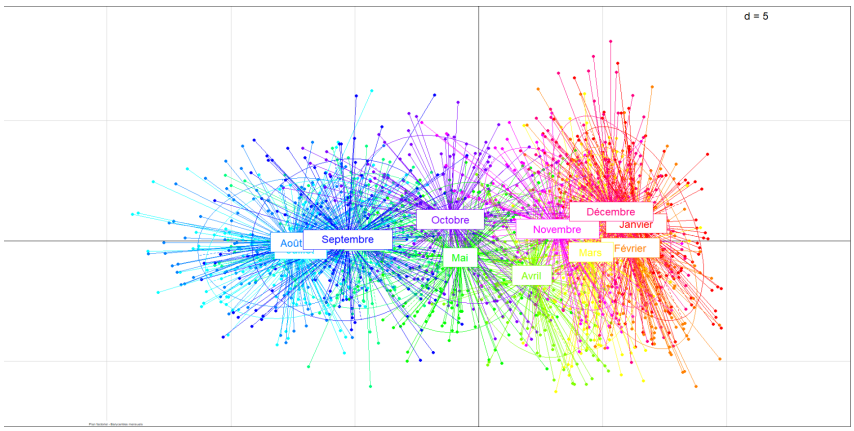


FIGURE 2.10 – Plan factoriel sur les axes 1 et 3 avec les mois

Sur ce plan, on voit une séparation entre les mois d'hiver et les mois d'été. Les mois d'hiver (Décembre, Janvier et Février) sont à droite le long de l'axe 1 tandis que les mois d'été sont à gauche. Ce qui confirme ce que nous avons dit plus haut. En effet, l'axe 1 capte principalement les changements de température.
On remarque également que certains mois sont superposés avec d'autres. Par exemple Juillet qui est masqué par Août ; cela traduit peut-être des conditions thermiques similaires. De même pour Juin qui n'est pas du tout visible ; il semble être englouti par Septembre.

De plus, nous remarquons les mois comme Octobre et Mai qui se situent au centre. Ceci est surement dû au fait que ces mois ont des conditions qui sont à cheval entre le froid de l'hiver et le chaud de l'été. Nous pouvons les qualifier de mois de "transition".

En ce qui concerne l'axe vertical (l'axe 3), qui reflète les dynamiques atmosphériques comme le vent et l'humidité, on remarque qu'il ne sépare pas clairement les mois. On voit que les mois tels que Décembre, Janvier et même Février ont leurs ellipses plus allongées suivant la vertical. Cela suggère que les conditions atmosphériques sont plus marqué pendant ces périodes. Peut-être des vents assez fort ou une humidité marquée. Il en va de même pour les mois tels que Octobre et Novembre.

Représentation du plan factoriel barycentré sur les mois Axe 1-2

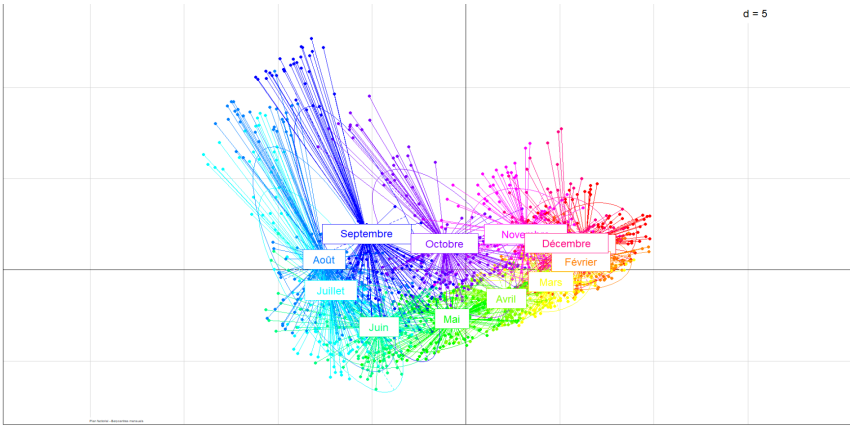


FIGURE 2.11 – Plan factoriel sur les axes 1 et 2 avec les mois

La figure 2.11 montre une meilleure répartition des mois. Comme à la section précédente, nous voyons du coté droit les mois d'hiver et les mois d'été du coté gauche. De plus, on distingue mieux les mois qu'on peut qualifier de globalement froid (Novembre, Décembre,Janvier,Février,Mars) des mois globalement chauds (Juin,Juillet,Août, Septembre). On observe aussi les mois tels que Avril, Octobre et Mai qui sont beaucoup plus au centre ce qui suggère des conditions modérées. Cela confirme que l'axe 1 capte les dynamiques thermiques.

D'un autre coté, on remarque que les ellipses autour de septembre, Août et Juillet sont étirées verticalement. Cette orientation pourrait refléter les facteurs captés par l'axe 2. Il s'agit de conditions liées à l'hydrologie ou à des caractéristiques de la nappe phréatique pendant ces périodes.

Représentation du plan factoriel barycentré sur les mois Axe 2-3

```
s.class(acpj$li[,c(2,3)], fac = mois1, col = rainbow(length(
   unique(mois))),
        sub = "Plan␣factoriel␣-␣Barycentres␣mensuels",
        csub = 0.5)
```

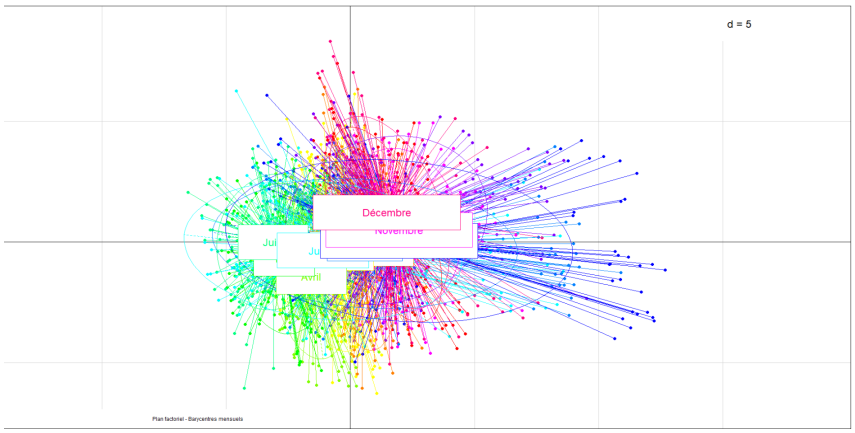


FIGURE 2.12 – Plan factoriel sur les axes 2 et 3 avec les mois

Ce plan factoriel est défini par les axes 2 et 3. Ces axes, qui reflètent notamment des phénomènes hydrologiques et atmosphériques, ne permettent pas ici de distinguer clairement les saisons ou les périodes de l'année. En effet, on remarque que la majorité des mois sont superposés au centre du plan. Les mois de Décembre et de Novembre sont les plus visibles et ils recouvrent plusieurs labels. On note aussi que plusieurs ellipses sont étirées dans la direction de l'axe 2, ce qui suggère une influence des variables corrélées à l'axe 2. En somme, la figure 2.12 n'offre pas de séparation nette des saisons comme observée sur les autres plans et elle ne permet pas d'avoir une interprétation claire.

Représentation du plan factoriel barycentré sur les années Axe 1-3

Analysons à présent la répartition des années sur les plans factoriels :

```
annee <-format(date, format = "%Y")
annee1 <- factor(annee,
                 levels = c("2017", "2018", "2019", "2020", "2021")
                    ,
                 ordered = TRUE)

s.class(acpj$li[,c(1,3)], fac = annee1, col = rainbow(length(
   unique(annee1))),
        sub = "Plan␣factoriel␣-␣Barycentres␣annuels",
        csub = 0.3)
```

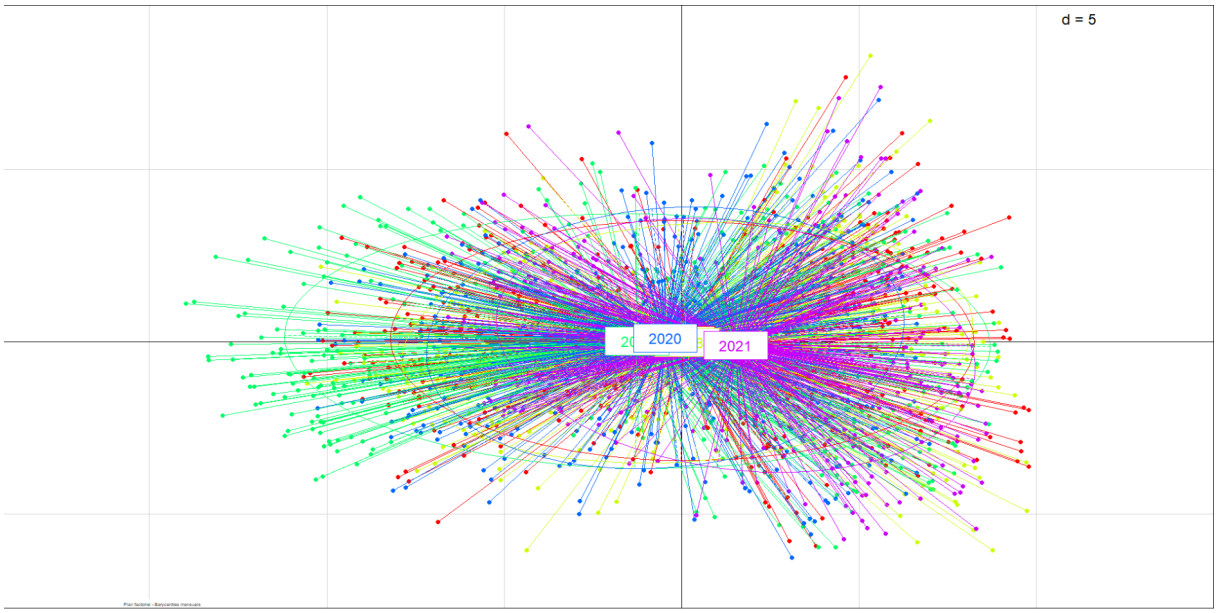


FIGURE 2.13 – Plan factoriel sur les axes 1 et 3 avec les années

Représentation du plan factoriel barycentré sur les années Axe 1-2

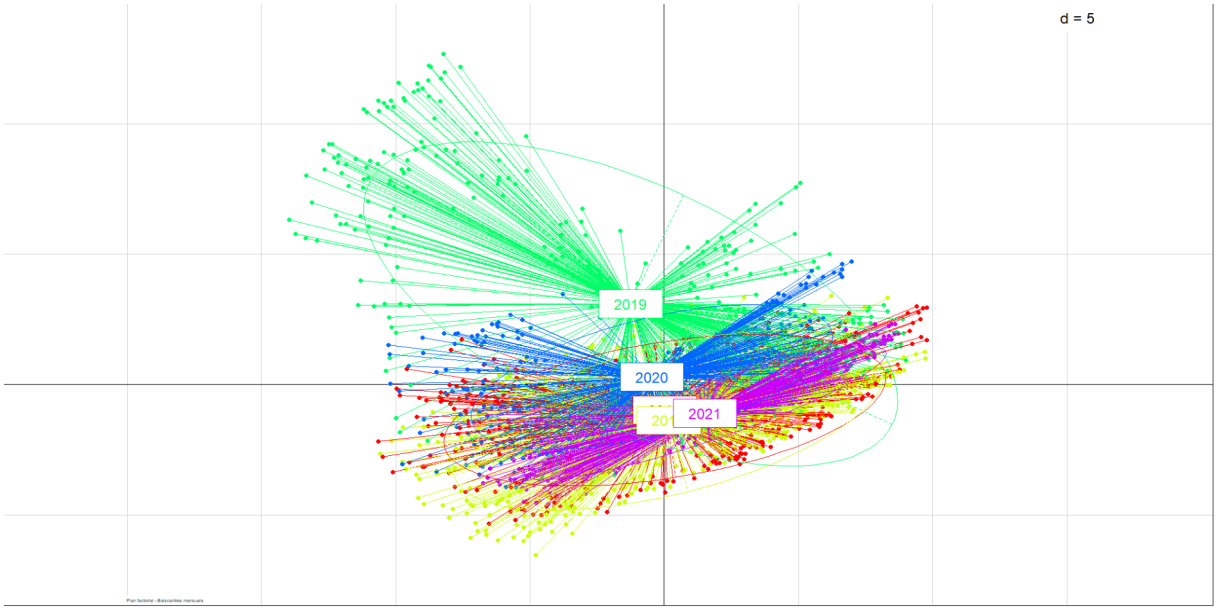


FIGURE 2.14 – Plan factoriel sur les axes 1 et 2 avec les années

Représentation du plan factoriel barycentré sur les années Axe 2-3

```
s.class(acpj$li[,c(2,3)], fac = annee1, col = rainbow(length(
    unique(annee1))),
         sub = "Plan factoriel - Barycentres annuels",
         csub = 0.3)
```

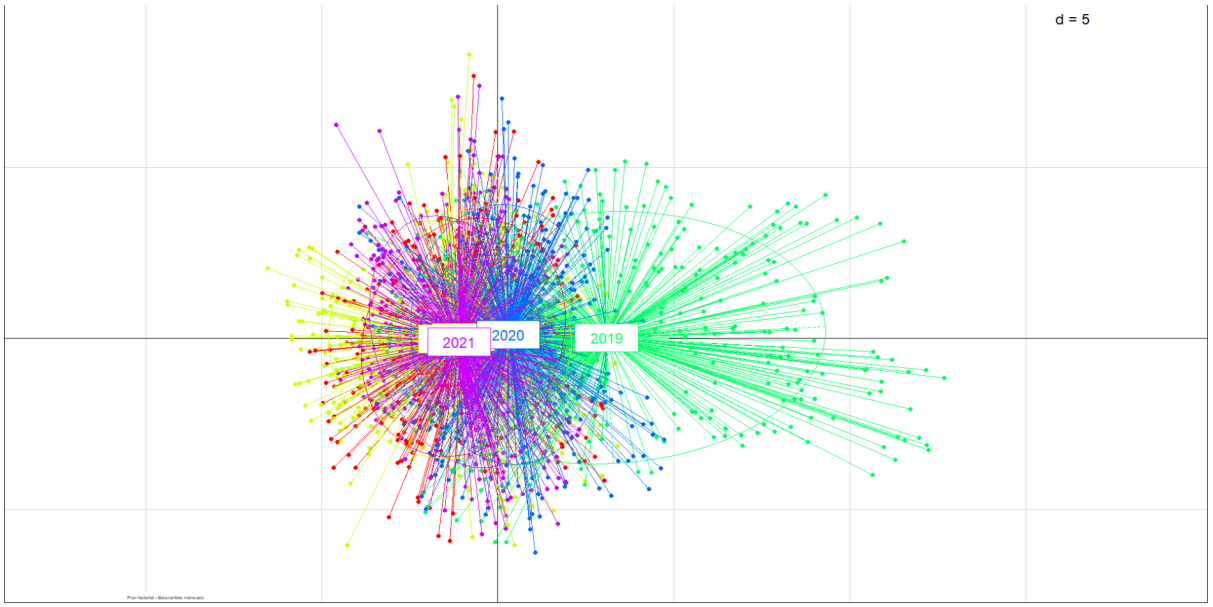


FIGURE 2.15 – Plan factoriel sur les axes 2 et 3 avec les années

Commentaire

Ici, nous représentons les résultats de notre ACP regroupés par année. La figure 2.15 et 2.14 montre que l'année 2019 se distingue des autres. En effet, sur 2.14, 2019 est beaucoup plus détaché de l'ensemble formé par les autres années. Et, son ellipse s'étire beaucoup plus sur l'axe 2, vers le haut. Cela suggère que les facteurs que captent l'axe 2 sont très marquées dans cette année. Comme cet axe a trait à l'hydrologie, la particularité de l'année 2019 pourrait traduire des conditions hydrologiques anormales ou extrêmes. Après vérification des archives, il apparait qu'une importante sécheresse a effectivement marquée cette année-là, ce qui confirme notre hypothèse. D'un autre côté, sur la figure 2.13 contrairement aux 2 autres, on remarque que toutes les années se superposent. Elles se regroupent au centre et les plus visibles sont 2020 et 2021. Néanmoins, nous remarquons que les ellipses de chaque année s'étirent sur l'axe 1 (l'horizontal). Cela suggère que les dynamiques thermiques influencent ces périodes. Mais, comme il n'y a pas de démarquation claire, il est difficile de conclure. Ces résultats soulignent ainsi l'intérêt de l'axe 2 pour détecter des variations hydrologiques annuelles marquées (comme en 2019), mais montrent aussi les limites d'une interprétation thermique concernant les années sur l'axe 1-3, où il n'y a pas de séparation claire.

2.2.8 Regard sous un autre angle

Nous avons inclus la composante 4 dans nos analyses pour voir si elle nous apporte des informations supplémentaires. Cet ajout est justifié car avec les 4 axes, nous arrivons à capter plus de 80% de l'inertie totale ce qui est énorme. De plus, la règle du coude sur l'éboulis de valeurs propres suggère, un coude autour de l'axe 4.

Les Cercles de corrélation

Regardons les différents cercles de corrélation impliquant l'axe 4 :

```
s.corcircle(acpj$co,xax=1,yax=4,clabel = 0.5)
title ( "ACP normEe: 1-4")
```

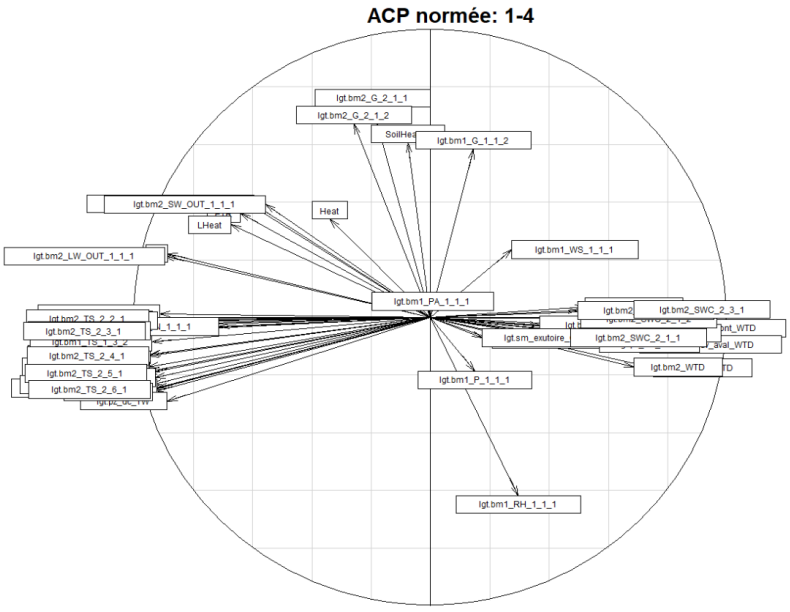


FIGURE 2.16 – Cercle de corrélation avec les axes 1-4

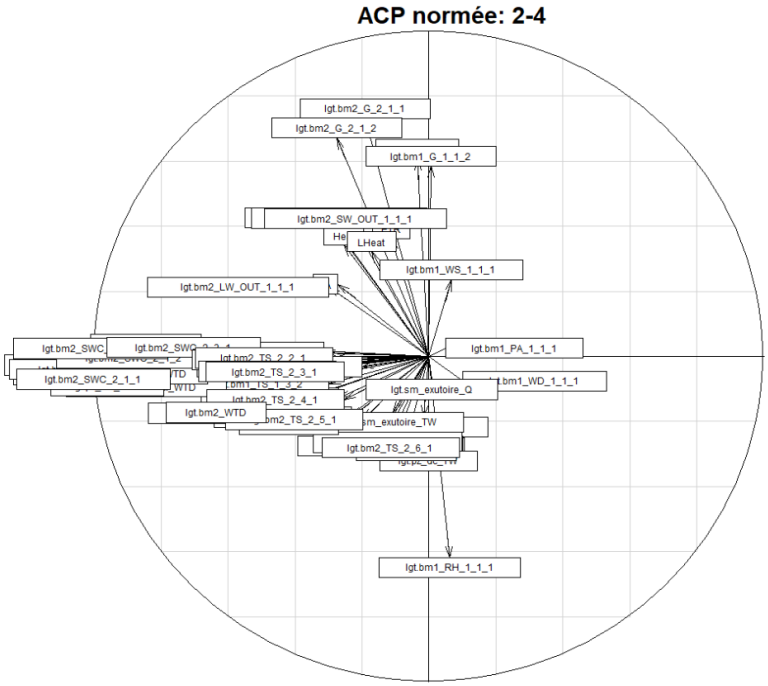


FIGURE 2.17 – Cercle de corrélation avec les axes 2-4

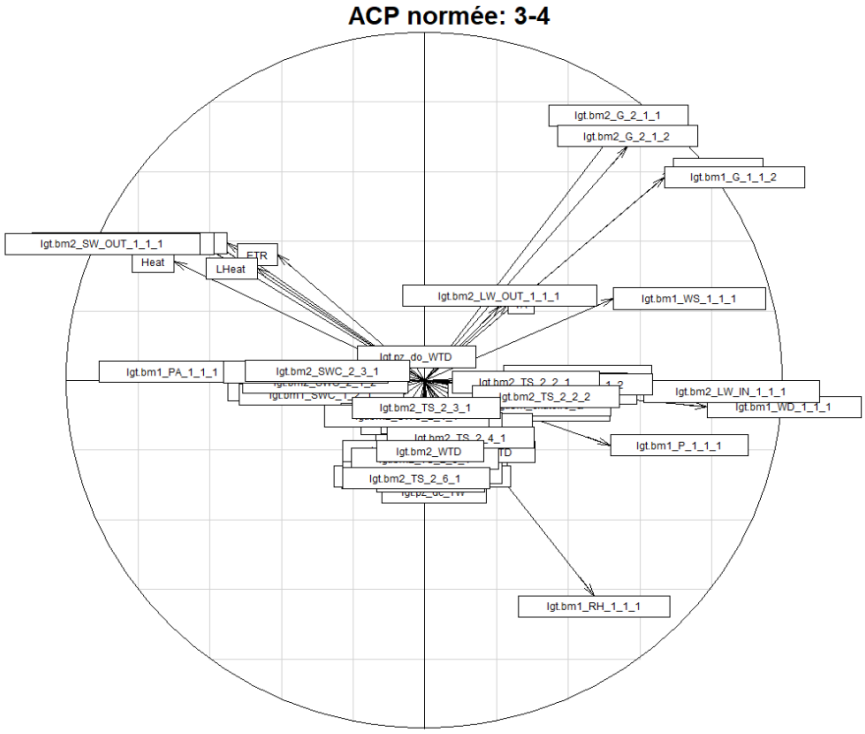


FIGURE 2.18 – Cercle de corrélation avec les axes 3-4

Commentaire

Sur chacun des ces 3 cercles, nous distinguons peu de variables fortement corrélées à l'axe 4 et bien représentées. En regardant les corrélations, on se rend compte que seules 5 variables présentent une corrélation en valeur absolue supérieure à 0.5.

— **Relative humidity** (RH), corrélée négativement à l'axe,

— et des variables de **Soil heat flux** (G), corrélées positivement.

Il apparait que cet axe oppose donc la chaleur du sol à l'humidité de l'air. Cela pourrait refléter des phénomènes plus subtils liés aux échanges de chaleur dans la tourbière. Cependant, le faible nombre de variables bien représentées indique que l'axe 4 apporte moins de structure interprétable que les axes précédents. Son ajout reste utile pour compléter l'inertie expliquée, mais son intérêt est limité et doit être interprété avec prudence.

Les Cercles de corrélation avec variables supplémentaires

```
s.corcircle(acpj$co,xax=1,yax=2,clabel=0.6 , sub ="Cercle 1-4" )

arrows(0, 0, cor_sup[1,1], cor_sup[1,4], col = "red", length =
   0.1)
text(cor_sup[1,1], cor_sup[1,4], labels = "FCO2", pos = 3, col =
   "red")

arrows(0, 0, cor_sup[2,1], cor_sup[2,4], col = "blue", length =
   0.1)
```

```
text(cor_sup[2,1], cor_sup[2,4], labels = "FCH4", pos = 3, col =
   "blue")
title("␣FCO2␣et␣FCH4␣suivant␣l'axe␣1␣et␣4")
```

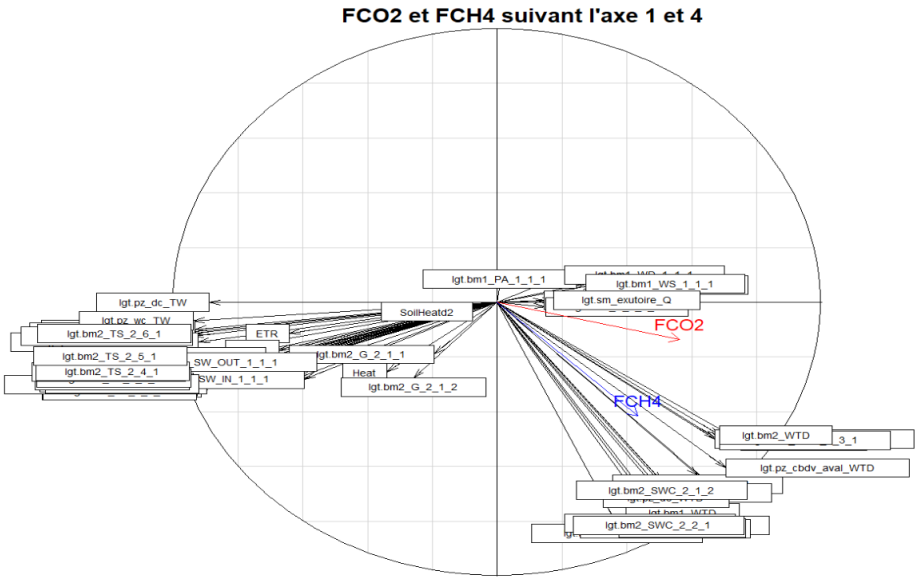


FIGURE 2.19 – Projection de FCO_2 et FCH_4 sur les axes 1 et 4

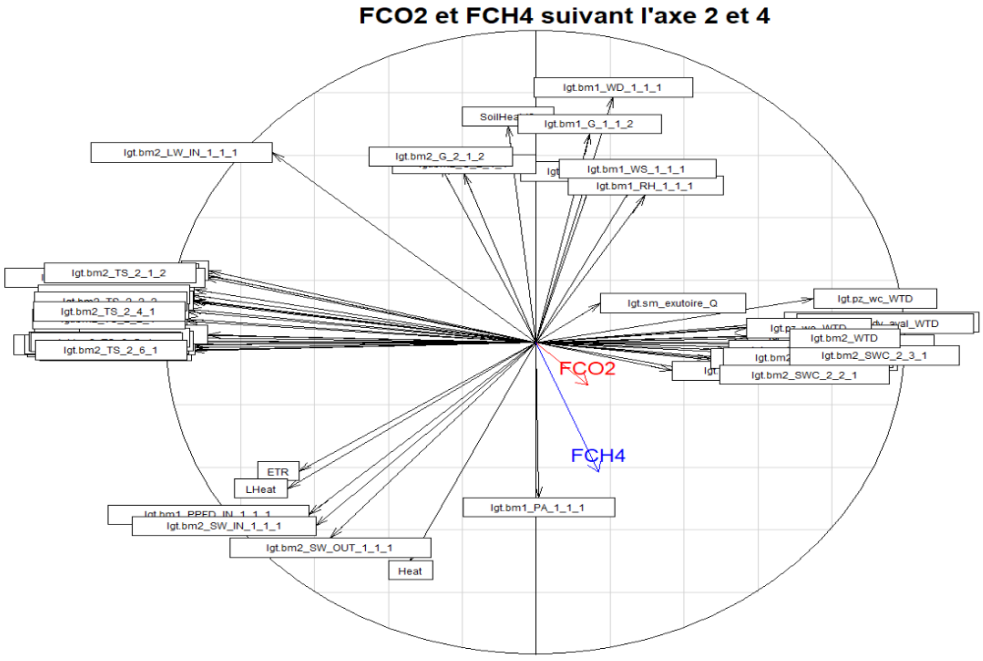


FIGURE 2.20 – Projection de FCO_2 et FCH_4 sur les axes 2 et 4

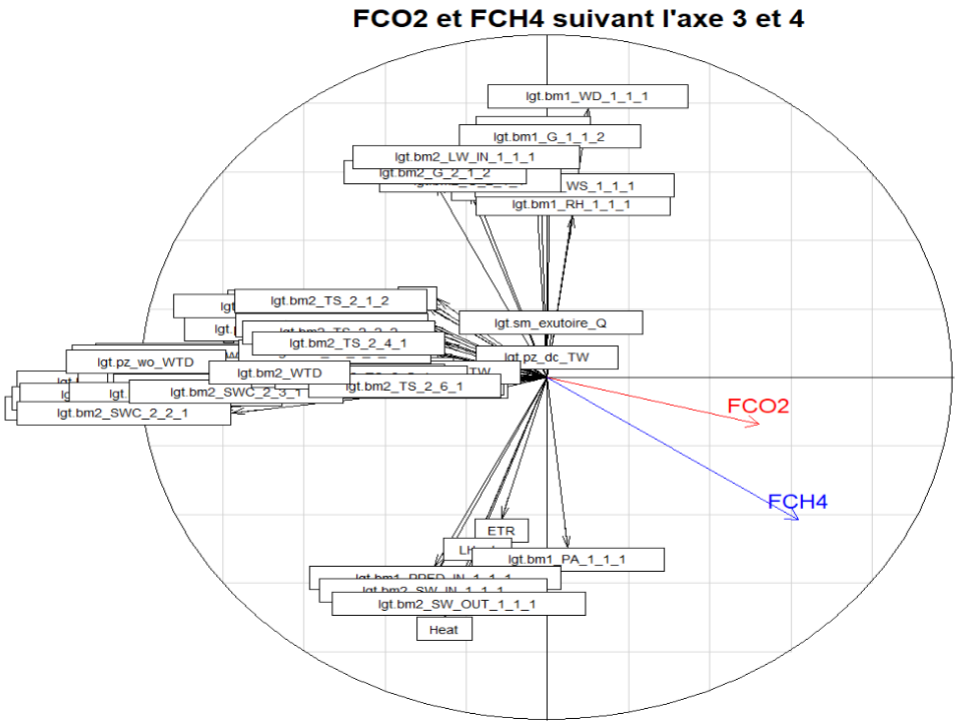


FIGURE 2.21 – Projection de FCO_2 et FCH_4 sur les axes 3 et 4

Commentaire

Sur l'ensemble des cercles, les flèches de FCO_2 et FCH_4 apparaissent courtes et centrées (notamment sur le cercle 2.20). Cela suggère que ces variables sont peu corrélées à cet axe et donc difficile à interpréter. Sur la figure 2.19, la flèche de FCO_2 se projette plus sur l'axe 1. Cette proximité avec l'axe 1 renforce nos analyses plus haut disant que FCO2 est en opposition avec les phénomènes thermiques (notamment TW et TS). En revanche, la projection sur l'axe 4 reste faible. De plus, nous avons calculé la corrélation entre les flux de GES et la composante 4. Nous avons obtenu :

— FCO_2 et FCH_4 sont corrélées négativement à l'axe,

— la corrélation de FCH_4 est -0.41 tandis que celle de FCO_2 est -0.13

Ces faibles valeurs confirment que l'axe 4 n'apporte pas d'information supplémentaire majeure sur la répartition de nos variables supplémentaires. En particulier, il n'aide pas à distinguer clairement les flux de CO_2 et CH_4.

Représentation sur l'axe factoriel groupé par mois

```
s.class(acpj$li[,c(1,4)], fac = mois1, col = rainbow(length(
    unique(mois))),
         sub = "Plan factoriel - Barycentres mensuels",
         csub = 0.3)
```

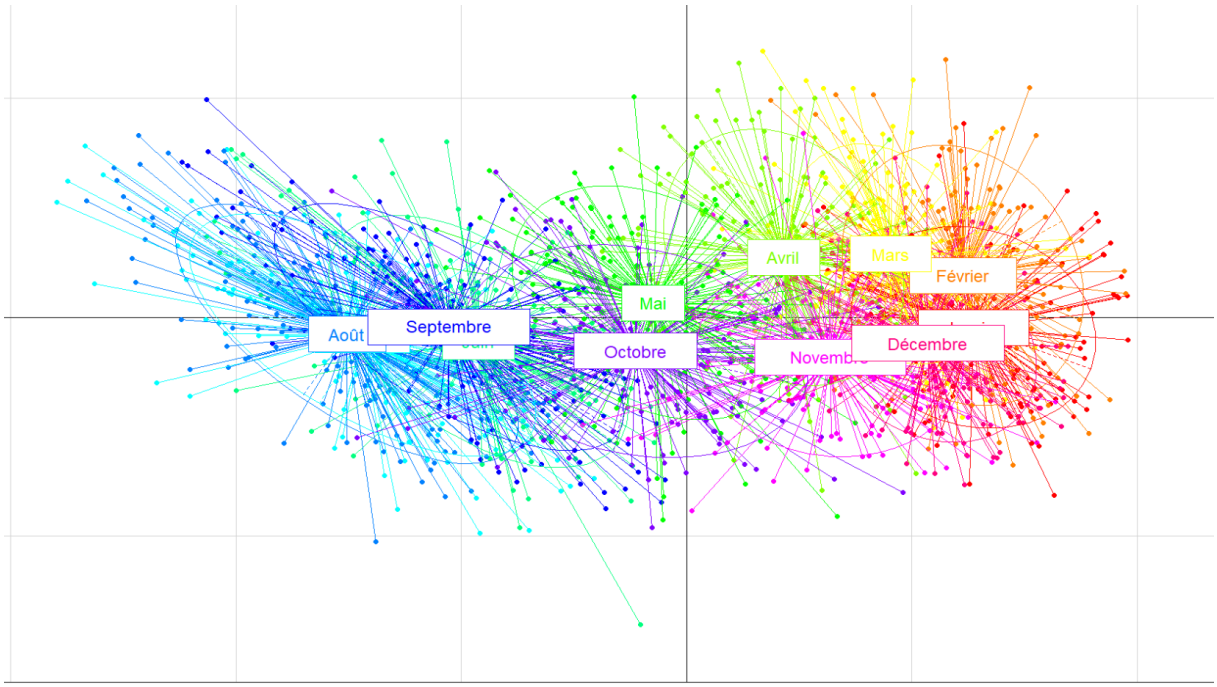


FIGURE 2.22 – Plan factoriel sur les axes 1 et 4 avec les mois

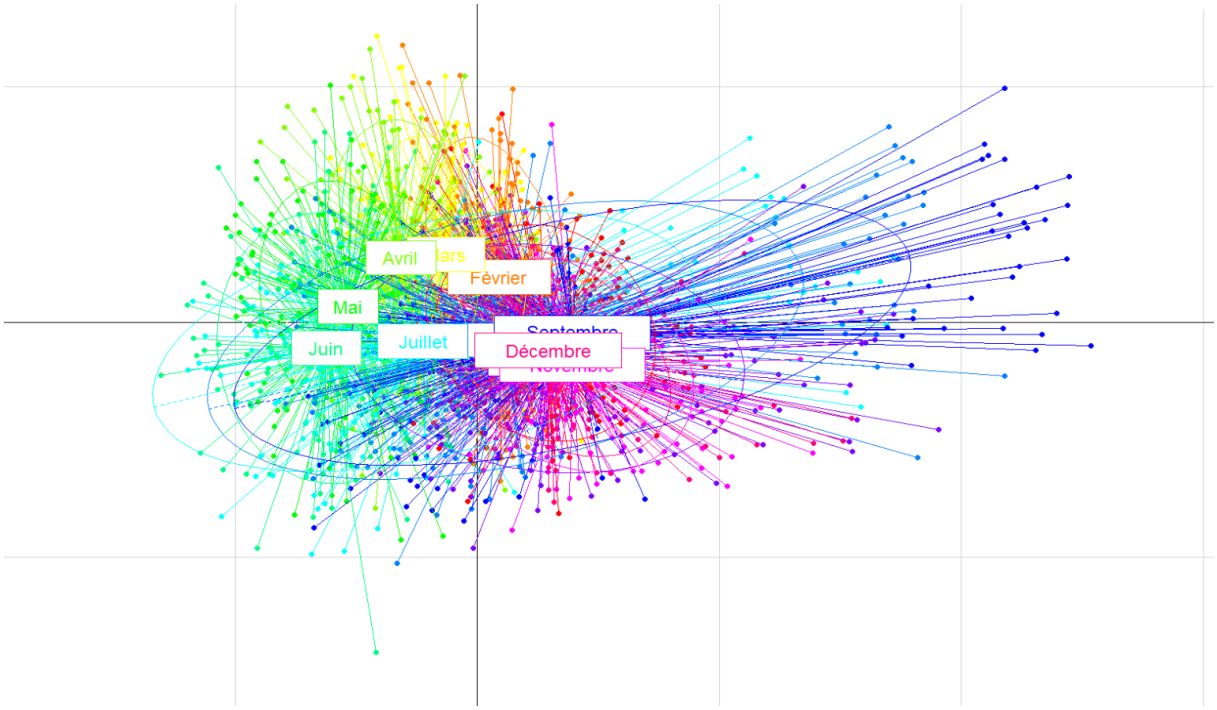


FIGURE 2.23 – Plan factoriel sur les axes 2 et 4 avec les mois

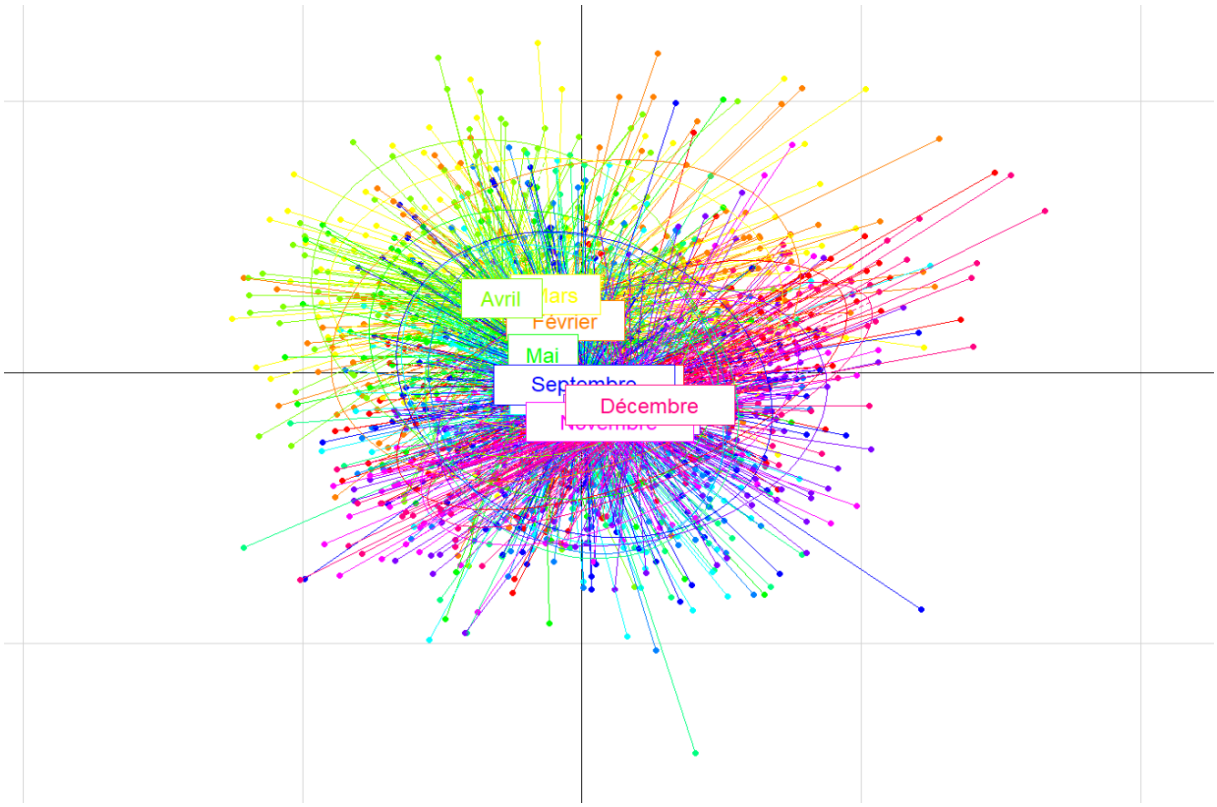


FIGURE 2.24 – Plan factoriel sur les axes 3 et 4 avec les mois

Commentaire

Ces graphiques représentent les barycentres mensuels selon les axes (1 à 4). Sur la figure 2.22 définie par les axes 1 et 4, nous distinguons une séparation claire suivant l'axe 1 entre les mois chauds à gauche et les mois froids à droite. Cela confirme que l'axe 1 capte fortement les dynamiques thermiques. Les mois de transition comme Mai et Octobre se trouvent beaucoup plus au centre, ce qui est cohérent. En revanche, l'axe 4 ne semble pas apporter d'informations sur les mois. En effet, nous avons quelques ellipses qui s'étirent légèrement vers la vertical comme celui de Avril mais, pas de séparation claire. Cette orientation vers la verticale pourrait suggérer des conditions spécifiques opposant le flux de chaleur du sol et d'humidité.

La figure 2.23, définie par les axes 1 et 4, montre quant à elle une configuration différente. Les mois chauds (Juillet, Juin) sont regroupés vers le centre gauche, tandis que Septembre, Novembre et Décembre sont sur la droite du plan. Cependant, ce plan n'offre pas une séparation nette des mois. On note aussi que les mois comme septembre, Decembre, Novembre se superposent et cachent totalement d'autre comme Octoble,Janvier, ce qui complique l'interprétation.

Le plan 3-4 égalament ne présente aucune séparation claire et les mois se superposent. La majorité des mois se regroupent au centre et il n'y a aucune structure interessante. En résumé, l'ajout de la composante 4 permet de raffiner le pourcentage d'inertie mais, sa contribution aux interprétations n'est pas aussi claire que celle des premier axes.

Représentation sur l'axe factoriel groupé par années

```
s.class(acpj$li[,c(3,4)], fac = annee1, col = rainbow(length(
   unique(annee1))),
        sub = "Plan factoriel - Barycentres annuels",
        csub = 0.3)
```

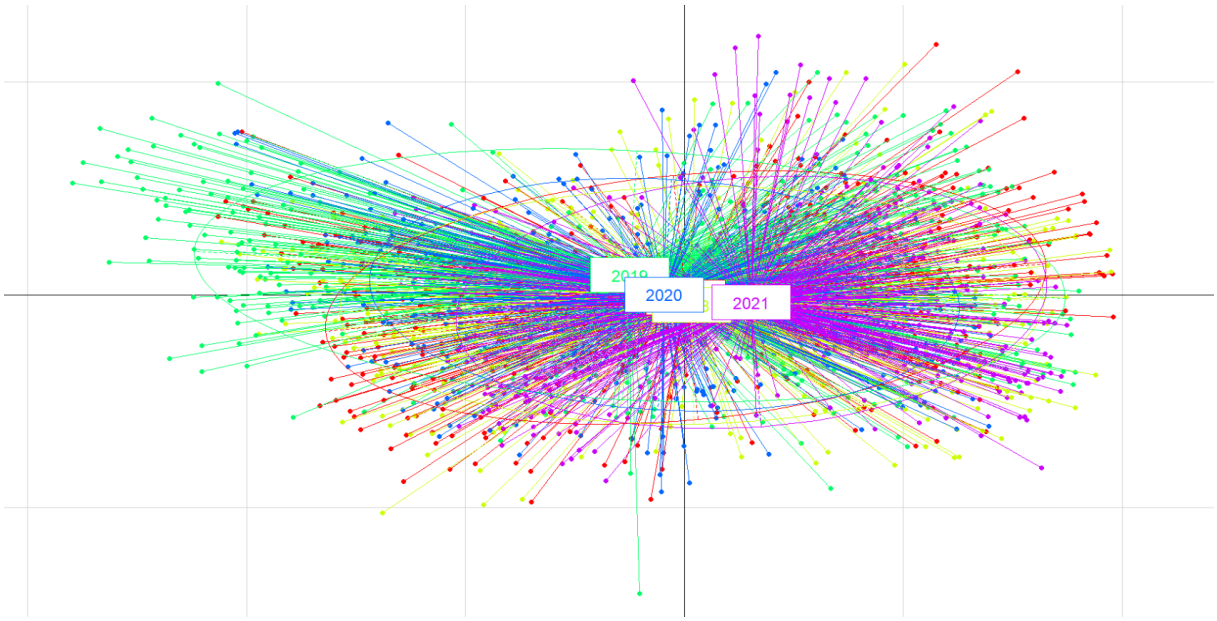


FIGURE 2.25 – Plan factoriel sur les axes 1 et 4 avec les années

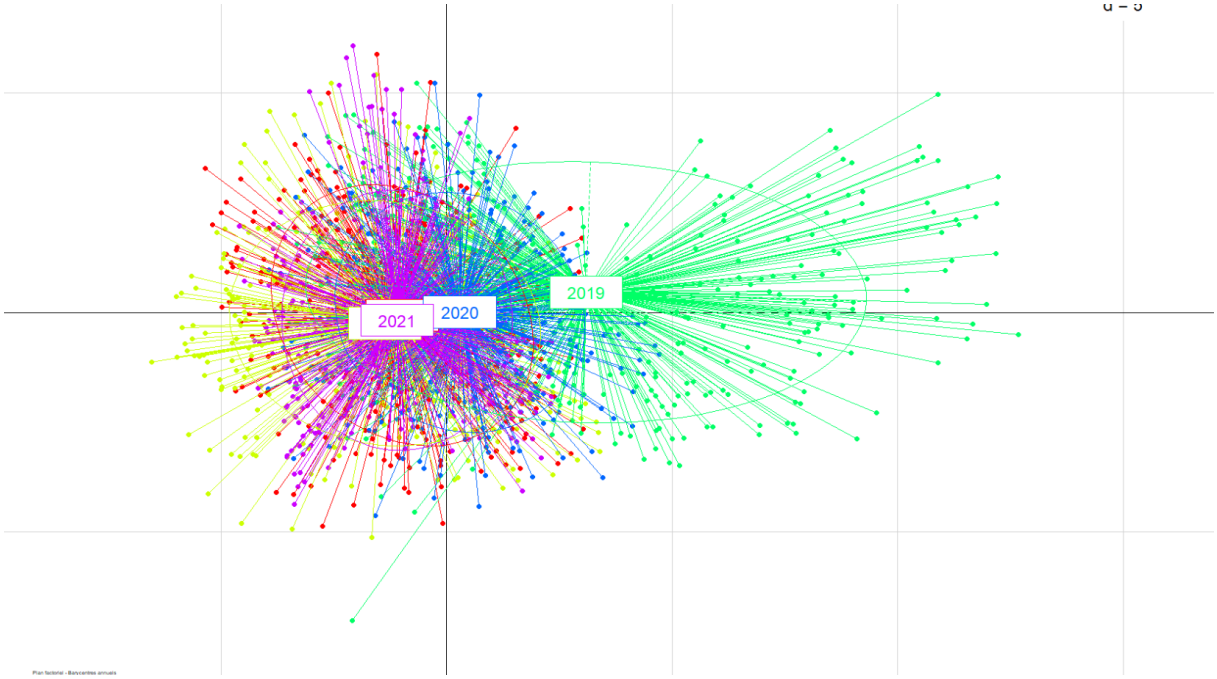


FIGURE 2.26 – Plan factoriel sur les axes 2 et 4 avec les années

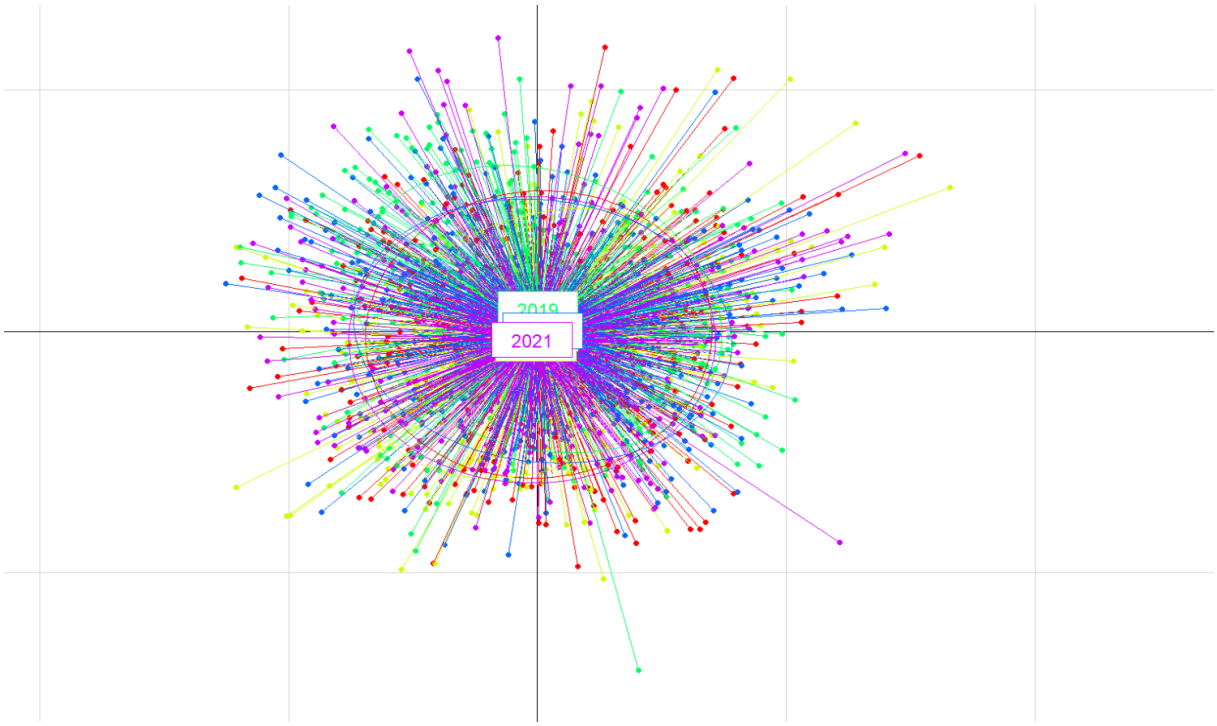


FIGURE 2.27 – Plan factoriel sur les axes 3 et 4 avec les années

Commentaire

Ici, nous représentons les résultats de nos ACP regroupés par année. Sur les figures 2.25 et 2.27, on remarque que toutes les années se superposent. Sur la 2.27, les années se regroupent au centre et la plus visible est 2021. On remarque aussi que sur cette figure, les ellipses ont l'air d'être des cercles et il y a beaucoup de dispersion des points dans tous les sens. Cela suggère qu'il n' y a pas de différenciation notable entre ces années sur ce plan. Aussi, cela limite fortement l'interprétation et souligne que l'axe 4 n'apporte pas d'information pertinente ici. Contrairement aux 2 autres figures, le plan sur la 2.26 montre une distinction claire de l'année 2019. Cette dernière a son éllipse qui s'étire beaucoup plus sur l'horizontal (l'axe 2), cela suggère que l'année 2019 traduit des conditions hydrologiques très différentes des autres. Ce résultat est cohérent avec nos analyses précédentes. En somme, si l'ajout de l'axe 4 augmente l'inertie expliquée, il n'apporte qu'une contribution limitée à la différenciation des années. Seul le plan 2-4 permet de révéler une information intéressante, en isolant l'anomalie hydrologique de 2019.

Troisième partie

Modélisation des séries temporelles et prévisions

Chapitre 1

1.1 Introduction

La modélisation des séries temporelles constitue une étape essentielle pour analyser l'évolution des gaz à effet de serre tels que le dioxyde de carbone (CO_2) et le méthane (CH_4). Elle repose sur un cadre méthodologique visant à identifier les caractéristiques dynamiques de la série (tendance, saisonnalité, bruit), à garantir la stationnarité, puis à estimer un modèle adapté (ARIMA, avec ou sans régressseurs).
Dans cette partie, nous décrivons les principales étapes de modélisation : transformation de la série, sélection des paramètres, validation via l'analyse des résidus et enfin, prévision. Une attention particulière est portée à l'impact des composantes principales comme variables explicatives. L'objectif est d'obtenir des modèles robustes et interprétables, capables de prédire de façon fiable l'évolution future des concentrations en gaz à effet de serre.

1.2 Les différentes étapes de la modélisation de série temporelles

1.2.1 Méthodologie ARIMA

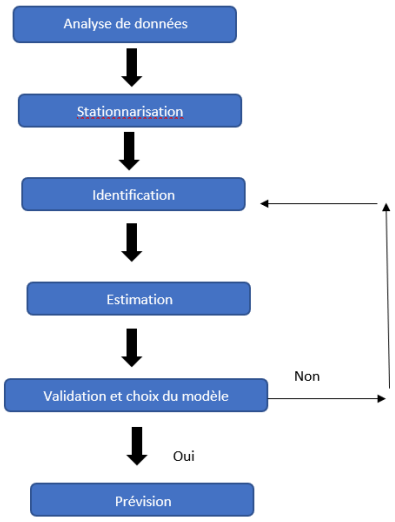


FIGURE 1.1 – Méthodologie ARIMA

1.2.2 Quelques détails sur les différentes parties théoriques

a- Analyse de données

Pour étudier une série temporelle, on doit s'intéresser généralement à plusieurs aspects. On examine d'abord son comportement global : est-elle d'un point de vue macroscopique, croissante, décroissante... ? Ce qui donne la tendance de la série . Ensuite, on peut être amené à repérer un éventuel comportement saisonnier : y a-t-il dans cette série un élément qui revient plus ou moins régulièrement dans toutes les observations ?

b- Stationnarisation

Définition : Une série y_t est dite stationnaire si :
- $E(y_t) = u$, constante indépendante de t (le temps)
- $cov(y_t, y_{t-l})$ ne dépend que de l (un entier)

Après avoir analysé le comportement de la série, on peut être en mesure d'affirmer son état stationnaire . Il est nécessaire de vérifier si la série est stationnaire ou pas avant de poursuivre la modélisation. Et cela se fait aussi par la lecture des chronogrammes (ACF, PACF), lagplot, aussi par des test de Dickey Fuller (absence de racine unité dans la partie autorégressive, KPSS ...

c- Identification

Comment identifier les ordres p et q du modèle ARMA(p,q) ?

Principe : - Comparer les fonctions d'autocorrélation (ACF) et d'autocorrélation partielle (PACF) théoriques (donc connues) à fonctions estimées à partir de la série temporelle ou échantillons (donc empirique)
- Rechercher une correspondance entre un modèle ARMA(p,q) théorique et le processus générateur de la série temporelle

d- Estimation

Après avoir déterminé p et q, on estime les polynômes P et Q qui sont les polynômes caractéristiques de la partie autorégressive et la partie moyenne mobile .

e- Validation et choix du modèle

Suite à l'identification de p et q et à l'estimation des polynômes P et Q , On valide le modèle par un test de blancheur ou la visualisation des autocorrélations de ses résidus . Si le modèle est validé, on passe à la prévision, dans le cas contraire , on retourne à l'étape de l'identification des paramètres .
NB : La partie modélisation se fait sur environ 90 % des données brutes

f- Prévision

On fait une prévision sur les périodes dont les données sont déjà connues, avec le modèle validé. On fait ensuite la comparaison des données prédites avec celles déjà connues pour voir la qualité de la prévision.

1.3 Application sur nos données

1.3.1 Les composantes principales

Pour décomposer les composantes principales ainsi que les séries des gaz à effet de serre en leurs différentes composantes (tendance, saisonnalité et bruit), nous utiliserons la fonction **decompose()** . Cette fonction calcule notamment la tendance par la méthode des **moyennes mobiles**, ce qui est particulièrement adapté lorsque les séries sont additives.

a- Composante 1

— Tendance et saisonnalité

```
af_1<-ts(acp$li[,1], start =c(2017,19),frequency = 365 )
af_11 <- decompose(af_1)
plot(af_1)
plot(af_11)
```

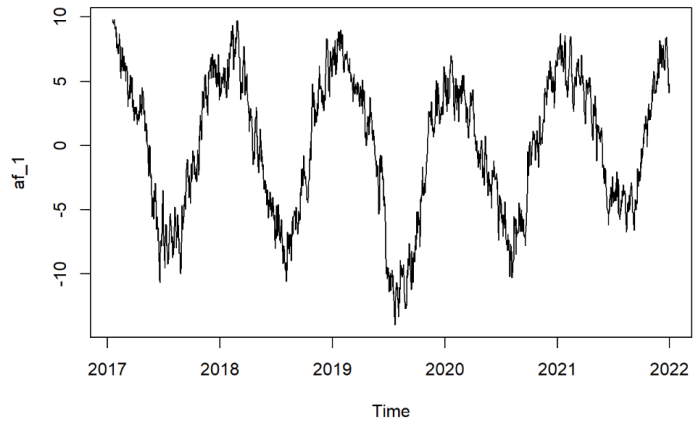


FIGURE 1.2 – Chronogramme de la série de la composante 1

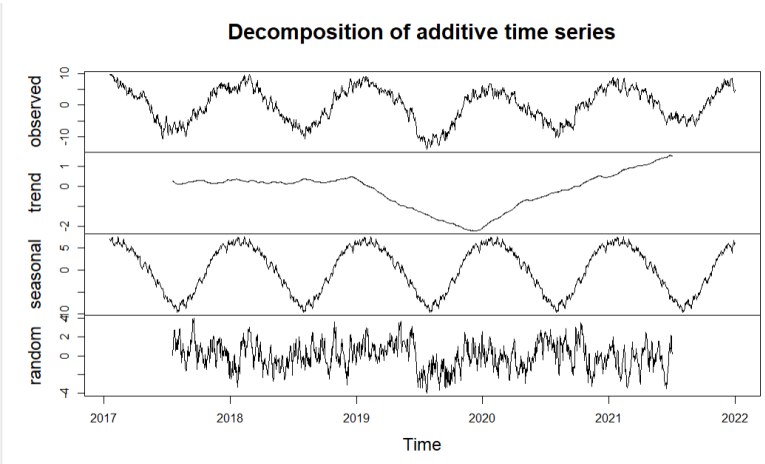


FIGURE 1.3 – Décomposition de la série de la composante 1

D'après la figure 1.3, la série issue de la composante principale 1 présente un aspect saisonnier, avec une tendance globalement stable en 2017-2018, décroissante en 2019, puis à nouveau croissante par la suite. On observe un phénomène particulier en 2019, qui semble avoir perturbé la dynamique des variables liées à la température et à la profondeur de la nappe phréatique.

b- Composante 2

— Tendance et saisonnalité

```
af_2<-ts(acp$li[,2], start =c(2017,19),frequency = 365 )
af_22 <- decompose(af_2)
plot(af_2)
plot(af_22)
```

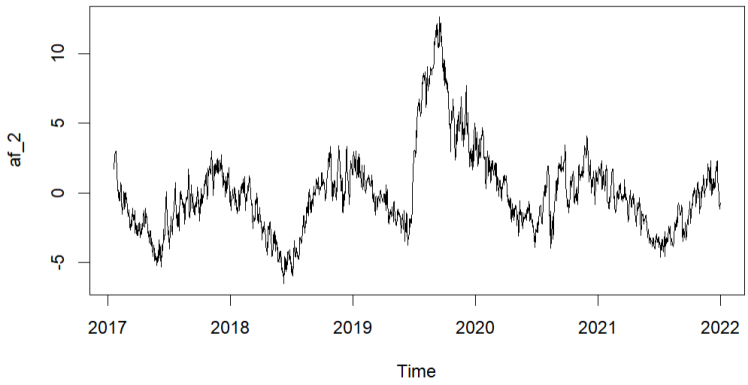


FIGURE 1.4 – Chronogramme de la série de la composante 2

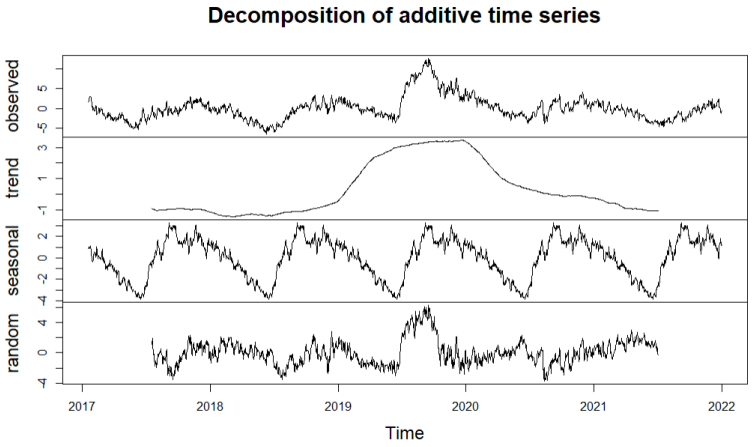


FIGURE 1.5 – Décomposition de la série de la composante 2

La série observée sur la composante 2 présente des valeurs plus faibles pendant l'été, ce qui correspond aux variables liées à l'hydrologie. On observe une hausse de la tendance en 2019, qui commence ensuite à revenir à la normale à partir de 2020. Le phénomène observé sur les autres composantes semble également avoir affecté celle-ci, mais son effet paraît plus temporaire.

c- Composante 3

— Tendance et saisonnalité

```
af_3<-ts(acp$li[,3], start =c(2017,19),frequency = 365 )
af_33 <- decomp(af_3)
plot(af_3)
plot(af_33)
```

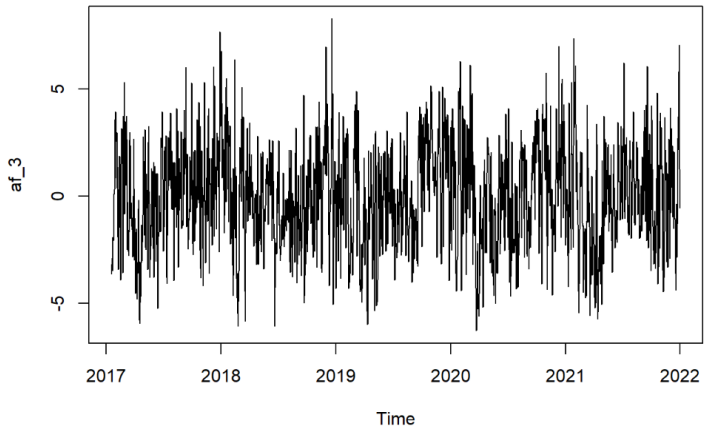


FIGURE 1.6 – Chronogramme de la série de la composante 3

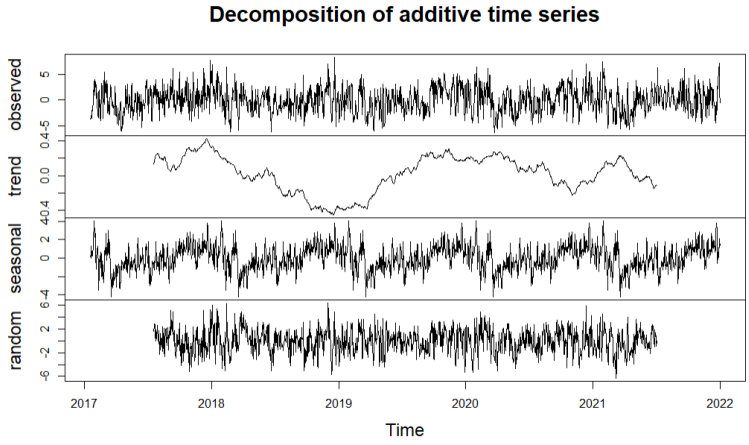


FIGURE 1.7 – Décomposition de la série de la composante 3

Pendant l'été, les variables liées aux phénomènes atmosphériques (radiation longue onde, vent) et aux phénomènes thermiques directs (chaleur sensible, rayonnement court) présentent, d'après la série observée, un flux plus faible. On observe également une chute marquée de la tendance en 2019, ainsi qu'une baisse moins prononcée vers la fin de 2020. La composante 2, qui regroupe ces variables, apparaît comme saisonnière, en raison de la dynamique similaire qui se répète chaque année.

d- Composante 4

— Tendance et saisonnalité

```r
af_4<-ts(acp$li[,4], start =c(2017,19),frequency = 365 )
af_44 <- decompose(af_4)
plot(af_4)
plot(af_44)
```

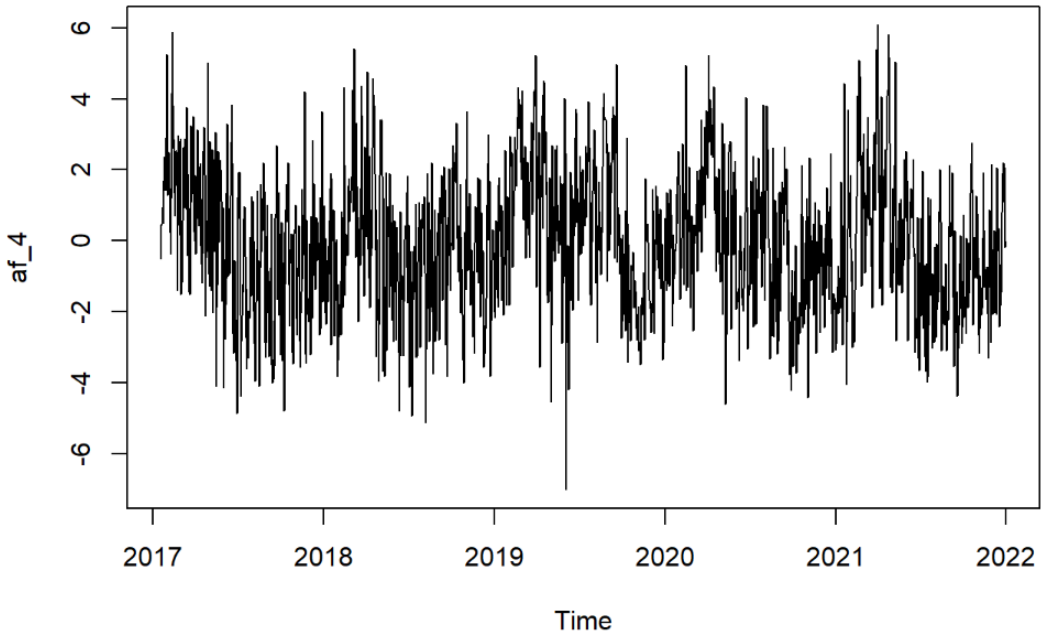


FIGURE 1.8 – Chronogramme de la série de la composante 4

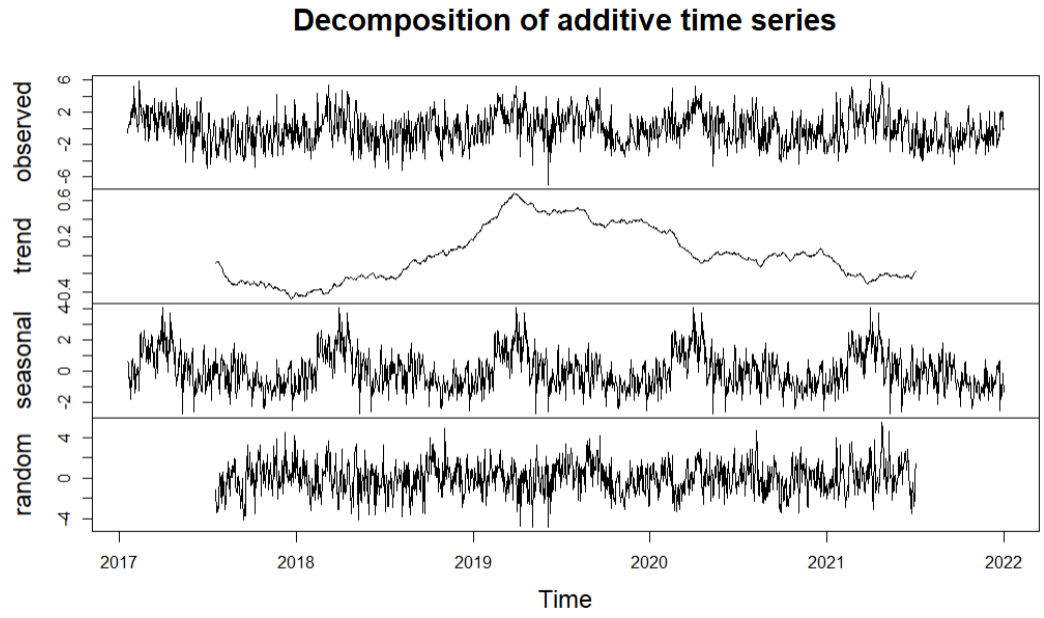


FIGURE 1.9 – Décomposition de la série de la composante 4

L'humidité relative (RH) et les variables liées au flux de chaleur du sol (Soil heat flux)

à l'axe 4, présentent globalement une tendance croissante. Cette tendance connaît toutefois une chute à partir de 2019, comme observé pour d'autres composantes. Par ailleurs, l'aspect saisonnier de cette composante est bien marqué et facilement identifiable.

1.3.2 Les gaz à effets de serre

a- CO_2

Visualisons tout d'abord le chronogramme de CO_2

```
plot(tco2)
```

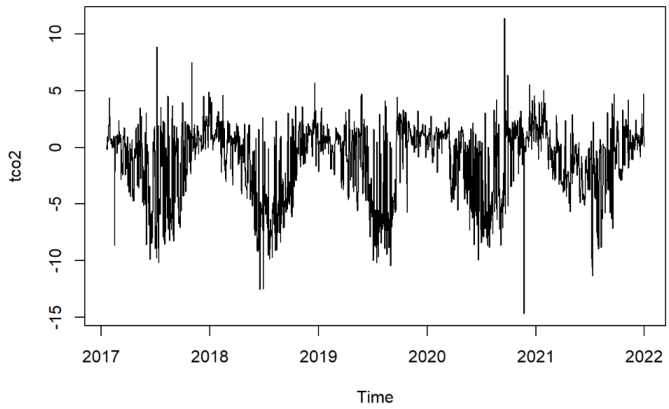


FIGURE 1.10 – Chronogramme de CO_2

En observant le chronogramme du flux de CO2, la saisonnalité est peu observable mais, une tendance claire est présente. Nous passons donc par une décomposition pour plus de précision.

— Décomposition de la série

```
dec_co2 <- stl(tco2, s.window = "periodic")
plot(dec_co2)
```

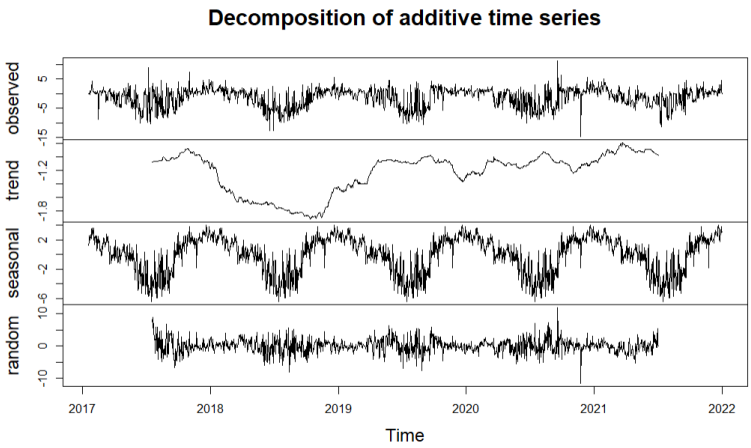


FIGURE 1.11 – Décomposition de CO_2

— Tendance

```
acf(co2)
```

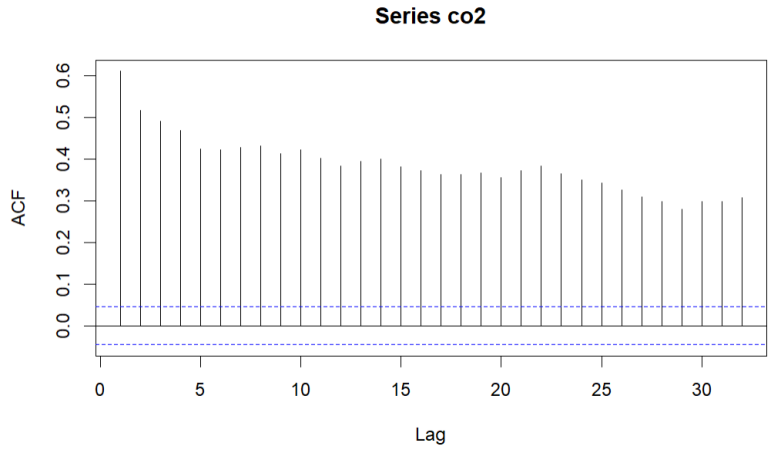


FIGURE 1.12 – ACF de CO_2

Pour CO_2, la décroissance est lente, on peut affirmer la présence d'une tendance.
Et sur le graphique de décomposition, on observe une croissance en 2017, une décroissnace entre fin 2017 et fin 2018 (ce qui est probablement due aux canicules obsèrevées lors des étés) et ensuite une croissance de fin 2018 jusqu'en 2022

— Saisonnalité

Dans head, on a " Frequency = 365 " pour les deux séries, donc ce sont des séries journalières avec une saisonnalité annuelle , ce qui est aussi visible sur le graphique de décomposition.
Pour plus de detail, on va transformer notre donnée en donnée mensuelle .

Agrégation par mois

```
An <- substr(dates, 1, 4)
Mois <- substr(dates, 6, 7)
AnMois <- as.numeric(paste(An, Mois, sep = ""))
data_mois <- aggregate(df[,-1], by = list(AnMois), FUN = sum)
colnames(data_mois)[1] <- "AnMois"
head(data_mois)
```

Description: df [6 × 60]

	AnMois <dbl>	ETR <dbl>	FCO2 <dbl>	FCH4 <dbl>	Heat <dbl>	LHeat <dbl>	SoilHeatd2 <dbl>
1	201701	-0.08258203	16.136435	-0.1201289	452.3601	-9.271885	-4.233309
2	201702	0.81738164	2.067737	-0.3932979	920.8585	653.477394	37.277286
3	201703	1.33525422	-1.973507	-0.5864424	1767.1401	1108.500995	11.772960
4	201704	2.33950061	-48.600337	-1.2857656	3762.9002	1929.325538	-87.416484
5	201705	3.08442128	-39.046516	-1.2224822	3523.6910	2428.920004	-61.012673
6	201706	5.00539111	-116.572877	-1.1276001	2761.2398	3584.727348	-98.072478

6 rows | 1-8 of 60 columns

FIGURE 1.13 – Données mensuelles

Examinons maintenant le month.plot de la série mensuelle de CO_2 .

```
diox <- ts(data_mois[,3], start = c(2017, 1), frequency = 12) #
   Serie mensuelle de CO2
monthplot(diox, ylab = "CO2",main = "Profil␣saisonnier␣mensuel␣de
   ␣CO2",labels = substr(month.name,1,3))
```

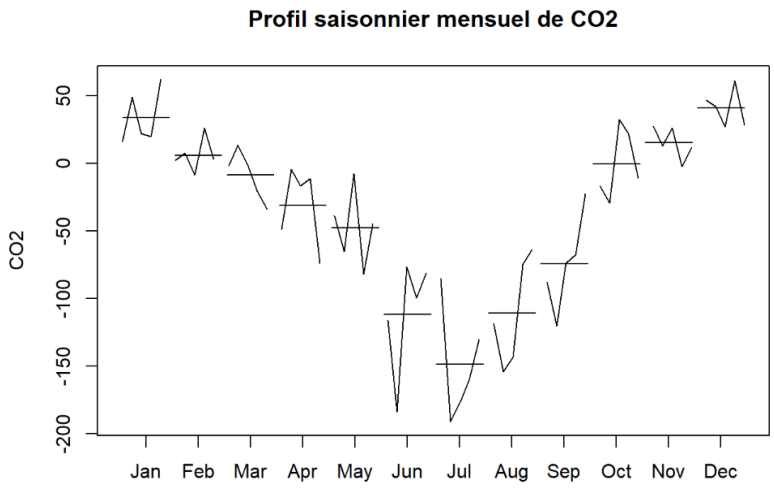


FIGURE 1.14 – month.plot de CO_2

Chaque chronogramme represent le flux de CO_2 par an.
S'il n'y avais pas l'aspect saisonnier, Ces 12 chronogrammes se ressembleraient, ce qui n'est pas le cas ici et donc il y'a une saisonnalité.
- On remarque qu'il y'a plus d'absorption (signe négatif) de CO_2 dans le mois de Juin,Juillet et Août que les autres mois possiblement due à l'activité végétale (photosynthèse accrue en été = absorption de CO_2 et rejet de CO_2 pendant le jour).
- On remarque aussi plus de relâchement CO_2 dans les mois hivernaux (Décembre, Janvier) par la tourbière, ce qui serait due à la perte de feuilles de plusieurs plantes et donc l'absence de photosynthèse de ces derniers

Conclusion :

De tout ce qui précède, on peut affirmer que notre série est saisonnière de saisonnalité 12 mois ou 365 jours.

b- CH4

```
plot(tch4)
```

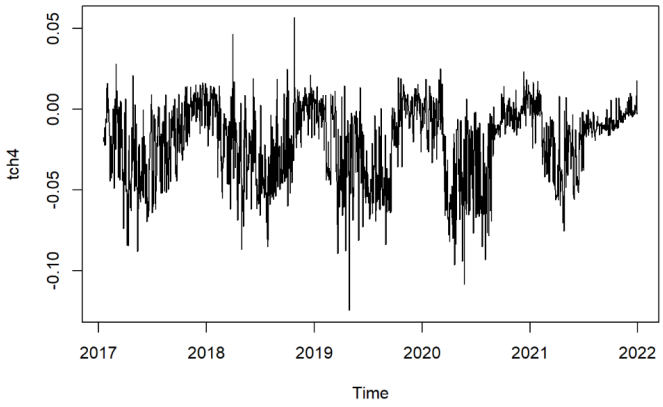


FIGURE 1.15 – Chronogramme de CH_4

De même pour CH_4, on note une tendance apparente. La décomposition est utile ici aussi pour une analyse plus claire.

— Décomposition de la série

```
dec_ch4 <- decompose(tch4)
plot(dec_ch4)
```

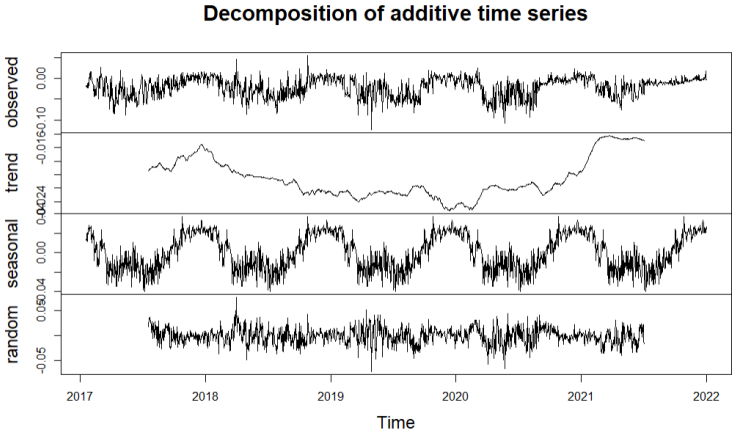


FIGURE 1.16 – Décomposition de CH_4

— Tendance

```
acf(ch4)
```

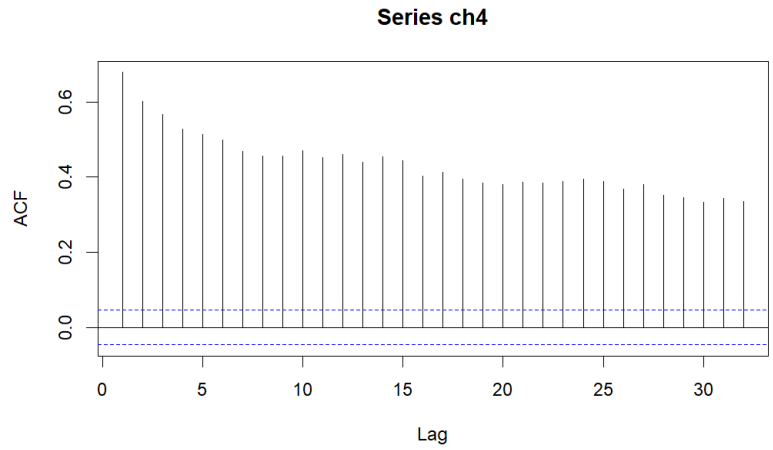


FIGURE 1.17 – ACF de CH_4

Pour le CH_4, la décroissance des corrélations est lente d'après la figure 1.17, ce qui indique la présence d'une tendance.
On observe que cette tendance commence déjà à diminuer dès 2018, et cette baisse s'accentue en 2019. En 2020, la tendance retrouve ensuite sa dynamique normale, orientée à la hausse.

— Saisonnalité

La série de CH_4 présente une saisonnalité bien marquée, caractérisée par une forte libération de méthane pendant les mois d'été d'après figure 1.16

Analysons également le *month.plot* de CH_4 afin d'examiner plus précisément sa nature saisonnière.

```
diox <- ts(data_mois[,4], start = c(2017, 1), frequency = 12) #
   Serie mensuelle de CH4
monthplot(diox, ylab = "CH4",main = "Profil␣saisonnier␣mensuel␣de
   ␣CH4",labels = substr(month.name,1,3))
```

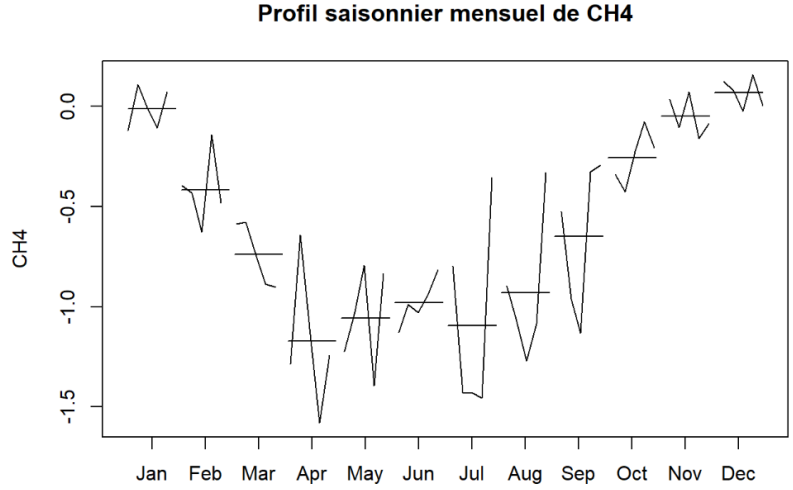


FIGURE 1.18 – Monthplot de CH_4

S'il n'y avait pas de composante saisonnière, ces 12 chronogrammes se ressembleraient fortement, ce qui n'est pas le cas ici : on observe des variations récurrentes au cours de l'année, ce qui indique la présence d'une saisonnalité.

On remarque notamment qu'il y a plus de libération de CH_4 durant les mois d'été (d'avril à août), ce qui peut s'expliquer par l'augmentation de la température –> cela favorise l'activité des micro-organismes méthanogènes responsables de la production de CH_4.
De plus, si la nappe phréatique reste élevée durant cette période, les conditions anaérobies sont maintenues –> ce qui conduit à une forte émission de CH_4 par la tourbière.

Conclusion

De tout ce qui précède, on peut affirmer que la série temporelle des flux de CH_4 présente une saisonnalité annuelle, avec une période de 12 mois (ou 365 jours).

Les parties précédentes nous ont permis de connaître la nature des séries de CO_2 et CH_4 en générales, et la nature des composantes principales qui nous serviront de régresseurs par la suite.

Par la suite, nous allons estimer différents modèles afin d'identifier ceux qui reproduisent le mieux les trajectoires des gaz à effet de serre. Cette démarche reposera sur le choix de diverses combinaisons de composantes principales et sur de diverses périodes, dans le but de sélectionner celles qui servent de meilleurs régresseurs.

Le test de stationnarité, la stationnarisation si nécessaire, l'identification des paramètres ainsi que l'estimation des coefficients seront réalisés automatiquement grâce à la fonction `auto.arima`, que nous utiliserons par la suite.

A- Régresseurs utilisés : Composantes 1 et 3 pour le CO_2 ; composantes 1, 3 et 4 pour le CH_4

Commencons d'habord par définir les régresseurs.

```
rg1<-as.matrix(acp$li[,c(1,3)])
rg2<-as.matrix(acp$li[,c(1,3,4)])
```

Modèle 1 : Modèle avec régressseurs tenant compte des données de 2020

Scindons ensuite CO_2 et CH_4 en 2 données : données d'entrainement et données test.

— Données d'entrainement 2017-2020

```
tco2_train <- window(tco2, end = c(2020, 365))
reg1_train<-rg1[1:length(tco2_train),]

```

```
tch4_train <- window(tch4, end = c(2020, 365))
reg2_train<-rg2[1:length(tch4_train),]
```

— Données test 2021

```
tco2_test <- window(tco2, start = c(2021, 1))
reg1_test <- rg1[(length(tco2_train)+1):(length(tco2_train)+
   length(tco2_test)), ]

tch4_test <- window(tch4, start = c(2021, 1))
reg2_test <- rg2[(length(tch4_train)+1):(length(tch4_train)+
   length(tch4_test)), ]
```

— Analyse du modèle

* **CO_2**

Passons à l'entraînement en déterminant un modèle (permettant de faire des prévisions avec des phénomenès observés)

```
mod_co22 <- auto.arima(tco2_train, xreg = reg1_train )
summary(mod_co22)
```

```
## Series: tco2_train
## Regression with ARIMA(4,1,1) errors
##
## Coefficients:
##         ar1    ar2     ar3     ar4      ma1   Axis1   Axis3
##      0.1691  0.029  0.0711  0.0589  -0.9470  0.4343  0.6831
## s.e.  0.0310  0.030  0.0295  0.0292   0.0173  0.0404  0.0256
##
## sigma^2 = 4.051:  log likelihood = -3050
## AIC=6116   AICc=6116.1   BIC=6158.18
##
## Training set error measures:
##                      ME     RMSE      MAE       MPE     MAPE      MASE
## Training set 0.008079491 2.007175 1.392018 -21.73257 363.9474 0.5341945
##                     ACF1
## Training set -0.0005960364
```

FIGURE 1.19 – modèle de CO_2 sur 2017-2020

Le modèle nous fait savoir que la série de CO_2 avec régresseurs est différenciée pour être stationnaire. cette non-stationnarité est liée certainement aux régresseurs .

Analysons les résidus de ce modèle afin de conclure la validité du modèle

— Résidus

```
tsdisplay(residuals(mod_co22), main ="Residus␣du␣modele␣ARIMAX␣
   saisonnire␣de␣CO2␣sur␣la␣periode␣d'essaie(debut␣2017-fin␣2020)"
   )
```

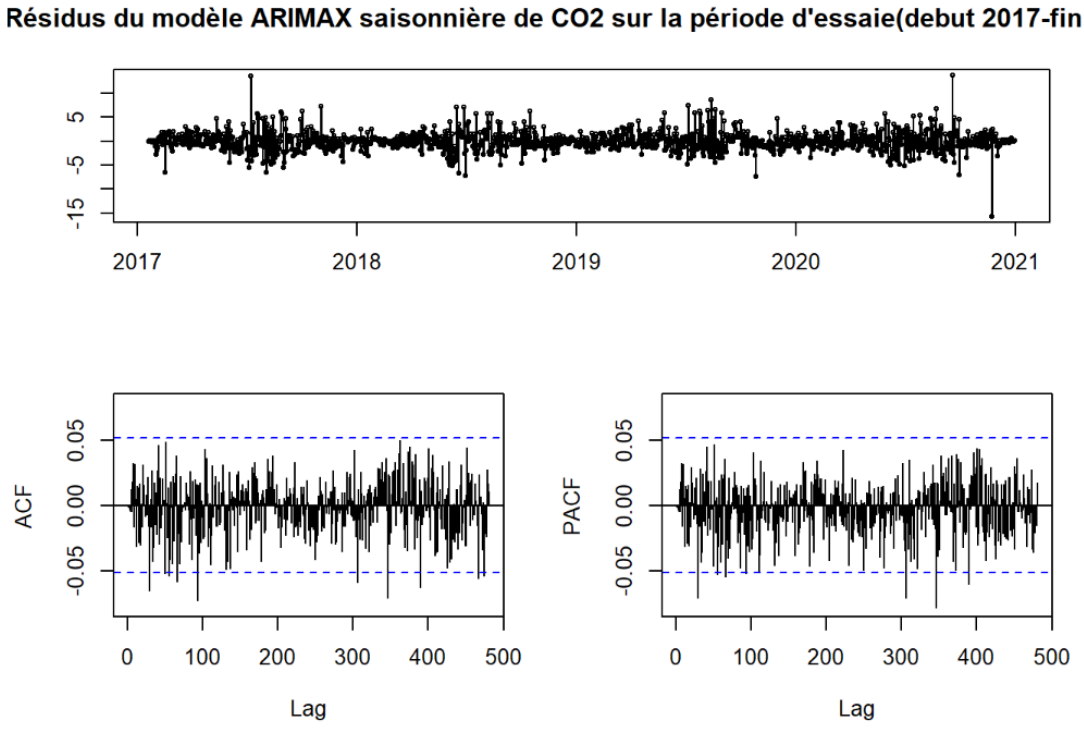


FIGURE 1.20 – Residus de CO_2 sur 2017-2020

Les autocorrelations ne nous permettent pas d'affirmer clairement que les résidus du modèle de CO2 sont du bruit blanc à cause du fait que certains sont légèrement sortie de la bande.

Faisons le test de blancheur pour vérifier si les résidus sont du bruit blanc ou pas, sous les hypothèses

— H0 :"les résidus ne sont pas autocorrélés (c'est du bruit blanc)"
contre
— H1 :"les résidus sont autocorrélés (modèle mal ajusté)"
au niveau de risque 5 %

```
Box.test(residuals(mod_co22), lag = 30, type = "Ljung-Box")
```

```
##
##  Box-Ljung test
##
## data:  residuals(mod_co22)
## X-squared = 19.433, df = 30, p-value = 0.9305
```

FIGURE 1.21 – Test de blancheur de CO_2 sur 2017-2020

Pour ce test, la p-valeur est supérieure au seuil de significativité $\alpha = 0{,}05$. Par conséquent, on ne rejette pas l'hypothèse nulle H_0, ce qui indique que les résidus peuvent être considérés comme du bruit blanc. Cela suggère que le modèle est correctement ajusté .

Analysons quelques statistiques de ce modèles.

```
accuracy(mod_co22)[, "RMSE"] /sd(tco2)
accuracy(mod_co22)[, "RMSE"] /abs(mean(tco2))
```

```
[1] -1.212604
[1] 3.239895
[1] 2.007175
```

FIGURE 1.22 – statistique du modèle de CO_2 sur 2017-2020

RMSE < Ecart-type : le modèle obtenu pour CO_2 explique une part significative de la variabilité, Mais elle est sensiblement superieure à la moyenne, ce qui indique que le modèle est correct, mais pas très précis.

— Prévision sur 2021

Nous allons réaliser la prévision sur l'horizon de l'année 2021 et vérifier ensuite la superposition des valeurs prédites avec les données réellement observées pour cette période.

```
par(mfrow=c(1,2))
pred_co2 <- forecast(mod_co22, h = 365, xreg = reg1_test)
plot(pred_co2, main = "Prevision de CO2 pour 2021")
plot(tco2,main="la serie originale" )
```

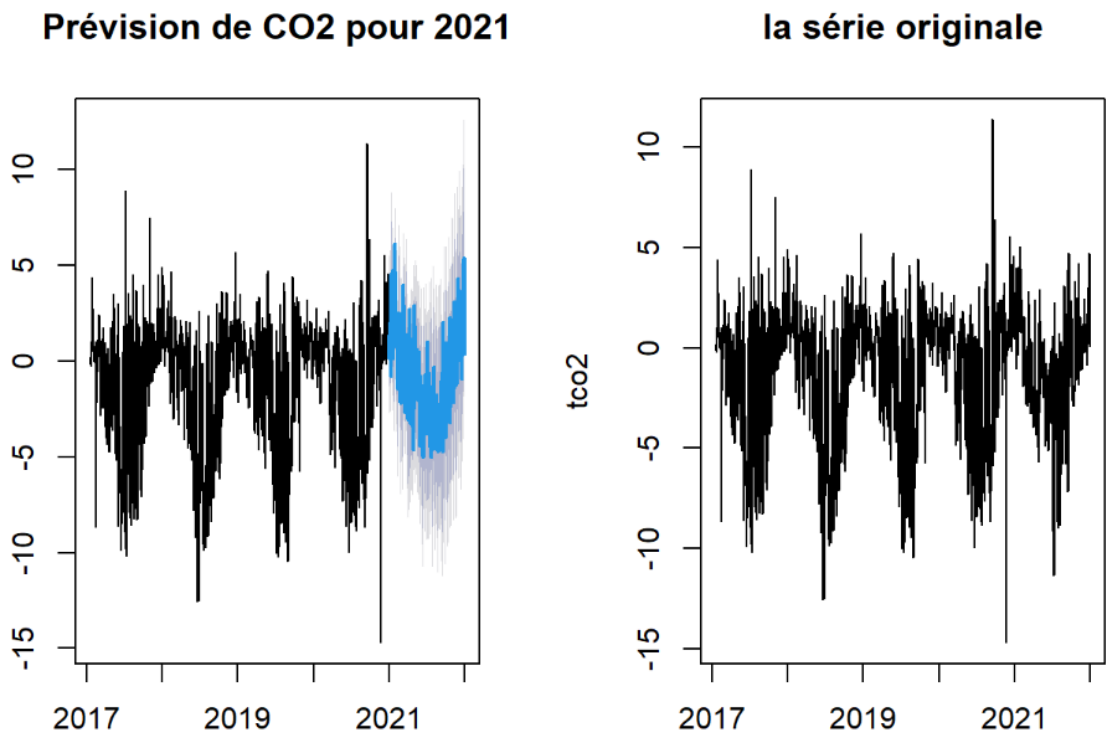


FIGURE 1.23 – Prévision de CO_2 sur 2021

En observant le graphique de la prédiction, on constate que celle-ci reproduit globalement pas mal les fluctuations de la série de CO_2 pour l'année 2021. Pour compléter cette analyse qualitative, nous allons maintenant examiner quelques statistiques descriptives des erreurs de prévision, afin d'évaluer plus précisément la qualité du modèle.

```
accuracy(tco2_test,pred_co2$mean)
```

```
                ME     RMSE      MAE       MPE     MAPE      ACF1 Theil's U
Test set 0.2214726 1.721516 1.114809 0.1567243 94.85057 0.5191973 0.5873369
```

FIGURE 1.24 – accuracy de la prévision de CO_2 sur 2021

MAPE est élevé donc les données surestimées et sousestimées sont nombreuses, ce qui montre que la prédiction n'est pas aussi bonne que ça, mais c'est mieux qu'un modèle naif (répétition de la dernière sur le futur) a cause de (Theil's U < 1) .

*$\mathbf{CH_4}$

Pour CH_4 aussi, on refait les mêmes choses

— Analyse du modèle

```
mod_ch44 <- auto.arima(tch4_train, xreg = reg2_train )
summary(mod_ch44)
```

```
## Series: tch4_train
## Regression with ARIMA(1,0,2) errors
##
## Coefficients:
##          ar1      ma1     ma2  intercept  Axis1  Axis3    Axis4
##       0.9493  -0.6811  -0.0963    -0.0206  2e-03  6e-03  -0.0047
## s.e.  0.0149   0.0311   0.0297     0.0012  2e-04  1e-04   0.0002
##
## sigma^2 = 0.0001185:  log likelihood = 4475.65
## AIC=-8935.3   AICc=-8935.2   BIC=-8893.11
##
## Training set error measures:
##                       ME       RMSE        MAE      MPE     MAPE     MASE
## Training set -5.333803e-06 0.01085749 0.007065518 28.07183 137.4635 0.328882
##                      ACF1
## Training set -0.001272294
```

FIGURE 1.25 – modèle de CH_4 sur 2017-2020

La série de CH4 régressée est toujours stationnaire. Donc les régresseurs n'ont pas affectés la stationnarité de la série.

Analysons les résidus de ce modèle afin de conclure la validité de ce modèle.

— Résidus

```
tsdisplay(residuals(mod_ch44), main ="Residus du modele ARIMAX
   saisonniere de CH4 sur la periode d'essaie(debut 2017-fin 2020)
   ")
```

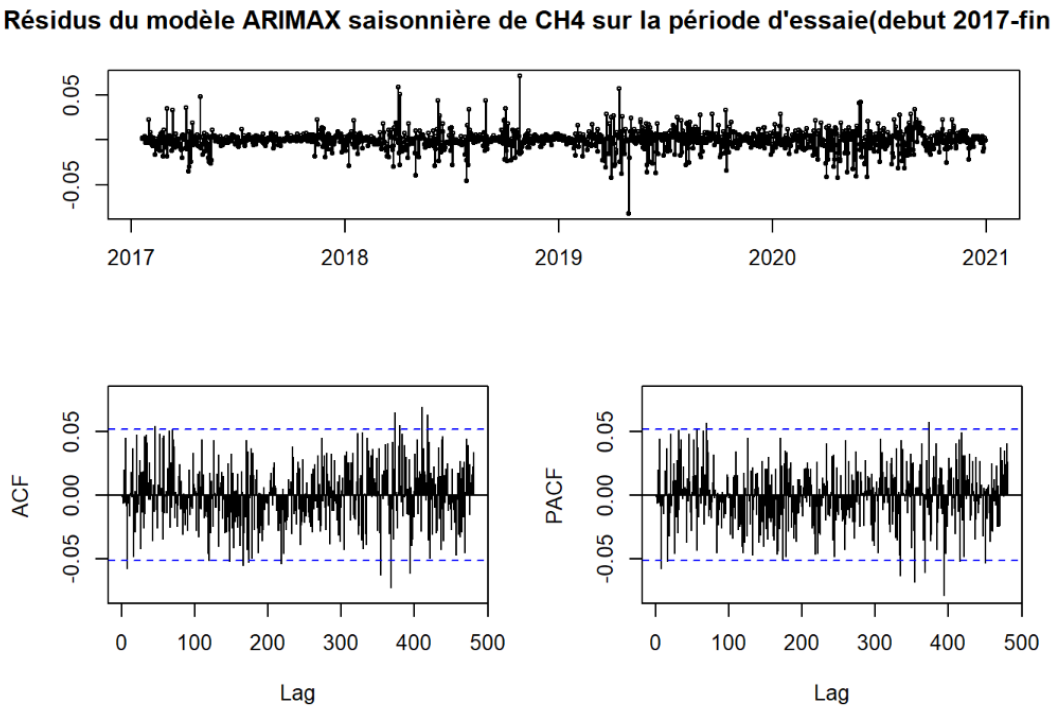


FIGURE 1.26 – Residus de CH_4 sur 2017-2020

Les autocorrelations ne nous permettent pas d'affirmer clairement que les résidus du modèle de CH_4 sont du bruit blanc à cause du fait que certains sont légèrement sortie de la bande .
Passons maintenant au test de blancheur sur les résidus pour être plus précis sur sa nature.

```
Box.test(residuals(mod_ch44), lag = 30, type = "Ljung-Box")
```

```
##
##  Box-Ljung test
##
## data:  residuals(mod_ch44)
## X-squared = 26.905, df = 30, p-value = 0.6282
```

FIGURE 1.27 – Test de blancheur de CH_4 sur 2017-2020

En ce qui concerne le test de blancheur, la p-valeur est supérieure eu risque(0.05), donc on ne rejette pas "les résidus sont du bruit blancs" et donc on peut considérer les résidus du modèle de CH_4 comme etant du bruit blanc.

En ce qui concerne ce modèle, en analysant la sortie suivante :

```
mean(tch4); sd(tch4)
accuracy(mod_ch44)[, "RMSE"]
```

```
[1] -0.0201321
[1] 0.02354836
[1] 0.01085749
```

FIGURE 1.28 – statistique du modèle de CH_4 sur 2017-2020

on peut dire que RMSE est inférieure à la moyenne et aussi inférieure à l'écart-type, donc le modèle obtenu pour CH_4 explique une bonne part de variabilité .

— Prévision sur 2021

On réalise maintenant la prévision sur l'horizon 2021 et vérifier sa superposition aux données connues.

```
par(mfrow=c(1,2))
pred_ch4 <- forecast(mod_ch44, h = 365, xreg = reg2_test)
plot(pred_ch4, main = "Prevision de CH4 pour 2021")
plot(tch4,main="la serie originale" )
```

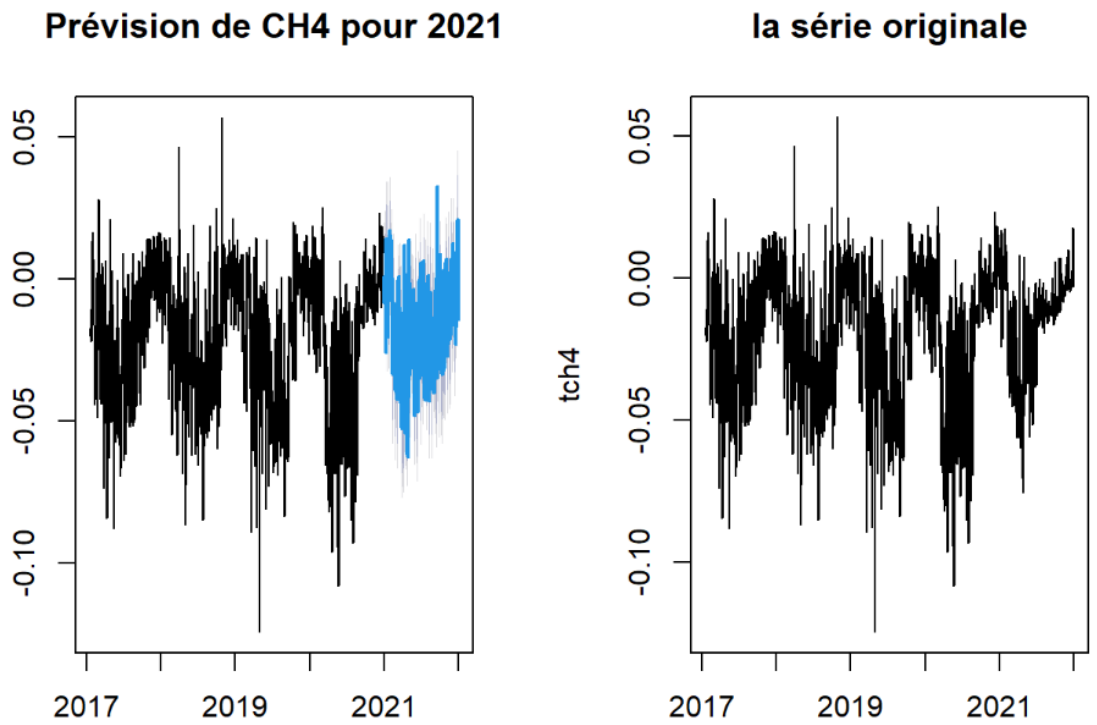


FIGURE 1.29 – Prévision de CH_4 sur 2021

Analysons la qualité de la prévision avec la commande `accuracy()`.

```
accuracy(tch4_test,pred_ch4$mean)
```

```
                     ME        RMSE         MAE      MPE    MAPE      ACF1 Theil's U
Test set -0.002464183 0.009782133 0.007081393 16.62787 91.0725 0.6839007 0.9580824
```

FIGURE 1.30 – accuracy de la prévision de CH_4 sur 2021

Les mesures d'erreurs de précision de la prévision nous montrent que MAPE(Erreur Moyenne Absolue en Pourcentage) est élevé donc les données surestimées et sous-estimées sont nombreuses , ce qui montre que la prédiction n'est pas aussi bonne que ça, mais c'est très mieux qu'un modèle naif a cause de (Theil's U <1).

Modèle 2 : Modèle avec régressseurs sans les données de 2020

Avant tout, commençons avec la construction des données et des régresseurs sur la période train et test.

Données d'entrainement

```r
tco2_17_19 <- window(tco2, end = c(2019, 365))
reg_17_19<-rg1[1:length(tco2_17_19),]

tch4_17_19 <- window(tch4, end = c(2019,365 ))
r_17_19<-rg2[1:length(tch4_17_19),]
```

Données test

```r
tco2_20_21 <- window(tco2, start = c(2020, 1))
reg_20_21 <- rg1[(length(tco2_17_19) + 1):(length(tco2_17_19) +
   length(tco2_20_21)), ]

tch4_20_21 <- window(tco2, start = c(2020, 1))
r_20_21 <- rg2[(length(tch4_17_19) + 1):(length(tch4_17_19) +
   length(tch4_20_21)), ]
```

— Analyse du modèle

CO_2

```r
mod_co2_17_19 <- auto.arima(tco2_17_19, xreg = reg_17_19 )
summary(mod_co2_17_19)
```

```
Series: tco2_17_19
Regression with ARIMA(1,1,2) errors

Coefficients:
         ar1      ma1     ma2   Axis1   Axis3
      0.7160  -1.4879  0.5143  0.4659  0.6956
s.e.  0.1789   0.2007  0.1777  0.0550  0.0295

sigma^2 = 3.848:  log likelihood = -2249.98
AIC=4511.96   AICc=4512.04   BIC=4541.85

Training set error measures:
                     ME     RMSE      MAE       MPE     MAPE      MASE       ACF1
Training set 0.01093882 1.956148 1.371735 -47.38454 416.0245 0.5086019 0.01633917
```

FIGURE 1.31 – Modèle de CO_2 sur 2017-2019

CH_4

```
mod_ch4_17_19 <- auto.arima(tch4_17_19, xreg = r_17_19 )
summary(mod_ch4_17_19)
```

```
Series: tch4_17_19
Regression with ARIMA(2,1,3) errors

Coefficients:
          ar1     ar2      ma1      ma2     ma3  Axis1   Axis3    Axis4
      -0.1592  0.7291  -0.6214  -0.9303  0.5804  2e-03  0.0062  -0.0047
s.e.   0.1001  0.0877   0.1126   0.0298  0.0983  2e-04  0.0002   0.0002

sigma^2 = 0.0001098:  log likelihood = 3381
AIC=-6744   AICc=-6743.83   BIC=-6699.17

Training set error measures:
                       ME       RMSE         MAE      MPE    MAPE      MASE       ACF1
Training set -1.111041e-05 0.01043659 0.006491715 27.47347 161.641 0.3044104 0.01068031
```

FIGURE 1.32 – Modèle de CH_4 sur 2017-2019

— Résidus

Passons directement au test de blancheur pour conclure la nature des residus.

```
Box.test(residuals(mod_co2_17_19), lag = 30, type = "Ljung-Box")
```

```
        Box-Ljung test

data:  residuals(mod_co2_17_19)
X-squared = 23.491, df = 30, p-value = 0.7945
```

FIGURE 1.33 – test de blancheur du modèle de CO_2

```
Box.test(residuals(mod_ch4_17_19), lag = 30, type = "Ljung-Box")
```

```
        Box-Ljung test

data:  residuals(mod_ch4_17_19)
X-squared = 30.816, df = 30, p-value = 0.4245
```

FIGURE 1.34 – test de blancheur du modèle de CH_4

Ici les p-valeurs des deux test sont inferieures au risque(0.05), donc les résidus du modèle de CO_2 et de CH_4 sont du bruit blanc.

On peut donc passer à la prévision du flux des gaz à effets de serre sur 2020-2021 ;

— Prévision

Celui de CO_2 nous donne :

```
par(mfrow=c(1,2))

pred_co2_20_21 <- forecast(mod_co2_17_19, h = 365*2, xreg =reg_20
    _21   )

plot(pred_co2_20_21, main = "Prevision de CO2 pour 2020-2021")
plot(tco2,main="la serie originale" )
```

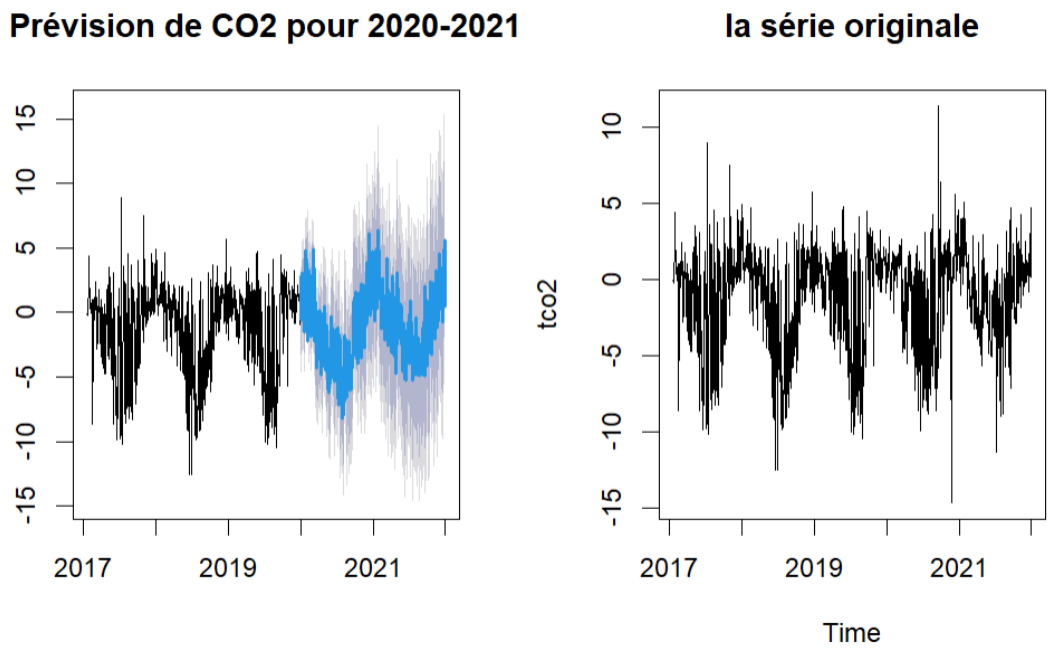


FIGURE 1.35 – chronogramme de la prédiction de CO_2

Visuellement, on voit que les prévision sont bonnes, à cause de la dynamique et la saisonnalité qui sont concervées , et aussi la fluctuation de la prévision augmente progressivement avec le temps

Voyons pour CH_4 aussi

```
par(mfrow=c(1,2))

pred_ch4_20_21 <- forecast(mod_ch4_17_19, h = 365*2, xreg =r_20_
    21   )

plot(pred_ch4_20_21, main = "Prevision de CH4 pour 2018-2021")
plot(tch4,main="la serie originale" )
```

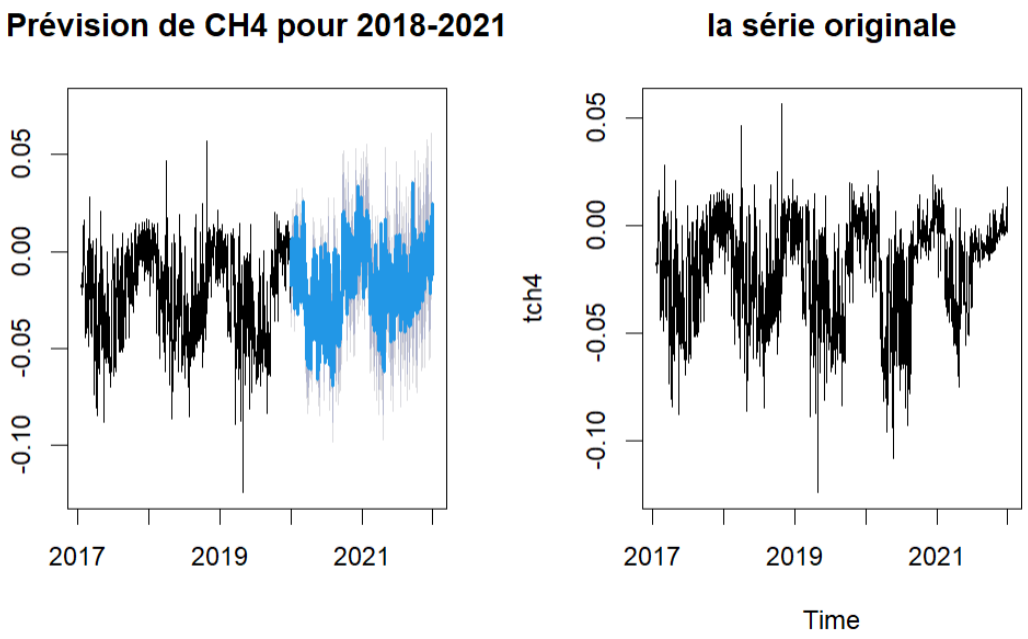


FIGURE 1.36 – chronogramme de la prédiction de CH_4

De même ici aussi, on remarque la conservation de la dynamique et de la saisonnalité.
Voyons quelques statistiques de la prévision.

```
accuracy(tco2_20_21,pred_co2_20_21$mean)
```

```
                ME     RMSE      MAE      MPE     MAPE      ACF1 Theil's U
Test set -0.1220508 2.038874 1.355502 8.333917 129.2074 0.3516016 0.9867543
```

FIGURE 1.37 – statistique de la prévision de CO_2

Les statistiques de la prévision de CO_2 nous montre que l'Erreur Moyenne Absolue en Pourcentage (MAPE) est élevée, ce qui montre qu'on a plus d'erreur que de bonne valeur dans la prédiction

```
accuracy(tch4_20_21,pred_ch4_20_21$mean)
```

```
               ME     RMSE      MAE       MPE     MAPE      ACF1 Theil's U
Test set 1.00697 3.153798 2.298546 -16401.16 33970.39 0.5859264   173.901
```

FIGURE 1.38 – statistique de la prévision de CH_4

L'Erreur Moyenne Absolue en Pourcentage (MAPE) est un peu élevée, ce qui montre qu'on a un peu d'erreur que de bonne valeur dans la prédiction. Les autres indicateurs montrent que le modèle est bon, mais toujours perfectible.

Modèle 3 : Modèle sans l'année 2019(année de secheresse)

On va faire un modèle sur l'année (2017-2018) et faire la prévision sur les années qui suivent pour voir l'impact de l'année de sécheresse sur le flux de ces gaz.

CO_2

```
tco2_17_18 <- window(tco2, end = c(2018, 365))
reg1_17_18<-rg1[1:length(tco2_17_18),]

tco2_19_21 <- window(tco2, start = c(2019, 1))
reg1_19_21 <- rg1[(length(tco2_17_18) + 1):(length(tco2_17_18) +
   length(tco2_19_21)), ]
```

```
mod_co2_17_18 <- auto.arima(tco2_17_18, xreg = reg1_17_18 )
summary(mod_co2_17_18)
```

```
## Series: tco2_18
## Regression with ARIMA(1,0,1) errors
##
## Coefficients:
##          ar1      ma1  intercept   Axis1   Axis3
##       0.8927  -0.7139    -1.5140  0.4233  0.6977
## s.e.  0.0421   0.0644     0.1947  0.0365  0.0355
##
## sigma^2 = 3.879:  log likelihood = -1490.53
## AIC=2993.06   AICc=2993.18   BIC=3020.47
##
## Training set error measures:
##                       ME     RMSE      MAE       MPE     MAPE      MASE
## Training set 0.002055175 1.962668 1.361386 -93.72513 356.9494 0.4776065
##                    ACF1
## Training set 0.01566117
```

FIGURE 1.39 – modèle de CO_2 sur 2017-2018

La modèle de CO_2 sans l'année 2019 minimise bien les mesures d'erreurs sauf MAPE qui est toujours élevé et c'est un modèle stationnaire .

Comme principe, vérifions la blancheur des résidus

```
Box.test(residuals(mod_co2_17_18), lag = 30, type = "Ljung-Box")
```

```
        Box-Ljung test

data:  residuals(mod_co2_17_18)
X-squared = 23.594, df = 30, p-value = 0.7901
```

FIGURE 1.40 – test de blancheur des residus de CO_2

CH_4

```
tch4_17_18 <- window(tch4, end = c(2018,365 ))
reg2_17_18<-rg2[1:length(tch4_17_18),]

tch4_19_21 <- window(tch4, start = c(2019, 1))
reg2_19_21 <- rg2[(length(tch4_17_18) + 1):(length(tch4_17_18) +
   length(tch4_19_21)), ]
```

```
mod_ch4_17_18 <- auto.arima(tch4_17_18, xreg = reg2_17_18 )
summary(mod_ch4_17_18)
```

```
Series: tch4_17_18
Regression with ARIMA(1,1,2) errors

Coefficients:
         ar1      ma1     ma2   Axis1   Axis3    Axis4
      0.7444  -1.5245  0.5432  0.0024  0.0063  -0.0049
s.e.  0.1089   0.1260  0.1164  0.0003  0.0002   0.0002

sigma^2 = 9.389e-05:  log likelihood = 2290.01
AIC=-4566.02   AICc=-4565.86   BIC=-4534.06

Training set error measures:
                      ME     RMSE         MAE        MPE     MAPE     MASE       ACF1
Training set 5.334088e-05 0.009642 0.005790152 -0.6683113 158.1447 0.259855 0.01398772
```

FIGURE 1.41 – modèle de CH_4 sur 2017-2018

Le modèle de CH_4, ici sans l'année 2019 minimise aussi bien les mesures d'erreurs sauf MAPE qui reste toujours élevé et c'est un modèle non stationnaire , qui a été différencié une fois pour être stationnaire. Faisons maintenant le test de blancheur des résidus

```
Box.test(residuals(mod_ch4_17_18), lag = 30, type = "Ljung-Box")
```

On ne rejete donc pas la non blancheur des residus.

```
        Box-Ljung test

data:  residuals(mod_co2_17_18)
X-squared = 23.594, df = 30, p-value = 0.7901
```

FIGURE 1.42 – test de blancheur des residus de CH_4

Ici aussi, On ne rejette donc pas la non blancheur des résidus.

Passons maintenant à la prévision sur l'année 2019-2021

CO_2

```
par(mfrow=c(1,2))

pred_co2_19_21 <- forecast(mod_co2_17_18, h = 365*3, xreg =reg1_
   19_21  )

plot(pred_co2_19_21, main = "Prevision de CO2 pour 2019-2021")
plot(tco2,main="la serie originale" )
```

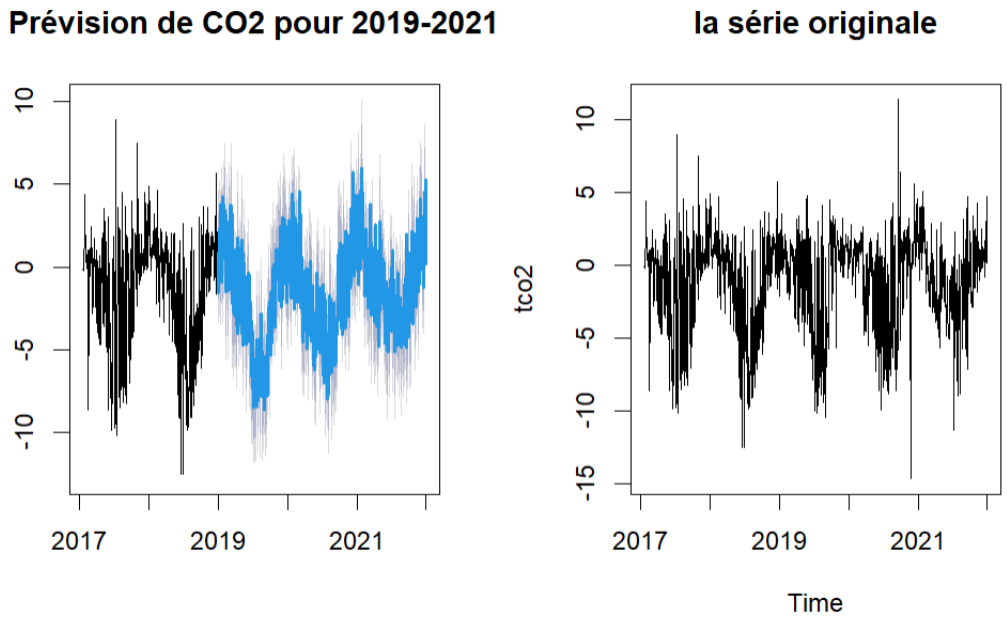


FIGURE 1.43 – Prévision de CO_2 sur 2019-2020

Visuellement, il semble que ce modèle a une meilleure prévision

CH_4

```
par(mfrow=c(1,2))

pred_ch4_19_21 <- forecast(mod_ch4_17_18, h = 365*3, xreg =reg2_
    19_21  )

plot(pred_ch4_19_21, main = "Prevision de CH4 pour 2019-2021")
plot(tch4,main="la serie originale" )
```

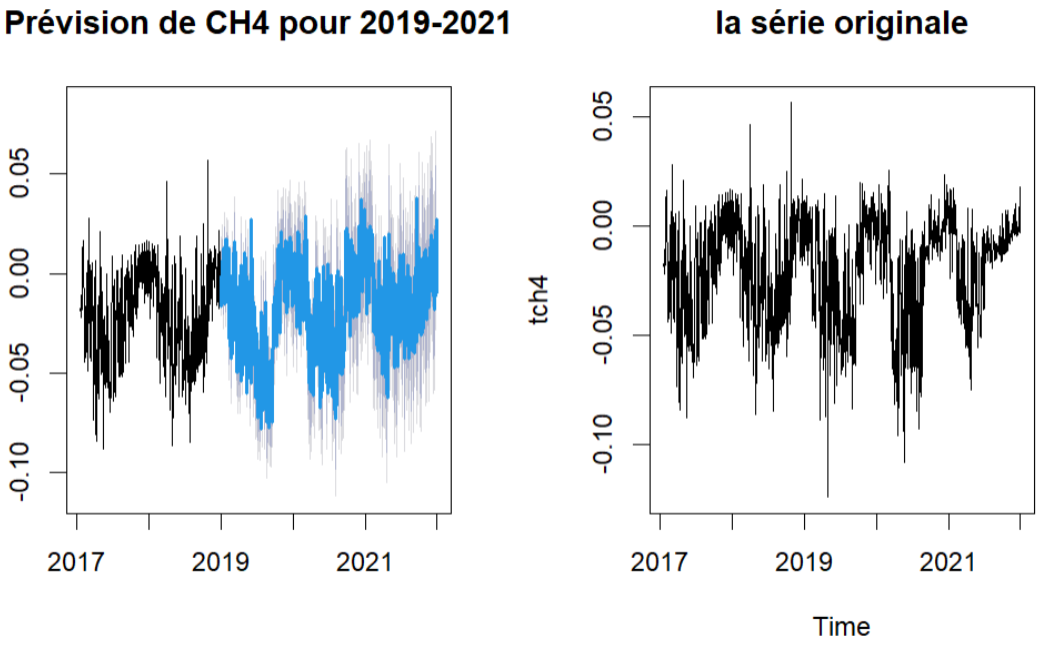


FIGURE 1.44 – Prévision de CH_4 sur 2019-2020

La prévision al'air d'être conforme à la prévision, mais plus condensée en 2021 .

Modèle 4 : Modèle sans régressseurs

Dans cette partie vérifions si un modèle conçu uniquement sur CO_2 et CH_4 capte mieux la variation de leur flux .

On va suivre ici aussi les mêmes étapes que celles de la conception du modèle précédent.

Données d'entrainement sur 2017-2020

```
tco2_train <- window(tco2, end = c(2020, 365))

tch4_train <- window(tch4, end = c(2020, 365))
```

Données test sur 2017-2020

```
tco2_test <- window(tco2, start = c(2021, 1))

tch4_test <- window(tch4, start = c(2021, 1))
```

— **Analyse du modèle**.

Passons à l'entrainement en déterminant un modèle

CO_2

```
mod_co2_sr <- auto.arima(tco2_train )
summary(mod_co2_sr)
```

```
Series: tco2_train
ARIMA(2,0,1) with zero mean

Coefficients:
         ar1      ar2      ma1
      1.2089  -0.2183  -0.8694
s.e.  0.0353   0.0337   0.0212

sigma^2 = 6.167:  log likelihood = -3356.97
AIC=6721.95   AICc=6721.97   BIC=6743.04

Training set error measures:
                     ME     RMSE      MAE      MPE     MAPE      MASE         ACF1
Training set -0.08244551 2.480834 1.75013 50.81721 335.8661 0.6716219 -0.005145006
```

FIGURE 1.45 – modèle de CO_2 sur 2017-2020 sans régresseurs

Le modèle de CO2 sans régresseur est stationnaire. Mais on remarque que les critères, et l'erreur moyenne en pourcentage (MAPE) sont très élevées, donc ce modèle ne capte pas la dynamique du flux de CO_2 .

Voyons quand même ce que donne le graphique de sa prévision sur 2021 .

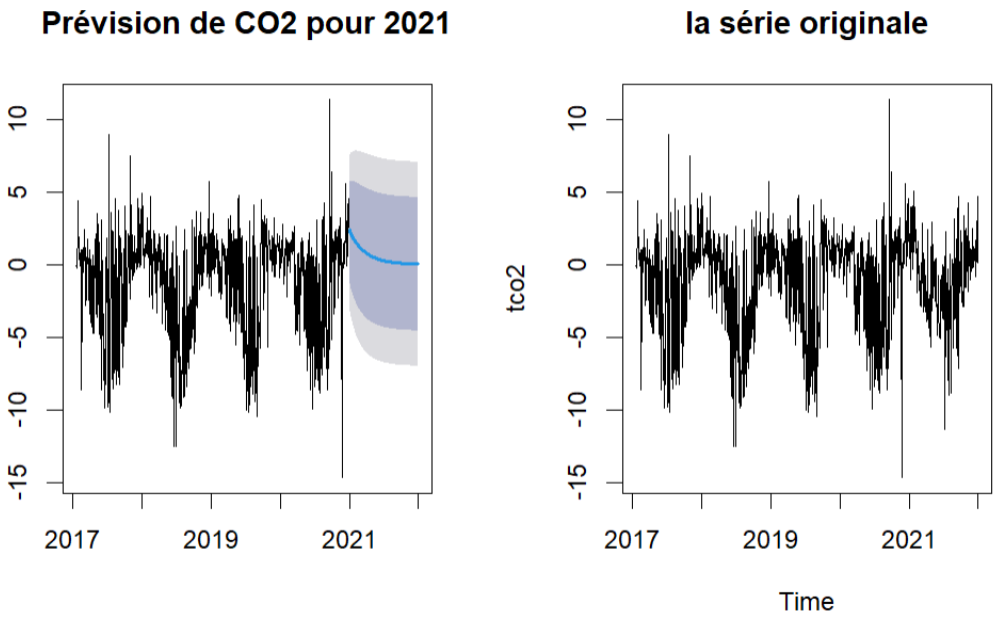


FIGURE 1.46 – Prévision de CO_2 sur 2021

La prévision de 2021 sur le graphique nous confirme la non robustesse du modèle .

Ici, on n'a pas besoin d'étudier la blancheur des résidus car le modèle n'est pas intéressant d'après les informations préliminaires .

CH_4

```
mod_ch4_sr <- auto.arima(tch4_train )
summary(mod_ch4_sr)
```

```
Series: tch4_train
ARIMA(4,0,1) with non-zero mean

Coefficients:
         ar1      ar2     ar3      ar4      ma1     mean
      1.2870  -0.2342  0.0015  -0.0623  -0.9002  -0.0212
s.e.  0.0353   0.0437  0.0429   0.0292   0.0229   0.0054

sigma^2 = 0.0002945:  log likelihood = 3818.12
AIC=-7622.25   AICc=-7622.17   BIC=-7585.33

Training set error measures:
                      ME       RMSE        MAE      MPE     MAPE      MASE         ACF1
Training set 7.331889e-05 0.01712617 0.01282145 42.54727 282.6952 0.5968061 0.0003843698
```

FIGURE 1.47 – modèle de CH_4 sur 2017-2020 sans régresseurs

Le modèle de CH_4 sans régresseur est aussi stationnaire.On remarque que les critères et l'erreur moyenne en pourcentage (MAPE) sont de faibles valeurs, donc ce modèle semble bien capté la dynamique du flux de CH_4 .

Voyons ce que donne le graphique de sa prévision sur 2021 .

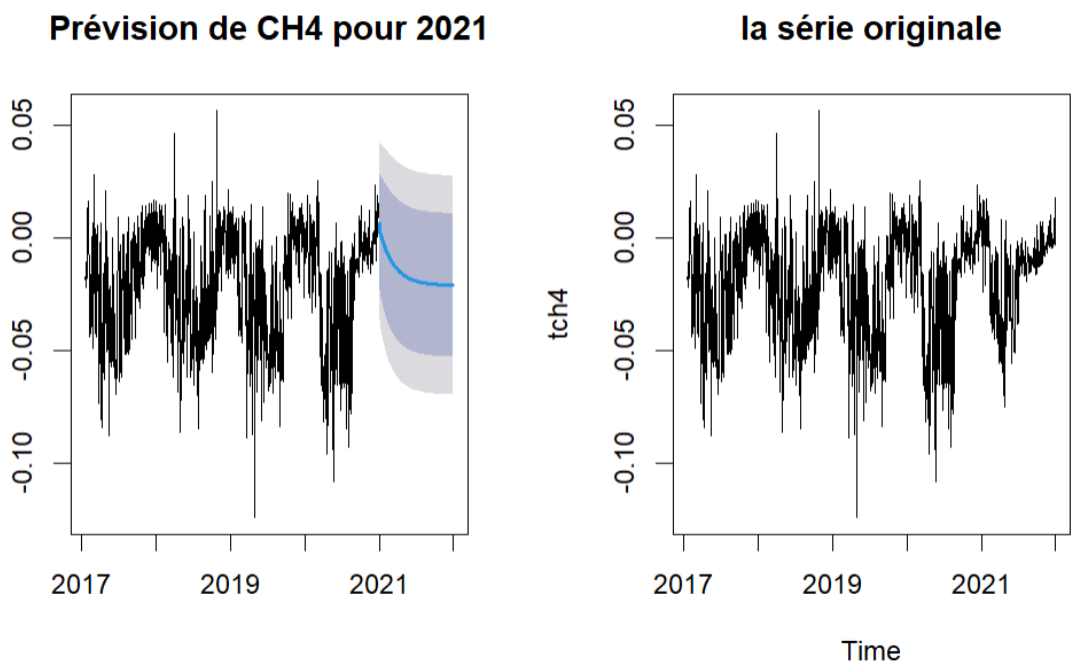


FIGURE 1.48 – Prévision de CH_4 sur 2021

La prévision de 2021 sur le graphique nous présente la faiblesse de la capacité de prédiction de ce modèle .

Ici aussi, plus besoin d'étudier la blancheur des résidus de ce modèle.

On a une idée sur ce que sont les modèles construits sur les composantes avec lesquelles les GES sont corrélés. Passons maintenant à une autre catégorie de régresseurs avec les composantes principales.

B- Régresseurs de CO_2 et de CH_4 : les quatres premières composantes principales

Commençons par définir ces régresseurs :

```
rg1<-as.matrix(acp$li[,c(1,2,3,4)])
rg2<-as.matrix(acp$li[,c(1,2,3,4)])
```

Dans cette partie, on va refaire les mêmes modèles que la partie précédente, qu'on ne va pas étaler ici, mais on va exploiter leurs résultats pour la suite.

1.3.3 Comparaison des modèles

Ici nous allons effectuer une comparaison entre tous les modèles, sur les deux catégories de régresseurs ; sauf celui fait sans régresseur.

Visualisons d'abord la superposition des chronogrammes des données prédites et observées.

CO_2 :

```
tco2_21 <- window(tco2, start = c(2021, 1))
matrix_3<-cbind(tco2_21,pred_co2$mean) #,pred_co2_19_21$upper,
    pred_co2_19_21$lower)

plot(matrix_3, plot.type = "single", lty = c(1,2), col = c("black
    ","red"), xlab = "dates", ylab = "CO2", main = "Superposition␣
    de␣CO2␣predit␣et␣la␣serie␣observee␣2021␣", cex.main = 1.2)
legend(par("usr")[1],par("usr")[4], legend = c("CO2␣Observe","CO2
    ␣predit"),col = c("black","red"), lty = c(1,2),lwd=1,bty = "n")
```

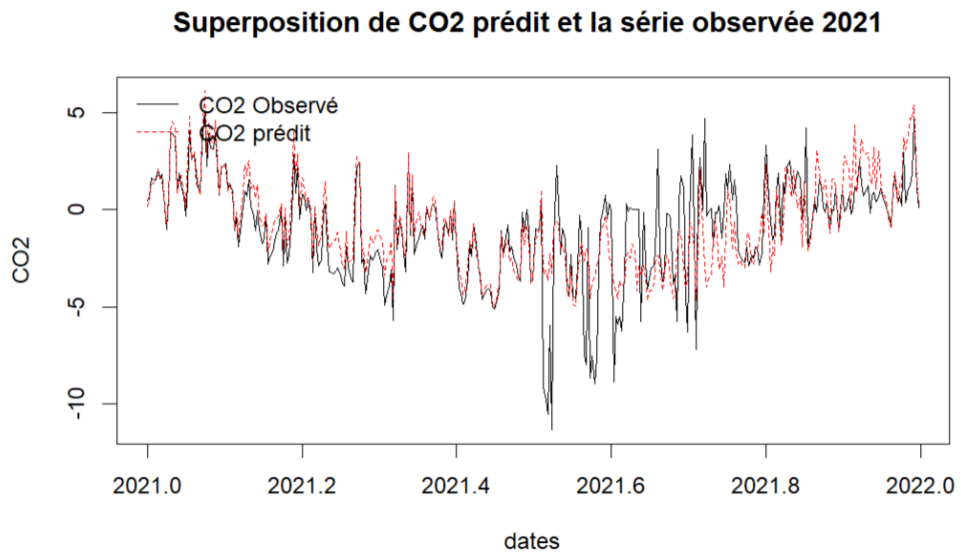


FIGURE 1.49 – Superposition de CO_2 prédit et observé 2021

La prévision de CO2 de ce modèle(2017-2020) semble prédire pas mal l'année 2021. Mais elle n'est pas bien superposé sur les données réelles.

```
tco2_20_21 <- window(tco2, start = c(2020, 1))

matrix_1<-cbind(tco2_20_21,pred_co2_20_21$mean)
plot(matrix_1, plot.type = "single", lty = c(1,2), col = c("black
    ","red"), xlab = "dates", ylab = "CO2", main = "Superposition␣
    de␣CO2␣predit␣et␣la␣serie␣observee␣2020-2021␣", cex.main = 1.2)

```

```
legend(par("usr")[1],par("usr")[4], legend = c("CO2␣Observe","CO2
   ␣predit"),
       col = c("black","red"), lty = c(1,2),lwd=1, bty = "n")
```

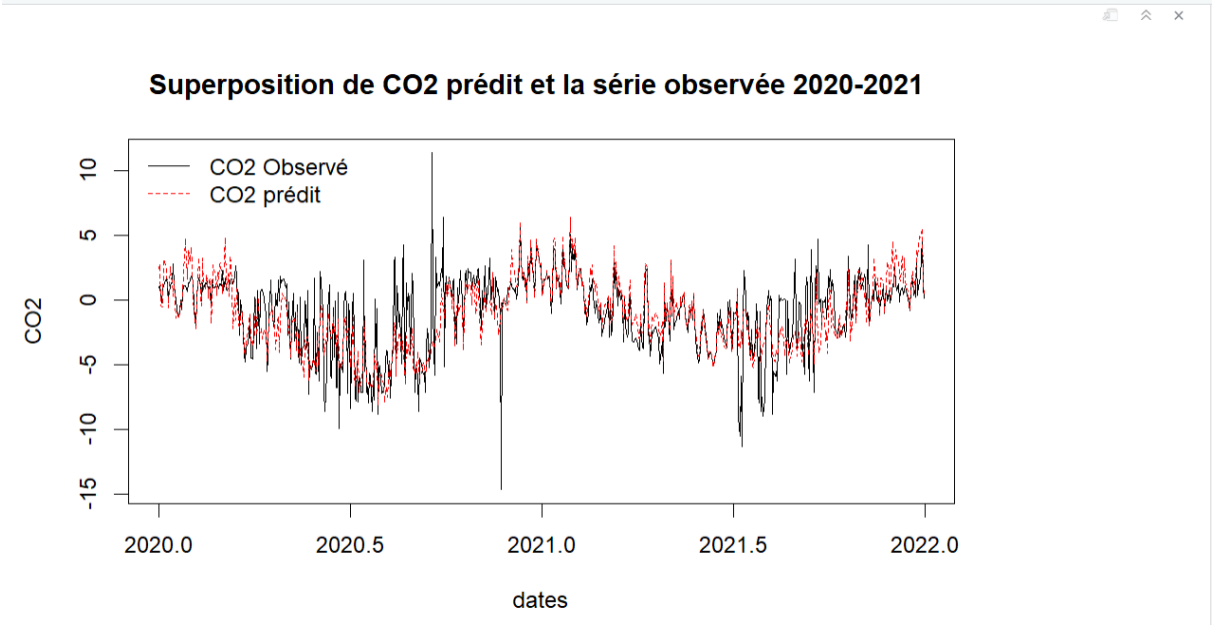


FIGURE 1.50 – Superposition de CO2 prédit et observé 2020-2021

On voit ici que la superposition n'est pas bien faite. On peut dire que la prévision n'est pas assez bonne avec ce modèle .

```
tco2_19_21 <- window(tco2, start = c(2019, 1))
matrix_11<-cbind(tco2_19_21,pred_co2_19_21$mean)

plot(matrix_11, plot.type = "single", lty = c(1,2), col = c("
   black","red"), xlab = "dates", ylab = "CO2",  main = "
   Superposition␣de␣CO2␣predit␣et␣la␣serie␣observee␣2019_2021␣",
   cex.main = 1.2)

legend(par("usr")[1],par("usr")[4], legend = c("CO2␣Observe","CO2
   ␣predit"),col = c("black","red"), lty = c(1,2),lwd=1, bty = "n"
   )
```

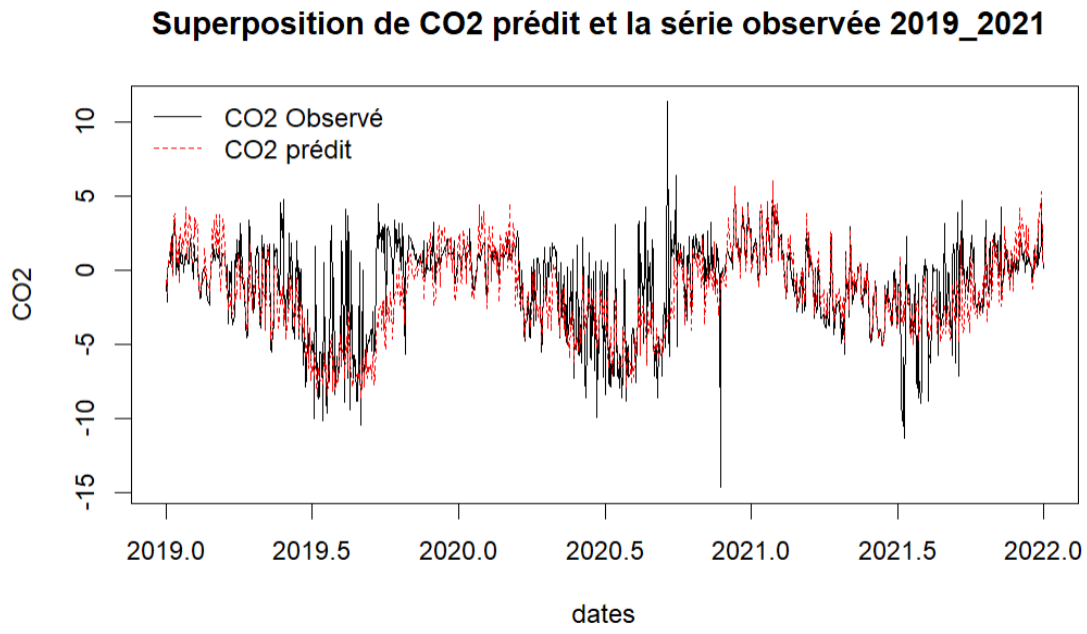


FIGURE 1.51 – Superposition de CO2 prédit et observé sur 2019-2021

La prévision de CO2 de ce modèle(2017-2018) semble être moins bon sur 2021 que les deux dernières.

CH_4

```
tch4_21 <- window(tch4, start = c(2021, 1))
matrix_4<-cbind(tch4_21,pred_ch4$mean)

plot(matrix_4, plot.type = "single", lty = c(1,2),col = c("black"
   ,"red"),xlab = "dates", ylab = "CH4",main = "Superposition de
   CH4 predit et la serie observee en 2021 ", cex.main = 1.2)

legend(par("usr")[1],par("usr")[4], legend = c("CH4 Observe","CH4
   predit"), col = c("black","red"), lty = c(1,2),lwd=1, bty = "n
   ")
```

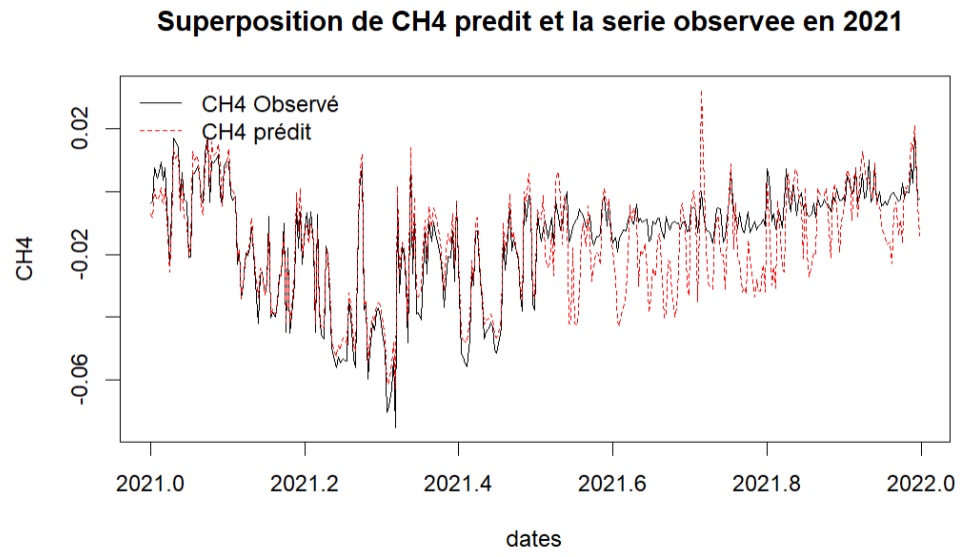


FIGURE 1.52 – Superposition de CH4 prédit et observé 2021

Voyant ça, la superposition n'est pas bien faite, à cause de grand écart visible entre le trait noir et le rouge.

```
tch4_20_21 <- window(tch4, start = c(2020, 1))
matrix_2<-cbind(tch4_20_21,pred_ch4_20_21$mean)

plot(matrix_2, plot.type = "single", lty = c(1,2),col = c("black"
   ,"red"), xlab = "dates", ylab = "CH4", main = "Superposition de
   CH4 predit et la serie observee 2020-2021 ", cex.main = 1.2)

legend(par("usr")[1],par("usr")[4], legend = c("CH4 Observe","CH4
   predit"),col = c("black","red"), lty = c(1,2),lwd=1, bty = "n"
   )
```

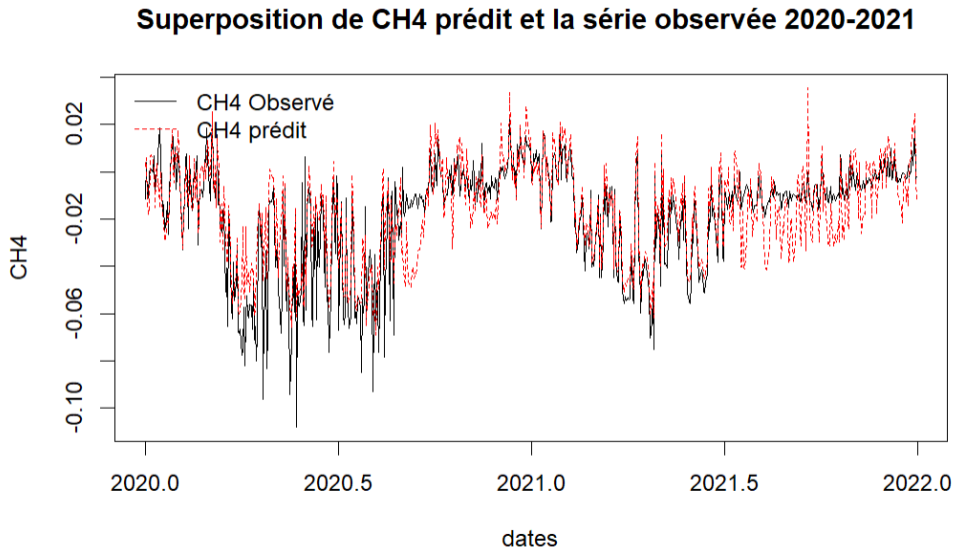


FIGURE 1.53 – Superposition de CH4 prédit et observé 2020-2021

Ici aussi, on voit que la superposition n'est pas bien faite. Donc sans les statistiques, on peut dire que la prévision n'est pas bonne avec ce modèle, et cela se fait plus remarqué en 2021 .

```
tch4_19_21 <- window(tch4, start = c(2019, 1))
matrix_12<-cbind(tch4_19_21,pred_ch4_19_21$mean)

plot(matrix_12,  plot.type = "single", lty = c(1,2), col = c("
    black","red"), xlab = "dates", ylab = "CH4", main = "
    Superposition de CH4 predit et la serie observee en 2019_2021 "
    , cex.main = 1.2)

legend(par("usr")[1],par("usr")[4], legend = c("CH4 Observe","CH4
    predit"), col = c("black","red"), lty = c(1,2),lwd=1,bty = "n"
    )
```

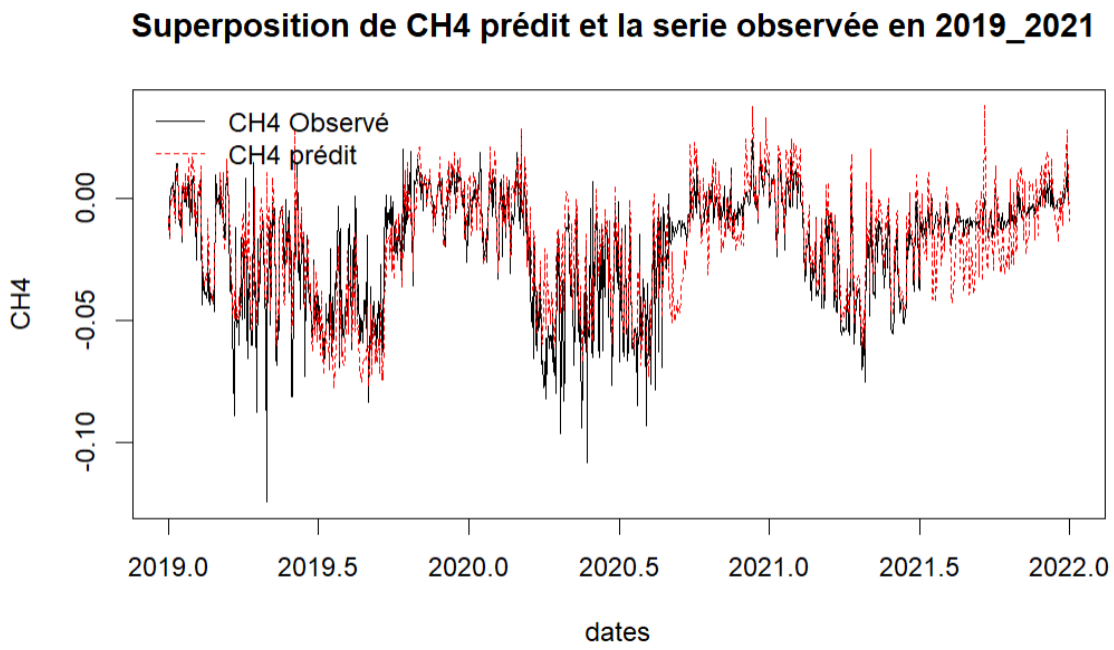


FIGURE 1.54 – Superposition de CH4 prédit et observé 2019-2021

Il semble que la prévision avec ce modèle a mieux captée l'année 2021 que les autre modèle.

Toujours dans le cadre de comparaison, pour être plus précis, on utilise la fonction accuracy(), produisant plusieurs indicateurs :

RMSE (Racine de l'Erreur Quadratique Moyenne), MAE (Erreur Absolue Moyenne), MAPE (Erreur pourcentage absolue moyenne), et Theil's U (indiquant la qualité relative de la prévision par rapport à un modèle naïf).

Et pour plus de précision, la comparaison se fera uniquement sur les prévisions de 2021 des trois modèles des deux gaz, sur ces deux catégories de régresseurs.

Voyons tout d'abord les résultat sur la première catégorie de régresseurs(composante 1,3 pour CO_2 et composante 1,3,4 pour CH_4) .

- Modèle de 2017-2020

```
accuracy(tco2_test,pred_co2_sr$mean)
```

```
                ME     RMSE      MAE       MPE     MAPE      ACF1 Theil's U
Test set 0.2214726 1.721516 1.114809 0.1567243 94.85057 0.5191973 0.5873369
```

FIGURE 1.55 – Erreus de prévision de CO_2 sur 2021 avec le modèle 1

```
accuracy(tch4_test,pred_ch4_sr$mean)
```

```
                    ME        RMSE         MAE      MPE    MAPE      ACF1 Theil's U
Test set -0.002464183 0.009782133 0.007081393 16.62787 91.0725 0.6839007 0.9580824
```

FIGURE 1.56 – Erreus de prévision de CH_4 sur 2021 avec le modèle 1

- Modèle de 2017-2019

```r
tco2_21 <- window(tco2_19_21, start = c(2021, 1), end = c(2021,
    365))
pred_co2_2021 <- window(pred_co2_20_21$mean, start = c(2021, 1),
    end = c(2021, 365))
accuracy(tco2_21, pred_co2_2021)
```

```
                ME    RMSE      MAE       MPE     MAPE      ACF1 Theil's U
Test set 0.2212157 1.75359 1.171426 -5.339274 95.60096 0.5375284 0.9491012
```

FIGURE 1.57 – Erreus de prévision de CO_2 sur 2021 avec le modèle 2

```r
tch4_2021 <- window(tch4_19_21, start = c(2021, 1), end = c(2021,
    365))
pred_ch4_2021 <- window(pred_ch4_20_21$mean, start = c(2021, 1),
    end = c(2021, 365))

accuracy(tch4_2021, pred_ch4_2021)
```

```
                    ME        RMSE         MAE      MPE     MAPE      ACF1 Theil's U
Test set -0.0004015075 0.009654343 0.007472967 21.13917 108.8785 0.6779191 0.4004546
```

FIGURE 1.58 – Erreus de prévision de CH_4 sur 2021 avec le modèle 2

- Modèle de 2017-2018

```r
tco2_21 <- window(tco2_19_21, start = c(2021, 1), end = c(2021,
    365))
pred_co2_2021 <- window(pred_co2_19_21$mean, start = c(2021, 1),
    end = c(2021, 365))

accuracy(tco2_21, pred_co2_2021)
```

```
                ME     RMSE      MAE      MPE     MAPE     ACF1
Test set 0.03388455 1.699483 1.085914 15.13054 81.36274 0.512154
        Theil's U
Test set 0.3855909
```

FIGURE 1.59 – Erreus de prévision de CO_2 sur 2021 avec le modèle 3

```r
tch4_21 <- window(tch4_19_21, start = c(2021, 1), end = c(2021, 365))
pred_ch4_2021 <- window(pred_ch4_19_21$mean, start = c(2021, 1), end = c(2021, 365))

accuracy(tch4_21, pred_ch4_2021)
```

```
                ME       RMSE         MAE      MPE     MAPE      ACF1
Test set 0.00103482 0.01021708 0.008158019 91.37772 174.0714 0.6922782
        Theil's U
Test set 0.3884068
```

FIGURE 1.60 – Erreus de prévision de CH_4 sur 2021 avec le modèle 3

On refait exactement les mêmes choses avec l'autre régresseur(composante 1 à 4), qu'on ne va pas développer ici .

Après comparaison des modèles construits sur différentes périodes d'apprentissage et utilisant différents nombres de composantes principales comme régresseurs, nous avons obtenu les résultats suivants :

CO_2 sur 2021

Période	Axes	ME	RMSE	MAE	MAPE	ACF1	Theil's U
2017–2020	1,3	0.22	1.72	1.11	94.8	0.52	0.59
2017–2020	1,2,3,4	0.08	1.58	0.81	156.1	0.47	0.19
2017–2019	1,3	0.22	1.75	1.17	95.6	0.54	0.95
2017–2019	1,2,3,4	-0.0016	1.59	0.85	116.2	0.47	0.36
2017–2018	1,3	0.03	1.70	1.09	81.4	0.51	0.38
2017–2018	1,2,3,4	-0.32	1.63	1.05	170.1	0.46	0.38

TABLE 1.1 – Qualité des prévisions de CO_2 sur 2021 selon les modèles

— Pour la période la plus longue (2017–2020), le modèle avec **4 axes** (1,2,3,4) obtient de meilleurs scores globaux : plus faible RMSE (1.58), plus faible MAE (0.81) et Theil's U très bas (0.19). Mais le MAPE est plus élevé (156.1) que celui avec seulement 2 axes (94.8).

— Pour 2017–2019, le modèle avec **4 axes** garde un meilleur RMSE (1.59) et un Theil's U plus bas (0.36), mais au prix d'un MAPE encore un peu élevé (116.2 contre 95.6).

— Pour 2017–2018, les deux modèles sont proches : le modèle avec 4 axes a un RMSE un peu plus faible (1.63 vs 1.70) et MAE légèrement plus bas (1.05 vs 1.09), mais un MAPE plus élevé (170.1 vs 81.4).

Globalement, ajouter les axes 2 et 4 améliore souvent la stabilité (ACF1 plus faible) et réduit RMSE et MAE, mais peut augmenter le MAPE, signe d'erreurs plus importantes sur certaines valeurs extrêmes.

Le modèle construit sur la période 2017–2020 avec comme régresseurs les axes 1,2,3 et 4 de l'ACP est retenu. Il présente en effet de bonnes performances globales (RMSE et MAE les plus faibles et Theil's U très bas) malgré un MAPE plus élevé, ce qui est tolérable car il s'explique par quelques valeurs extrêmes, tandis que la tendance générale et la qualité de la prévision sont mieux captées.

Comme sur CO_2, on refait les mêmes choses sur CH_4 . On ne va pas donner les détails du code, mais Les résultats sont juste conférés dans le tableau suivant :

Période	Axes	ME	RMSE	MAE	MAPE	ACF1	Theil's U
2017–2020	1,3,4	-0.0025	0.0098	0.0071	91.1	0.684	0.96
2017–2020	1,2,3,4	-0.0042	0.0108	0.0072	87.8	0.701	0.43
2017–2019	1,3,4	-0.0004	0.0097	0.0075	108.9	0.678	0.40
2017–2019	1,2,3,4	-0.0041	0.0107	0.0071	73.7	0.685	1.04
2017–2018	1,3,4	0.0010	0.0102	0.0082	174.1	0.692	0.39
2017–2018	1,2,3,4	-0.0035	0.0104	0.0069	68.8	0.665	0.53

TABLE 1.2 – Qualité des prévisions de CH_4 sur 2021 selon les modèles

— Sur la période la plus longue (2017–2020), le modèle avec **4 axes** (1,2,3,4) présente un meilleur Theil's U (0.43) et un MAPE plus faible (87.8) que celui avec seulement 3 axes (0.96).

— Pour 2017–2019, le modèle avec **3 axes** (1,3,4) est globalement plus stable, avec un Theil's U très bas (0.40), malgré un MAPE plus élevé (108.9).

— Pour 2017–2018, le modèle avec **4 axes** obtient un MAPE plus bas (68.8 contre 174.1) et un Theil's U légèrement plus élevé (0.53 contre 0.39).

Dans l'ensemble, l'ajout de l'axe 2 semble parfois améliorer la prévision (MAPE plus faible), mais au prix d'une complexité et parfois d'une plus grande instabilité (ACF1 ou Theil's U plus élevés).

Le modèle construit sur la période 2017–2018 utilisant les axes 1,2,3 et 4 comme régresseurs est préféré. Ce modèle obtient un MAPE plus faible et un Theil's U bas, traduisant une meilleure précision relative et une meilleure représentation des variations du CH_4.

1.4 Impact des phénomènes observés sur les flux de CO_2 et CH_4

Notre analyse s'est concentrée sur deux événements majeurs :

— la sécheresse de 2019,

— et la période de confinement liée à la COVID-19 en 2020.

En combinant l'observation des séries temporelles et les résultats des prévisions issues de nos modèles, plusieurs constats apparaissent :

Pour le CO_2

— Le modèle construit sur la période 2017–2018 montre que l'année 2019 (caractérisée par une sécheresse) a perturbé la dynamique habituelle du flux de CO_2 sur une longue période. Cela peut s'expliquer par les quatre composantes qui distinguent nettement cette année, comme on l'observe clairement sur leurs tendances. Cette sécheresse a provoqué une augmentation des fluctuations du CO_2 (moins de consommation et davantage de libération).

— Le modèle intégrant l'année 2019 prédit mieux le flux de 2021 que le modèle sans 2019. De même, le modèle basé sur la période 2017–2020 prédit mieux 2021 que le modèle 2017–2019, ce qui indique que les confinements ont également affecté la tendance du CO_2, en lien avec le ralentissement des activités humaines.

Pour le CH_4

— Les flux de CH_4 apparaissent plus sensibles aux conditions climatiques extrêmes, comme la sécheresse, qui peut limiter l'activité des zones humides responsables des émissions.

— Le modèle construit sur 2017–2019 capte moins bien la prévision pour 2021, ce qui confirme l'impact de la sécheresse sur le flux de CH_4. Cependant, cet effet semble temporaire, car le modèle 2017-2018 prédit mieux 2021.

En résumé :

— La sécheresse de 2019 a surtout amplifié la tendance haussière du flux de CO_2 et perturbé la dynamique naturelle des émissions de CH_4.

— Les confinements de 2020 ont entraîné une baisse ponctuelle des émissions de CO_2 et CH_4, avec effet durable sur CO_2 et sans effet durable au-delà de cette année pour CH_4 .

Après avoir sélectionné les régresseurs et défini la période d'apprentissage la plus pertinente, nous passons maintenant à l'étape de prévision mensuelle des flux de CO_2 et de CH_4. Cette prévision vise à estimer l'évolution future de ces gaz en tenant compte des principales tendances et effets saisonniers identifiés,ce qui est plus pratique.

1.5 Modélisation des flux de CO_2 et CH_4 sur les données mensuelles

Tout d'abord, on finalise la création des données mensuelles, qu'on avait utilisé pour la représentation des month.plot plus haut, et ensuite,on crée celui des composantes principales.

Pour le CO_2

```
co2_mois <- ts(data_mois$FCO2, start = c(2017, 1), frequency =
    12)

plot(co2_mois, main = "Serie temporelle mensuelle de CO2")
```

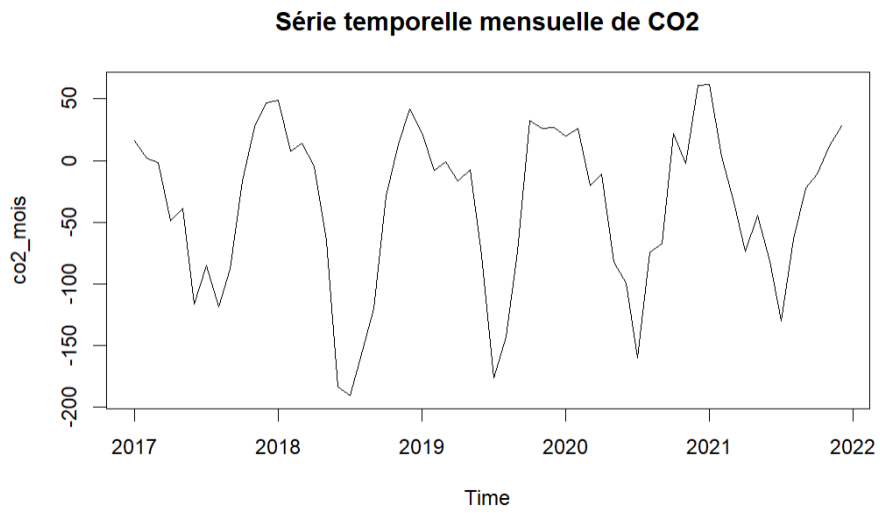


FIGURE 1.61 – Chronogramme des données mensuelles de CO_2

A partir de l'année 2019, on observe l'augmentation des flux de CO2 dans les mois d'été, Ce qui montre la croissance de la tendance observée sur la décomposition des données journalières

Pour le CH_4

```
ch4_mois <- ts(data_mois$FCH4, start = c(2017, 1), frequency =
    12)

plot(ch4_mois, main = "Serie temporelle mensuelle de CH4")
```

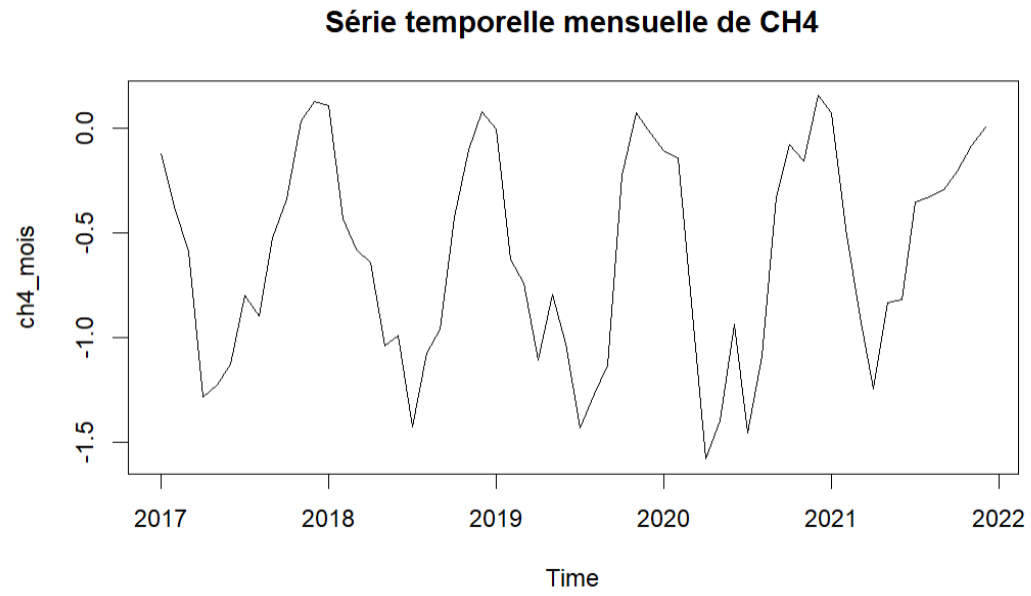


FIGURE 1.62 – Chronogramme des données mensuelles de CH_4

Ici, on observe une décroissance des flux de CH4 en été 2020, et c'est revenu presqu'au normale en 2021, ce qui justifie les analyses et conclusions faites sur le choix du modèle (2017-2018) pour la prévision de CH4 .

— Passons à la création des composantes principales mensuelles

```
comp <- data.frame(comp1 = acp$li[,1],comp2 = acp$li[,2],comp3 =
   acp$li[,3],comp4 = acp$li[,4])
cp_mois <- aggregate(comp, by = list(AnMois), FUN = mean)
colnames(cp_mois)[1] <- "AnMois"
head(cp_mois)
```

Description: df [6 × 5]

	AnMois <dbl>	comp1 <dbl>	comp2 <dbl>	comp3 <dbl>	comp4 <dbl>
1	201701	9.319136	2.099926	-0.9027975	1.2607946
2	201702	6.893655	-0.447396	0.5687444	1.9828711
3	201703	4.273613	-1.985617	0.1996814	1.2263393
4	201704	2.885284	-2.276126	-2.5745387	1.1160457
5	201705	-1.118651	-3.967742	-0.6442247	0.3806638
6	201706	-6.329126	-3.053315	-0.3426851	-0.5310677

6 rows

FIGURE 1.63 – Données mensulles des quatres prémières composantes

— Modélisation

Pour le CO_2

On va tout d'abord définir le régresseur.

```
reg_mois <- as.matrix(cp_mois[, c("comp1", "comp2", "comp3", "
   comp4")])
```

Ensuite à la création des données d'entrainement et test.

```
co2_mois_train <- window(co2_mois, end = c(2020, 12))
reg_mois_17_20 <- reg_mois[1:length(co2_mois_train), ]

co2_mois_test <- window(co2_mois, start = c(2021, 1))
reg_mois_21 <- reg_mois[(length(co2_mois_train)+1):length(co2_
   mois), ]
```

```
mod_co2_mois <- auto.arima(co2_mois_train, xreg = reg_mois_17_20)
summary(mod_co2_mois)
```

```
Series: co2_mois_train
Regression with ARIMA(0,0,1)(1,0,0)[12] errors

Coefficients:
         ma1     sar1  intercept   comp1   comp2    comp3    comp4
      0.6513  0.3711   -36.5085  9.8107  4.5263  22.9905  -4.6335
s.e.  0.1479  0.1677     6.6730  1.0918  1.5872   2.7045   5.0391

sigma^2 = 472.1:  log likelihood = -213.26
AIC=442.52   AICc=446.21   BIC=457.49

Training set error measures:
                     ME     RMSE      MAE       MPE     MAPE      MASE        ACF1
Training set -0.06716818 20.08115 16.51001 -110.1387 134.6743 0.5318801 -0.04262262
```

FIGURE 1.64 – Modèle de CO_2 sur les données 2017-2020 mensuelles

— Le modèle capture la saisonnalité annuelle grâce à l'AR saisonnier et l'effet dynamique grâce à MA.

— Les composantes principales, surtout comp3 et comp1, apportent une bonne partie de l'explication de la tendance et de la variabilité mensuelle.

— Le MAPE élevé montre qu'il reste une variabilité difficile à prédire.
Et l'équation du processus retenu par le modèle est :

$$(1-0.3711B^{12})y_t = -36.51+9.81\cdot\text{comp1}_t+4.53\cdot\text{comp2}_t+22.99\cdot\text{comp3}_t-4.63\cdot\text{comp4}_t+(1+0.6513B) \tag{1.1}$$

Ce qui peut s'ecrire encore sous la forme :

$$y_t-0.3711y_{t-12} = -36.51+9.81\cdot\text{comp1}_t+4.53\cdot\text{comp2}_t+22.99\cdot\text{comp3}_t-4.63\cdot\text{comp4}_t+\varepsilon_t+0.6513\varepsilon_{t-1} \tag{1.2}$$

Vérifions la nature des residus avec le test de blancheur.

```r
Box.test(residuals(mod_co2_mois), lag = 30, type = "Ljung-Box")
```

```
        Box-Ljung test

data:  residuals(mod_co2_mois)
X-squared = 30.166, df = 30, p-value = 0.4572
```

FIGURE 1.65 – Test de blancheur

le resultat de ce test nous amène à accepter la blancheur des residus.

Passons maintenant à la prévision .

```r
par(mfrow=c(1,2))

pred_co2_mois <- forecast(mod_co2_mois,h=365, xreg = reg_mois_21)

plot(pred_co2_mois, main = "Prevision␣sur␣2021")
plot(co2_mois,main="la␣serie␣originale" )
```

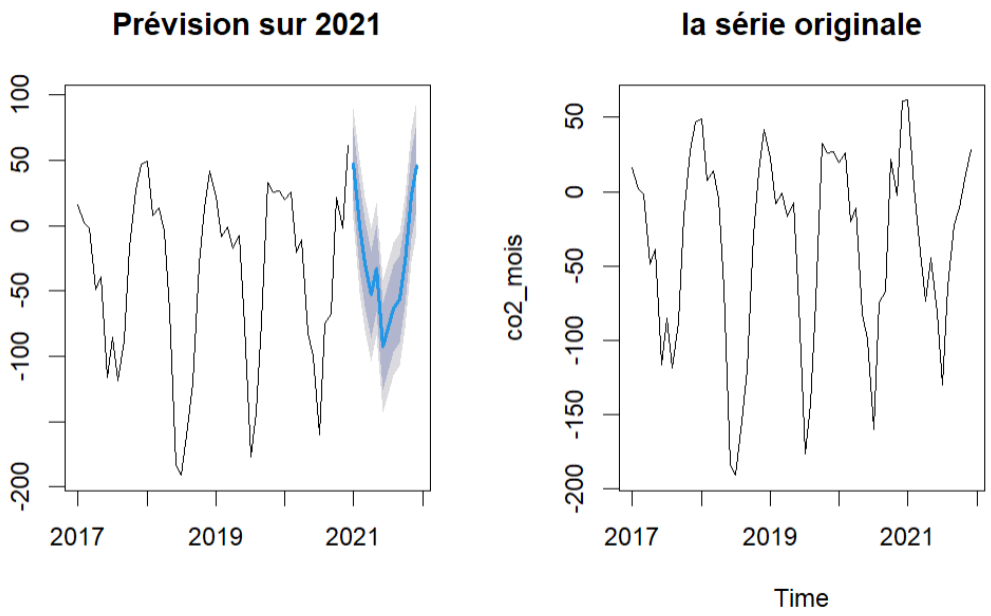


FIGURE 1.66 – Prévision mensuelle de CO_2 sur 2021

La prévision sur 2021 suit la dynamique et la tendance du flux du CO2 observé préalablement avec les données journalières. Certainement, la prévision sur un long horizon donnera la réduction progressive du chronogramme —> plus de consommation de CO2 par la tourbière en été —> plus de sa production par les activités humaines.

Pour le CH_4

Comme retenu sur la série journalière de CH4, on fait un modèle sur l'année 2017-2018 avec les données mensuelles.

```
ch4_mois_train <- window(ch4_mois, end = c(2018, 12))
reg_mois_17_18 <- reg_mois[1:length(ch4_mois_train), ]

ch4_mois_test <- window(ch4_mois, start = c(2019, 1))
reg_mois_19_21 <- reg_mois[(length(ch4_mois_train)+1):length(ch4_
   mois), ]
```

```
mod_ch4_mois <- auto.arima(ch4_mois_train, xreg = reg_mois_17_18)
summary(mod_ch4_mois)
```

```
Series: ch4_mois_train
Regression with ARIMA(0,0,0) errors

Coefficients:
      intercept   comp1   comp2   comp3    comp4
        -0.5409  0.0517  0.0892  0.1779  -0.1448
s.e.     0.0209  0.0048  0.0102  0.0176   0.0253

sigma^2 = 0.007723:  log likelihood = 27.11
AIC=-42.22   AICc=-37.28   BIC=-35.15

Training set error measures:
                      ME       RMSE        MAE        MPE     MAPE      MASE       ACF1
Training set -5.372728e-15 0.07819216 0.05746823 -0.9081018 21.01701 0.2496909 -0.2281406
```

FIGURE 1.67 – Modèle de CH_4 sur les données 2017-2020 mensuelles

— On suppose que tout le signal est capturé par les régresseurs.

— Le coefficient le plus important en valeur absolue est pour la comp3 (0.1779), ce qui montre que cette composante explique la plus grande part de variabilité de CH4.

Le modèle est globalement simple et explique bien la série sans dynamique résiduelle (ACF1 -0.23, pas d'autocorrélation notable). Et aussi les erreurs d'entraînement mesurées sont faible.

L'équation de cette trajectoire s'écrit comme suit :

$$y_t = -0.5409 + 0.0517 \cdot \text{comp1}_t + 0.0892 \cdot \text{comp2}_t + 0.1779 \cdot \text{comp3}_t - 0.1448 \cdot \text{comp4}_t + \varepsilon_t \tag{1.3}$$

Vérifions donc si les résidus sont gaussiens avec le test de Shapiro-Wilk, vu que notre modèle ici est une régression. Les hypothèses sont du test sont :

— $H0$: Les résidus suivent une loi normale.

— $H1$: Les résidus ne suivent pas une loi normale.

```r
shapiro.test(residuals(mod_ch4_mois))
```

```
        Shapiro-Wilk normality test

data:  residuals(mod_ch4_mois)
W = 0.94221, p-value = 0.1826
```

FIGURE 1.68 – Test de normalité sur CH_4

On valide la normalité des residus, car la p-valeure >0.05. Donc la régression est valide. On peut maintenant faire la prévision mensuelle de CH_4 sur 2019-2021 ;

```r
par(mfrow=c(1,2))

pred_ch4_mois <- forecast(mod_ch4_mois,h=3, xreg =reg_mois_19_21
    )
```

```
4
5 plot(pred_ch4_mois, main = "Prevision sur 2021")
6 plot(ch4_mois,main="la serie originale" )
```

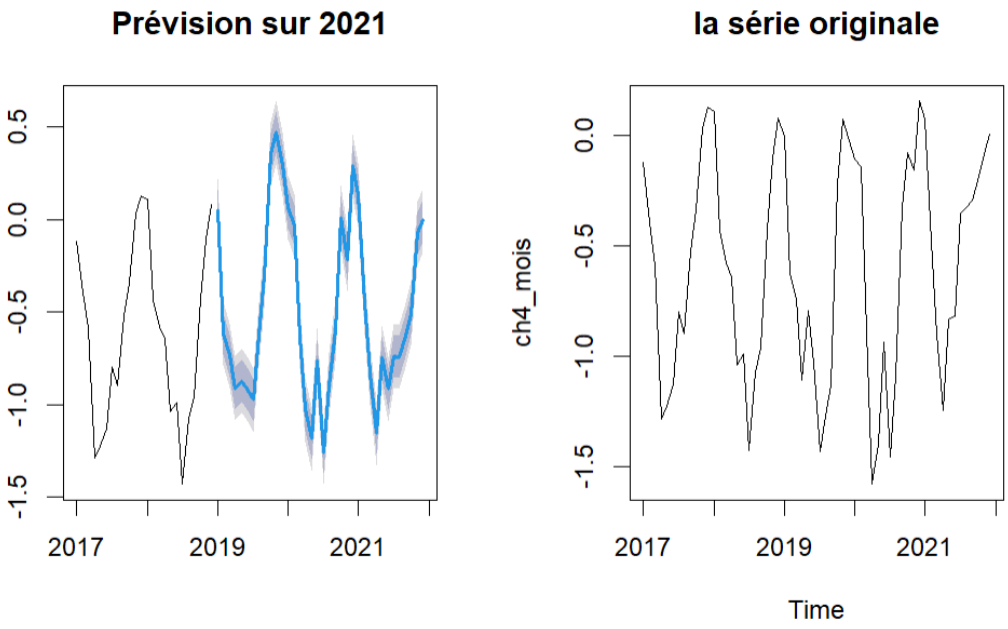


FIGURE 1.69 – Prévision mensuelle de CH_4 sur 2019-2021

Ici, la prévision nous montre une augmentation de la quantité de CH4 libérés en 2019,2020, par rapport aux années précédentes, et qui revient presque au rythme de l'année 2017 en 2021 .Donc les phénomènes de 2019 ont un effet temporaires sur le flux de CH_4 Cette prévision mensuelle de CH_4 confirme bien les conclusions faites avec la série journalière.

En conclusion :

Le choix du modèle(2017-2020) comme étant le meilleur pour la prévision de CO_2, et du modèle(2017-2018) pour la prévision de CH_4 ont bien leurs places a cause des analyses pertinentes faites avant leur choix . Ils ont une bonne prévision sur 2021, mais ayant toujours des imperfections, à cause des données sur une courte période, de l'excès des manquantes et aussi la sensibilité des gaz à effet de serre aux aléas climatiques .

Conclusion générale

Ce projet nous a permis d'explorer la structure des relations entre de nombreuses variables environnementales mesurées sur la tourbière, ainsi que leurs liens avec les flux de gaz à effet de serre (CO_2, CH_4). Nous avons utilisé les méthodes apprises en cours pour explorer nos données et interpréter les résultats. Notre objectif était de mieux comprendre quels facteurs influencent le comportement des GES dans cette tourbière. Pour cela, nous avons commencé par traiter les manquants, qui constituaient un sérieux handicap à notre analyse (Chapitre 1). Ensuite, nous avons appliqué l'ACP pour comprendre en détails quelles conditions atmosphériques et/ou thermiques influent sur les flux de GES (chapitre 2). Enfin, nous les avons étudiés en tant que série temporelle (dernier chapitre).
Nos analyses effectuées par l'ACP ont révélé des axes principaux captant des phénomènes thermiques (axe 1), hydrologiques (axe 2) et atmosphériques (axe 3) ; et leur lien possible avec les flux de GES. Cependant, ces interprétations sont à prendre de manière précautionneuse à cause de la sensibilité des GES aux différents phénomènes observés. De plus, le fait d'avoir imputé les manquants en utilisant une méthode basée sur l'ACP avant de faire une ACP peut biaiser nos résultats.

En ce qui concerne la partie modélisation, nous avons d'abord modélisé les flux journaliers de CO_2 et CH_4 en utilisant des modèles ARIMAX intégrant des composantes principales issues de l'ACP comme régresseurs. Les modèles construits sur différentes périodes (2017–2018, 2017–2019, 2017–2020) ont montré que certains événements extrêmes, comme la sécheresse de 2019 ou les confinements de 2020, avaient un impact notable sur la dynamique des séries, modifiant la tendance et augmentant la variabilité des flux.
Pour affiner l'analyse et lisser les fluctuations de haute fréquence, nous avons ensuite agrégé les données sous forme de séries mensuelles. Les modèles mensuels obtenus ont confirmé l'influence significative des composantes principales (en particulier les axes 1, 2, 3 et parfois 4) sur les flux de gaz à effet de serre.

Dans l'ensemble, la modélisation a mis en évidence l'importance des conditions climatiques et des phénomènes exceptionnels sur la dynamique des émissions.

En résumé, si ce travail nous a permis de dégager des pistes intéressantes sur le comportement des flux de GES, il faut souligner aussi la nécessité de méthodes encore plus rigoureuses et d'une interprétation prudente des résultats.

Annexe des données

Description des variables du projet : **Analyse multidimensionnelle des données de tourbières.**

Code_site_station	Station_nom	Variables	Définition
lgt/ec1	Eddy-covariance station 1	ETR	Actual evapotranspiration by eddy-covariance
lgt/ec1	Eddy-covariance station 1	FCO2	CO2 flux measurements by eddy-covariance
lgt/ec1	Eddy-covariance station 1	FCH4	CH4 flux measurements by eddy-covariance
lgt/bm1	Bio-meteorological station 1	G_1_1_1	Soil heat flux for profil 1_1_1 (depth 2 cm)
lgt/bm1	Bio-meteorological station 1	G_1_1_2	Soil heat flux for profil 1_1_2 (depth 2 cm)
lgt/bm2	Bio-meteorological station 2	G_2_1_1	Soil heat flux for profil 2_1_1 (depth 2 cm)
lgt/bm2	Bio-meteorological station 2	G_2_1_2	Soil heat flux for profil 2_1_2 (depth 2 cm)
lgt/ec1	Eddy-covariance station 1	H	Sensitive heat flow by eddy-covariance
lgt/ec1	Eddy-covariance station 1	LE	Latent heat flow by eddy-covariance
lgt/bm2	Bio-meteorological station 2	LW_IN_1_1_1	LongWave incoming radiation (corrected for T_BODY) for profil 1_1_1
lgt/bm2	Bio-meteorological station 2	LW_OUT_1_1_1	LongWave outgoing radiation (corrected for T_BODY)for profil 1_1_1
lgt/bm1	Bio-meteorological station 1	PA_1_1_1	Air pressure
lgt/bm1	Bio-meteorological station 1	PPFD_IN_1_1_1	Photosynthetic photon flux density incoming for profil 1_1_1
lgt/bm1	Bio-meteorological station 1	P_1_1_1	Precipitation
lgt/sm_exutoire	Multiparameter station	Q	Discharge
lgt/bm1	Bio-meteorological station 1	RH_1_1_1	Relative humidity for profil 1_1_1
lgt/bm1	Bio-meteorological station 1	SWC_1_1_1	Soil water content for profil 1_1_1 (depth 2 cm)
lgt/bm1	Bio-meteorological station 1	SWC_1_1_2	Soil water content for profil 1_1_2 (depth 2 cm)
lgt/bm1	Bio-meteorological station 1	SWC_1_2_1	Soil water content for profil 1_2_1 (depth 5 cm)
lgt/bm1	Bio-meteorological station 1	SWC_1_3_1	Soil water content for profil 1_3_1 (depth 10 cm)
lgt/bm2	Bio-meteorological station 2	SWC_2_1_1	Soil water content for profil 2_1_1 (depth 2 cm)
lgt/bm2	Bio-meteorological station 2	SWC_2_2_1	Soil water content for profil 2_2_1 (depth 5 cm)
lgt/bm2	Bio-meteorological station 2	SWC_2_3_1	Soil water content for profil 2_3_1 (depth 10 cm)
lgt/bm1	Bio-meteorological station 1	SW_IN_1_1_1	ShortWave incoming radiation for profil 1_1_1
lgt/bm2	Bio-meteorological station 2	SW_IN_1_1_1	ShortWave incoming radiation for profil 1_1_1
lgt/bm2	Bio-meteorological station 2	SW_OUT_1_1_1	ShortWave outgoing radiation for profil 1_1_1
lgt/bm1	Bio-meteorological station 1	TA_1_1_1	Air temperature
lgt/bm1	Bio-meteorological station 1	TS_1_1_1	Soil temperature for profil 1_1_1 (depth 2 cm)

lgt/bm1	Bio-meteorological station 1	TS_1_1_2	Soil temperature for profil 1_1_2 (depth 2 cm)
lgt/bm1	Bio-meteorological station 1	TS_1_2_1	Soil temperature for profil 1_2_1 (depth 5 cm)
lgt/bm1	Bio-meteorological station 1	TS_1_2_2	Soil temperature for profil 1_2_2 (depth 5 cm)
lgt/bm1	Bio-meteorological station 1	TS_1_3_1	Soil temperature for profil 1_3_1 (depth 10 cm)
lgt/bm1	Bio-meteorological station 1	TS_1_3_2	Soil temperature for profil 1_3_2 (depth 10 cm)
lgt/bm1	Bio-meteorological station 1	TS_1_4_1	Soil temperature for profil 1_4_1 (depth 25 cm)
lgt/bm1	Bio-meteorological station 1	TS_1_5_1	Soil temperature for profil 1_5_1 (depth 60 cm)
lgt/bm2	Bio-meteorological station 2	TS_2_1_1	Soil temperature for profil 2_1_1 (depth 2 cm)
lgt/bm2	Bio-meteorological station 2	TS_2_1_2	Soil temperature for profil 2_1_2 (depth 2 cm)
lgt/bm2	Bio-meteorological station 2	TS_2_2_1	Soil temperature for profil 2_2_1 (depth 5 cm)
lgt/bm2	Bio-meteorological station 2	TS_2_2_2	Soil temperature for profil 2_2_2 (depth 5 cm)
lgt/bm2	Bio-meteorological station 2	TS_2_3_1	Soil temperature for profil 2_3_1 (depth 10 cm)
lgt/bm2	Bio-meteorological station 2	TS_2_4_1	Soil temperature for profil 2_4_1 (depth 25 cm)
lgt/bm2	Bio-meteorological station 2	TS_2_5_1	Soil temperature for profil 2_5_1 (depth 60 cm)
lgt/bm2	Bio-meteorological station 2	TS_2_6_1	Soil temperature for profil 2_6_1 (depth 80 cm)
lgt/pz_cbdv_amont	Carbiodiv AMONT	TW	Water temperature
lgt/pz_cbdv_aval	Carbiodiv AVAL	TW	Water temperature
lgt/pz_dc	DC	TW	Water temperature
lgt/pz_do	DO	TW	Water temperature
lgt/pz_wc	WC	TW	Water temperature
lgt/sm_exutoire	Multiparameter station	TW	Water temperature
lgt/bm1	Bio-meteorological station 1	WD_1_1_1	Wind direction
lgt/bm1	Bio-meteorological station 1	WS_1_1_1	Wind speed
lgt/bm1	Bio-meteorological station 1	WTD	Water table depth
lgt/bm2	Bio-meteorological station 2	WTD	Water table depth
lgt/pz_cbdv_amont	Carbiodiv AMONT	WTD	Water table depth
lgt/pz_cbdv_aval	Carbiodiv AVAL	WTD	Water table depth
lgt/pz_dc	DC	WTD	Water table depth
lgt/pz_do	DO	WTD	Water table depth
lgt/pz_wc	WC	WTD	Water table depth
lgt/pz_wo	WO	WTD	Water table depth

Annexe 2

Voici la liste des variables corrélées à l'axe 1 :

```
 [1] "ETR"
 [2] "LHeat"
 [3] "lgt.bm1_PPFD_IN_1_1_1"
 [4] "lgt.bm1_SWC_1_1_2"
 [5] "lgt.bm1_SWC_1_2_1"
 [6] "lgt.bm1_SWC_1_3_1"
 [7] "TA"
 [8] "lgt.bm1_TS_1_1_1"
 [9] "lgt.bm1_TS_1_1_2"
[10] "lgt.bm1_TS_1_2_1"
[11] "lgt.bm1_TS_1_2_2"
[12] "lgt.bm1_TS_1_3_1"
[13] "lgt.bm1_TS_1_3_2"
[14] "lgt.bm1_TS_1_4_1"
[15] "lgt.bm1_TS_1_5_1"
[16] "lgt.bm1_WTD"
[17] "lgt.sm_exutoire_TW"
[18] "lgt.pz_cbdv_amont_TW"
[19] "lgt.pz_cbdv_amont_WTD"
[20] "lgt.pz_cbdv_aval_TW"
[21] "lgt.pz_cbdv_aval_WTD"
[22] "lgt.pz_dc_TW"
[23] "lgt.pz_dc_WTD"
[24] "lgt.pz_do_TW"
[25] "lgt.pz_do_WTD"
[26] "lgt.pz_wc_TW"
[27] "lgt.pz_wc_WTD"
[28] "lgt.pz_wo_WTD"
[29] "lgt.bm2_LW_IN_1_1_1"
[30] "lgt.bm2_LW_OUT_1_1_1"
[31] "lgt.bm2_SW_IN_1_1_1"
[32] "lgt.bm2_SW_OUT_1_1_1"
[33] "lgt.bm2_SWC_2_1_2"
[34] "lgt.bm2_SWC_2_3_1"
[35] "lgt.bm2_TS_2_1_1"
[36] "lgt.bm2_TS_2_1_2"
[37] "lgt.bm2_TS_2_2_1"
[38] "lgt.bm2_TS_2_2_2"
[39] "lgt.bm2_TS_2_3_1"
[40] "lgt.bm2_TS_2_4_1"
[41] "lgt.bm2_TS_2_5_1"
[42] "lgt.bm2_TS_2_6_1"
[43] "lgt.bm2_WTD"
```

La liste de celle qui ont une corrélation négalive avec l'axe :

```
 [1] "ETR"
 [2] "LHeat"
 [3] "lgt.bm1_PPFD_IN_1_1_1"
```

```
 [4] "TA"
 [5] "lgt.bm1_TS_1_1_1"
 [6] "lgt.bm1_TS_1_1_2"
 [7] "lgt.bm1_TS_1_2_1"
 [8] "lgt.bm1_TS_1_2_2"
 [9] "lgt.bm1_TS_1_3_1"
[10] "lgt.bm1_TS_1_3_2"
[11] "lgt.bm1_TS_1_4_1"
[12] "lgt.bm1_TS_1_5_1"
[13] "lgt.sm_exutoire_TW"
[14] "lgt.pz_cbdv_amont_TW"
[15] "lgt.pz_cbdv_aval_TW"
[16] "lgt.pz_dc_TW"
[17] "lgt.pz_do_TW"
[18] "lgt.pz_wc_TW"
[19] "lgt.bm2_LW_IN_1_1_1"
[20] "lgt.bm2_LW_OUT_1_1_1"
[21] "lgt.bm2_SW_IN_1_1_1"
[22] "lgt.bm2_SW_OUT_1_1_1"
[23] "lgt.bm2_TS_2_1_1"
[24] "lgt.bm2_TS_2_1_2"
[25] "lgt.bm2_TS_2_2_1"
[26] "lgt.bm2_TS_2_2_2"
[27] "lgt.bm2_TS_2_3_1"
[28] "lgt.bm2_TS_2_4_1"
[29] "lgt.bm2_TS_2_5_1"
[30] "lgt.bm2_TS_2_6_1"
```

La liste de celle qui ont une corrélation positive avec l'axe :

```
 [1] "lgt.bm1_SWC_1_1_2"
 [2] "lgt.bm1_SWC_1_2_1"
 [3] "lgt.bm1_SWC_1_3_1"
 [4] "lgt.bm1_WTD"
 [5] "lgt.pz_cbdv_amont_WTD"
 [6] "lgt.pz_cbdv_aval_WTD"
 [7] "lgt.pz_dc_WTD"
 [8] "lgt.pz_do_WTD"
 [9] "lgt.pz_wc_WTD"
[10] "lgt.pz_wo_WTD"
[11] "lgt.bm2_SWC_2_1_2"
[12] "lgt.bm2_SWC_2_3_1"
[13] "lgt.bm2_WTD"
```

Voici la liste des variables ayant une corrélation négative avec l'axe 2 :

```
[1] "lgt.bm1_SWC_1_1_1"
 [2] "lgt.bm1_SWC_1_1_2"
 [3] "lgt.bm1_SWC_1_2_1"
 [4] "lgt.bm1_SWC_1_3_1"
 [5] "lgt.bm1_WTD"
 [6] "lgt.pz_cbdv_aval_WTD"
 [7] "lgt.pz_dc_WTD"
```

```
 [8] "lgt.pz_do_WTD"
 [9] "lgt.pz_wc_WTD"
[10] "lgt.pz_wo_WTD"
[11] "lgt.bm2_SWC_2_1_1"
[12] "lgt.bm2_SWC_2_1_2"
[13] "lgt.bm2_SWC_2_2_1"
[14] "lgt.bm2_SWC_2_3_1"
```

Bibliographie et documentation

vidéo youtube : Explication des tourbières
https://www.youtube.com/watch?v=S_y16j8Bqes&t=215s.

article wikipédia : Article sur les zones humide
https://fr.wikipedia.org/wiki/Zone_humide.

article : Programme junon
https://www.junon-cvl.fr/fr/comprendre-jumeaux-numeriques.

article : explication du package missMDA
https://delladata.fr/imputation-donnees-manquantes-missmda/.

article : documentation du package missMDA
https://www.jstatsoft.org/article/view/v070i01.

article : site du studium
https://www.lestudium-ias.com/fr/programmes/ambition-research-development-programmes-programme-junon-ard-cvl.

article : archive météeo
https://meteofrance.com/actualites-et-dossiers/actualites/climat/une-canicule-aussi-s

Vidéo Youtube : Vidéo Descriptif de l'ACP
https://www.youtube.com/watch?v=IhBjLeDpOGg.

Vidéo Youtube : Vidéo sur la non stationarisation
https://www.youtube.com/watch?v=4EeBWYuG5_w.

article : documentation du package missMDA
https://www.jstatsoft.org/article/view/v070i01.

article wikipédia :
https://fr.wikipedia.org/wiki/Pand%C3%A9mie_de_Covid-19_en_France.

article wikipédia : Article sur les tourbières
https://fr.wikipedia.org/wiki/Tourbi%C3%A8re

Livres

- Série temporelles avec R, Méthode et cas, Springer de Yves Aragon (2011)
- Série temporelles avec R, Pratique R, edp Sience de Yves Aragon (2016)
- Méthode en séries temporelles et applications avec R, Ellipse de Mohamed B & Manuela R-C, Méthodes (2019)
- Support de cours de Madame Sophie Jacquot sur les Séries temporelles
- Support de cours de Monsieur Didier Chauveau sur la fouille de données
- Plaidoyer pour les tourbières de Hervé Cubizolle
- Les tourbières et la tourbe ,Géographie, hydro-écologie, usages et gestion conservatoire de Hervé Cubizolle